Pengembangan Sistem Deteksi Anomali dan Prioritisasi Ancaman Siber Berbasis *Machine Learning* pada SIEM Wazuh

Laporan Tugas Akhir

Disusun sebagai syarat kelulusan tingkat sarjana

Oleh

Rayhan Nugraha Putra

NIM : 18221149

PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI

SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA

INSTITUT TEKNOLOGI BANDUNG

September 2025

Pengembangan Sistem Deteksi Anomali dan Prioritisasi Ancaman Siber Berbasis *Machine Learning* pada SIEM Wazuh

Laporan Tugas Akhir

Oleh

Rayhan Nugraha Putra

NIM : 18221149

Program Studi Sistem dan Teknologi Informasi

Sekolah Teknik Elektro dan Informatika

Institut Teknologi Bandung

Telah disetujui dan disahkan sebagai Laporan Tugas Akhir

di Bandung, pada tanggal 19 September 2025

Pembimbing,

Signed by BUDI RAHARDJO (HA5937)
Signed on Sep 19, 2025 17:01:55

Ir. Budi Rahardjo, M.Sc., Ph.D.

NIP 109110001

LEMBAR PERNYATAAN

Dengan ini saya menyatakan bahwa:

1. Pengerjaan dan penulisan Laporan Tugas Akhir ini dilakukan tanpa menggunakan bantuan yang tidak dibenarkan.
2. Segala bentuk kutipan dan acuan terhadap tulisan orang lain yang digunakan di dalam penyusunan laporan tugas akhir ini telah dituliskan dengan baik dan benar.
3. Laporan Tugas Akhir ini belum pernah diajukan pada program pendidikan di perguruan tinggi mana pun.

Jika terbukti melanggar hal-hal di atas, saya bersedia dikenakan sanksi sesuai dengan Peraturan Rektor ITB No. 257 tahun 2019 tentang Penegakan Norma Akademik dan Kemahasiswaan Institut Teknologi Bandung.

Bandung, 19 September 2025

Rayhan Nugraha Putra

NIM 18221149

ABSTRAK

Pengembangan Sistem Deteksi Anomali dan Prioritisasi Ancaman Siber Berbasis *Machine Learning* pada SIEM Wazuh

Oleh

Rayhan Nugraha Putra

NIM : 18221149

Tugas akhir ini mengajukan artefak deteksi anomali berbasis *machine learning* untuk mereduksi *alert fatigue* dan meningkatkan efektivitas triase pada lingkungan SIEM Wazuh. Alih-alih klasifikasi biner, masalah dirumuskan sebagai pemeringkatan (Top-K/Top-p) sehingga atensi analis terfokus pada irisan kejadian bernilai tinggi dan berukuran sesuai kapasitas harian. Solusi memanfaatkan *feature spine* ber-*coverage* tinggi dengan pembersihan dan kanonisasi skema yang deterministik. Evaluasi dirancang temporal (latih–validasi–uji prospektif), dengan injeksi kejadian sintetis terkurasi pada fase validasi untuk menyediakan *ground truth* yang relevan secara operasional. Hasil menunjukkan pendekatan bertetangga (k-NN untuk *anomaly scoring*) paling konsisten pada *budgeted triage* kecil. Pada titik operasi p=1%, sistem mencapai *precision@1%* ≈ 0,68, *recall@1%* ≈ 0,23, *lift@1%* > 23× terhadap *base rate*, dan *FPR@1%* ≈ 0,0033 mengindikasikan kepadatan *true positive* yang tinggi pada irisan kecil dan *noise* yang terkendali, dengan stabilitas antar-hari yang memadai. Lapisan *explainability* melalui *reason codes* (fitur kontributor, pembanding "tetangga normal", indikator konteks) mempercepat *handoff* investigasi dan meningkatkan akuntabilitas prioritisasi. Implementasi disiapkan *deployment-friendly* melalui transformer fitur yang dibekukan dan layanan *headless* berkontrak keluaran stabil, siap diintegrasikan dengan dasbor/orkestrasi. Kontribusi utama meliputi: (i) formulasi deteksi sebagai pemeringkatan yang relevan untuk triase; (ii) *feature spine* yang tahan kelangkaan atribut; (iii) pendekatan model yang sensitif konteks lokal dan dapat dijelaskan; serta (iv) desain implementasi siap integrasi. Batasan mencakup keterbatasan sinyal jaringan/geo/taksonomi dan *ground truth* sintetis; arah lanjut adalah perluasan sinyal pasca-pembersihan, pelabelan insiden nyata, dan aktivasi pipeline ujung-ke-ujung.

Kata kunci: deteksi anomali, SIEM, Wazuh, pemeringkatan, k-NN, *explainability*, triase.

KATA PENGANTAR

Puji dan syukur penulis panjatkan kepada Tuhan Yang Maha Esa atas limpahan berkat dan rahmat-Nya, laporan tugas akhir yang berjudul "Pengembangan Sistem Deteksi Anomali dan Prioritisasi Ancaman Siber Berbasis *Machine Learning* pada SIEM Wazuh" dapat diselesaikan sebagai salah satu syarat kelulusan program sarjana pada program studi Sistem dan Teknologi Informasi.

Tugas akhir ini tidak akan dapat terselesaikan tanpa adanya bimbingan, dukungan, dan bantuan dari berbagai pihak. Oleh karena itu, penulis ingin mengungkapkan rasa terima kasih kepada:

1. Bapak Ir. Budi Rahardjo, M.Sc., Ph.D. selaku dosen pembimbing atas waktu, bimbingan, dan masukan yang telah diberikan kepada penulis selama penyusunan tugas akhir.
2. Ir. I Gusti Bagus Baskara Nugraha, S.T., M.T., Ph.D. selaku kepala program studi Sistem dan Teknologi Informasi 2025.
3. Seluruh dosen dan staf pengajar di Sekolah Teknik Elektro dan Informatika ITB yang telah membekali penulis dengan berbagai ilmu dan pengalaman yang berharga selama masa perkuliahan.
4. Dewi Intan Oktarina dan Dahrin Effendi Siregar, selaku orang tua penulis, atas segala doa, kasih sayang, serta dukungan yang tidak pernah berhenti dan tidak terhitung jumlahnya. Berkat keduanya, penulis dapat mengejar setiap mimpi dan pencapaian yang diinginkan, sesuatu yang tidak mungkin diraih seorang diri tanpa fondasi cinta dan pengorbanan yang telah diberikan sejak awal.
5. Mutiara Nur Aliya, selaku adik penulis, yang selalu memberikan semangat, keceriaan, dan dukungan dengan caranya sendiri. Kehadirannya menjadi pengingat untuk tetap ringan dalam menghadapi tantangan dan menjadi sumber motivasi tambahan dalam menyelesaikan perjalanan studi ini.

6. Naila Hasna Sasikirana, selaku pasangan penulis, yang senantiasa berada di sisi penulis dalam setiap pasang surut perjalanan. Dukungan, pengertian, dan semangat yang selalu ia berikan menjadi sumber kekuatan yang tak ternilai dan menjadi motivasi untuk selalu menjadi lebih baik setiap hari.
7. Penghuni Sukahaji 18 Homestay, Josua Adriel Sinabutar, Silvester Kresna Wicaksono, Raden Dizi Assyafadi, dan Clara Alrosa Fernanda, yang menjadikan Sukahaji Baru No.18 rumah kedua yang penuh keceriaan dan kebersamaan sepanjang perjalanan studi penulis.
8. Kimberly, Riguel, Mandew, Hasnan, dan Marvel, sahabat yang penulis temui selama program IISMA, atas kenangan, kebersamaan, dukungan, serta pengalaman berharga selama masa pertukaran sebelum tugas akhir ini menjadi bagian penting dari perjalanan hidup yang akan selalu dikenang.
9. Divisi CSOC PT Telkom Indonesia, khususnya Emak Ibeth, Mas Bakti, dan rekan-rekan lainnya, yang menerima penulis dengan tangan terbuka sejak masa kerja praktik hingga penulisan tugas akhir, serta atas masukan, dukungan, dan penyediaan *dataset* yang menjadi dasar tugas akhir ini.
10. Tanoto Foundation, atas dukungan beasiswa dan pendidikan yang memungkinkan penulis menyelesaikan studi tanpa beban biaya sekaligus mempersiapkan diri menghadapi dunia profesional pasca perkuliahan.

Akhir kata, penulis berharap semoga apa yang telah penulis usahakan dapat memberikan manfaat, baik secara akademis maupun praktis, serta menjadi pijakan bagi penelitian dan pengembangan selanjutnya.

DAFTAR ISI

ABSTRAK ..... **iv**

KATA PENGANTAR ..... **v**

DAFTAR ISI ..... **vii**

DAFTAR LAMPIRAN ..... **xi**

DAFTAR GAMBAR ..... **xii**

DAFTAR TABEL ..... **xiv**

DAFTAR RUMUS ..... **xvi**

BAB I PENDAHULUAN **1**

I.1 Latar Belakang 1

I.2 Rumusan Masalah 2

I.3 Tujuan 3

I.4 Batasan Masalah 3

I.5 Metodologi 4

BAB II STUDI LITERATUR **7**

II.1 Prinsip dan Kerangka Kerja Keamanan Siber 7

II.1.1 Triad CIA (*Confidentiality, Integrity, Availability*) 7

II.1.2 Evolusi Lanskap Ancaman Siber 8

II.1.3 Kerangka Kerja MITRE ATT&CK 9

II.2 *Security Operations Center* (SOC) 14

II.2.1 Peran dan Fungsi 14

II.2.2 Tantangan yang Dihadapi 15

II.3 *Security Information and Event Management* (SIEM) 17

II.3.1 Definisi dan Evolusi 17

II.3.2 Komponen Inti 18

II.3.3 Keterbatasan SIEM Tradisional 20

II.4 Wazuh: Platform SIEM *Open-Source* 22

II.4.1 Arsitektur dan Fitur 22

II.4.2 Keunggulan dan Keterbatasan 24

II.5 *Machine Learning* 25

II.5.1 Algoritma *Machine Learning* 27

II.5.2 Evaluasi Model 29

II.6 Tinjauan Penelitian Terkait 31

II.6.1 *Breaking Alert Fatigue: AI-Assisted SIEM Framework for Effective Incident Response* 32

II.6.2 *Automated Threat-Alert Screening with Temporal Isolation Forest* 32

II.6.3 *AI and Machine Learning in SIEM: Enhancing Threat Detection and Response with Predictive Analytics* 33

II.6.4 *Analysis of Explainable AI Methods in Security Information and Event Management Systems* 34

II.6.5 *Enhancing Security Event Management Systems with Unsupervised Anomaly Detection* 34

II.6.6 *Automating Security Incident Response in SCADA Systems via SIEM-ML Integration* 35

II.6.7 *SIEM Data Acquisition and Analysis with ML Principles* 36

BAB III ANALISIS MASALAH 38

III.1 Analisis Kondisi Saat Ini 38

III.2 Analisis Kebutuhan 40
III.2.1 Identifikasi Masalah Pengguna 40
III.2.2 Kebutuhan Fungsional 46
III.2.3 Kebutuhan Nonfungsional 46
III.3 Analisis Pemilihan Solusi 47
III.3.1 Alternatif Solusi 47
III.3.2 Analisis Penentuan Solusi 53
BAB IV DESAIN DAN IMPLEMENTASI SISTEM 59
IV.1 Gambaran Umum Sistem 59
IV.1.1 Proses Pelatihan 60
IV.1.2 Proses Inferensi 65
IV.1.3 Evolusi Skema Data 67
IV.2 Dataset 72
IV.2.1 Pemahaman Data dan Cakupan Kolom 72
IV.2.2 Pembersihan Data 81
IV.2.3 Rekayasa Fitur 86
IV.2.4 Pemodelan Data 91
IV.3 Implementasi 95
IV.3.1 Implementasi Algoritma 95
IV.3.2 Implementasi Antarmuka Sederhana 96
IV.3.3 Contoh Implementasi API 97
BAB V PENGUJIAN DAN EVALUASI 99
V.1 Metode Pengujian 99

V.1.1 Konfigurasi Sistem 99

V.1.2 Skenario Pengujian 102

V.2 Hasil Evaluasi 103

V.2.1 Evaluasi *Hyperparameter Tuning* dan Pemilihan Model 103

V.2.2 Evaluasi Desain Eksperimen dan Hasil Tuning k-NN (Top-p) 110

V.2.3 Evaluasi *Budgeted Triage* dengan K Tetap untuk Lingkungan Operasional 115

V.3 Diskusi 120

BAB VI KESIMPULAN DAN SARAN 124

VI.1 Kesimpulan 124

VI.2 Saran 125

DAFTAR PUSTAKA 127

DAFTAR LAMPIRAN

A.1 Tabel Metrik Terbaik Pada Algoritma *k-Nearest Neighbor* (Parameter: {"n_neighbors": 35}) 131

A.2 Tabel Metrik Terbaik Pada Algoritma *Isolation Forest* (Parameter: {"n_estimators": 600, "max_samples": 0.5, "max_features": 0.8, "bootstrap": true}) 132

A.3 Tabel Metrik Terbaik Pada Algoritma *Local Outlier Factor*..... 132

B.1 *Screenshot* Tampilan UI Gradio untuk Demo Inferensi 133

C.1 Tautan Github 134

DAFTAR GAMBAR

Gambar II.1 Arsitektur dasar SIEM (Mohanan 2022) 18

Gambar II.2 Arsitektur SIEM Wazuh (Wazuh 2025) 23

Gambar III.1 Skema Pengolahan Data SIEM pada Alur Kerja SOC 38

Gambar IV.1 Diagram Komponen Modul Pembelajaran Mesin 59

Gambar IV.2 Integrasi Modul ML dengan Arsitektur Sistem As-Is..... 60

Gambar IV.3 Diagram Aktivitas Proses Pelatihan..... 61

Gambar IV.4 Diagram Aktivitas Proses Inferensi 65

Gambar IV.5 Contoh *Log Alert* mentah dari Wazuh 68

Gambar IV.6 Contoh *log alert* kanonik 71

Gambar IV.7 Hasil Rekayasa Fitur pada *log* Wazuh 71

Gambar IV.8 Diagram Kelas Evolusi Skema Data 72

Gambar IV.9 Diagram jumlah *alert* per hari..... 75

Gambar IV.10 Histogram distribusi *alert* dalam rentang 24 jam 75

Gambar IV.11 Distribusi jumlah *alert* berdasarkan hari..... 76

Gambar IV.12 Pembagian jumlah *alert* dalam rentang jam kerja 76

Gambar IV.13 *Heatmap* jumlah *alert* dalam jam dan hari tertentu 77

Gambar IV.14 Distribusi tingkat aturan *alert* 78

Gambar IV.15 Distribusi ID aturan yang ditampilkan *alert* 78

Gambar IV.16 Distribusi kelompok aturan yang dihasilkan oleh *alert* 79

Gambar IV.17 Distribusi dekoder aturan yang menghasilkan *alert* 79

Gambar IV.18 Distribusi agen 80

Gambar IV.19 Gambaran Umum Proses dan Transformasi Pembersihan Data ... 81

Gambar IV.20 Gambaran Umum Proses dan Transformasi Rekayasa Fitur 86

Gambar IV.21 Contoh Keluaran API..... 98

Gambar V.1 Visualisasi Penilaian Anomali Peringkat ke-1 107

Gambar V.2 Visualisasi Penilaian Anomali Peringkat ke-3 107

Gambar V.3 *Precision-vs-p* untuk k-NN 112

Gambar V.4 *Recall-vs-p* untuk k-NN 112

Gambar V.5 *Lift-vs-p* untuk k-NN 113

Gambar V.6 Grafik *Precision* pada K tetap (*Precision@K*)..... 116

Gambar V.7 Grafik Perbandingan *Recall* pada K tetap (*Recall@K*)..... 117

Gambar V.8 Grafik Perbandingan *Lift* pada K tetap (*Lift@K*) 117

Gambar V.9 Grafik Perbandingan *FPR* pada K tetap (*FPR@K*)..... 118

Gambar V.10 Grafik Perbandingan *Confusion* pada K tetap..... 119

DAFTAR TABEL

Tabel II.1 Keterkaitan Insiden Keamanan dengan MITRE Framework 12

Tabel II.2 Ringkasan Tinjauan Penelitian Terkait 37

Tabel III.1 Identifikasi Kebutuhan Fungsional Sistem 46

Tabel III.2 Identifikasi Kebutuhan Nonfungsional Sistem 47

Tabel III.3 Kriteria Evaluasi dan Pembobotan AHP..... 54

Tabel III.4 Matriks Penilaian Alternatif Solusi..... 55

Tabel III.5 Hasil Perhitungan Skor AHP 57

Tabel IV.1 Ringkasan Tahapan Proses Pelatihan 63

Tabel IV.2 Informasi Umum Dataset..... 73

Tabel IV.3 Cakupan Fitur Inti Keseluruhan..... 74

Tabel IV.4 Ringkasan Proses Pembersihan Data..... 84

Tabel IV.5 Skema Pembagian Dataset Secara Temporal..... 85

Tabel IV.6 Dekomposisi Fitur yang Direkayasa..... 88

Tabel V.1 Spesifikasi Teknis Perangkat Keras Pengembangan 99

Tabel V.2 Pustaka Eksternal Python (PyPI) 100

Tabel V.3 Pustaka Internal Python 101

Tabel V.4 *Best-of-each* Algoritma pada p Operasi 104

Tabel V.5 Ringkasan 5 Anomali dengan Nilai Fitur Paling Tinggi..... 105

Tabel V.6 Ringkasan 5 Anomali dengan Nilai Fitur Paling Rendah 108

Tabel V.7 Hasil k-NN di p = 1% (Top-1% per hari) 111

Tabel V.8 *Best-of-k* per p 113

Tabel V.9 Ringkasan Kinerja k-NN pada K tetap..... 115

DAFTAR RUMUS

(II.1) Rumus *Precision@K*.....30

(II.2) Rumus *Recall@K*.....30

(II.3) Rumus *Precision@p*.....30

(II.4) Rumus *Recall@p*.....30

(II.5) Rumus Prevalensi.....31

(II.6) Rumus *Lift@p*.....31

(II.7) Rumus *FPR@K/p*.....31

BAB I

PENDAHULUAN

I.1 Latar Belakang

Dengan meningkatnya kompleksitas dan frekuensi ancaman siber di era digital saat ini, organisasi menghadapi tantangan besar dalam mempertahankan infrastruktur teknologi informasi mereka. *Security Operations Center* (SOC) modern dibanjiri dengan volume peringatan keamanan yang sangat besar, menciptakan fenomena yang dikenal sebagai "*alert fatigue*" (Ban dkk. 2023). Kondisi ini terjadi ketika tim keamanan menerima terlalu banyak peringatan yang menyebabkan analis keamanan mengabaikan atau terlambat merespons ancaman yang benar-benar berbahaya.

Sistem *Security Information and Event Management* (SIEM) telah menjadi tulang punggung strategi pertahanan keamanan siber organisasi dengan menyediakan informasi terpusat terhadap aktivitas keamanan di seluruh infrastruktur. Namun, implementasi SIEM tradisional yang mengandalkan pendekatan berbasis aturan statis menghadapi keterbatasan signifikan dalam menangani lanskap ancaman yang terus berkembang. Sistem SIEM konvensional, termasuk *platform open-source* seperti Wazuh, umumnya bergantung pada *signature* dan aturan yang telah ditentukan sebelumnya, membuatnya kurang efektif dalam mendeteksi serangan *zero-day* dan teknik penyusupan yang canggih.

Wazuh, sebagai *platform* SIEM *open-source* yang populer, menyediakan kemampuan deteksi ancaman komprehensif melalui lebih dari 3.000 aturan bawaan dan *framework rule-decoder* yang canggih. Meski demikian, karakteristik data Wazuh yang bersifat "*alert-centric*" dengan dominasi kolom waktu, *rule*, dan *decoder*, namun minim fitur jaringan, geolokasi, dan MITRE ATT&CK, menciptakan tantangan khusus dalam pengembangan mekanisme deteksi anomali

yang efektif. Volume data *alert* yang mencapai ratusan ribu baris dengan tingkat *false positive* yang tinggi mengakibatkan sepertiga profesional IT mengabaikan peringatan keamanan, sehingga berpotensi melewatkan ancaman sebenarnya.

Penelitian terdahulu telah menunjukkan potensi besar integrasi *machine learning* dengan sistem SIEM untuk mengatasi keterbatasan ini. Ban dkk. (2023) berhasil mengurangi *alert fatigue* secara signifikan melalui penggunaan *Instance-weighted Support Vector Machine* (IWSVM), sementara Aminanto dkk. (2019) mencapai reduksi 91,74% alert yang memerlukan investigasi manual menggunakan *Isolation Forest* dengan pendekatan temporal pada sistem *Intrusion Detection System* (IDS). Bulgakova dkk. (2025) juga membuktikan bahwa integrasi *Explainable AI* (XAI) dapat menghasilkan informasi insiden yang lebih detail dan menyederhanakan proses analisis.

Dengan demikian, diperlukan pengembangan sistem deteksi anomali berbasis *machine learning* yang dapat diintegrasikan dengan SIEM Wazuh untuk mengurangi *alert fatigue* dan meningkatkan prioritisasi ancaman. Sistem ini harus mampu menganalisis pola perilaku per *host*, memberikan skor anomali yang dapat dijelaskan, dan mendukung proses triase yang efisien dalam lingkungan SOC operasional.

I.2 Rumusan Masalah

1. Bagaimana memformulasikan deteksi anomali pada data alert Wazuh yang memiliki karakteristik *alert-centric* dengan fitur jaringan dan geolokasi yang minimal agar tetap sahih secara ilmiah dan relevan secara operasional?
2. Bagaimana merancang *pipeline* fitur dengan *coverage* tinggi dan nilai hilang minimal untuk model *unsupervised* pada data historis Wazuh yang heterogen?
3. Seberapa efektif algoritma *k-Nearest Neighbor* dalam menangkap penyimpangan perilaku temporal-aturan per *host* pada skenario SOC nyata?

4. Bagaimana mengevaluasi manfaat operasional sistem deteksi anomali secara komprehensif melalui metrik precision@K, studi kasus, dan kalibrasi *threshold* yang stabil lintas waktu?

I.3 Tujuan

1. Merancang dan mengimplementasikan modul deteksi anomali berbasis *k-Nearest Neighbor* yang terintegrasi dengan alur kerja SIEM Wazuh dengan fokus pada fitur temporal-aturan yang memiliki *coverage* tinggi.
2. Menghasilkan sistem penilaian anomali yang menghasilkan skor anomali dan *reason codes* per *event/host* yang siap digunakan untuk proses triase oleh tim SOC.
3. Menyusun kerangka evaluasi berbasis waktu dengan metodologi *hold-out* temporal, precision@K, uji injeksi anomali sintetis, dan studi kasus untuk memvalidasi efektivitas sistem.
4. Mendokumentasikan desain sistem, *trade-off* implementasi, dan alur pengembangan versi lanjutan yang mencakup pengayaan informasi jaringan/geolokasi/MITRE dan integrasi dengan lingkungan produksi Wazuh.

I.4 Batasan Masalah

1. Penelitian difokuskan pada deteksi anomali perilaku temporal-aturan dan tidak menganalisis *payload* jaringan secara *end-to-end*.
2. Fitur jaringan, geolokasi, dan MITRE ATT&CK bersifat opsional dan hanya digunakan jika tersedia dalam dataset, tidak memblokir proses pemodelan.
3. Evaluasi menggunakan data historis Wazuh dengan ground truth insiden terbatas sehingga menggunakan metrik precision@K dan uji sintetis daripada akurasi klasifikasi supervised.
4. Implementasi terbatas pada *use case* operasional yang telah didefinisikan,.

5. Integrasi dengan sistem SOAR, IDS, dan lingkungan produksi Wazuh tidak menjadi fokus utama tugas akhir ini.

I.5 Metodologi

Tugas akhir ini menggunakan kerangka CRISP-DM (*Cross-Industry Standard Process for Data Mining*) sebagai metodologi untuk merancang, membangun, dan memvalidasi artefak sistem deteksi anomali dan prioritisasi *alert* berbasis *machine learning* pada SIEM Wazuh. CRISP-DM dipilih karena bersifat iteratif, dekat dengan praktik *data-driven engineering*, serta selaras dengan kebutuhan operasional SOC yang menuntut penerapan berkelanjutan. Pemetaan enam tahap CRISP-DM berikut disesuaikan dengan fokus kandidat algoritma (k-NN, *Isolation Forest*, LOF) yang akan dieksplorasi dan dibandingkan. Metodologi ini terdiri atas enam tahap, namun tugas akhir ini hanya melaksanakan lima tahap pertama dan tidak mencakup tahap *deployment*.

1. Pemahaman Bisnis (*Business Understanding*)

Lingkungan SOC menghadapi volume peringatan tinggi, waktu analis terbatas, dan kebutuhan prioritisasi yang jelas, yang berpotensi menimbulkan *alert fatigue*. Tujuan bisnis ditetapkan untuk mengurangi beban baca, mempercepat keputusan triase, dan mengarahkan perhatian analis pada irisan risiko tertinggi melalui *anomaly ranking* yang dapat disisipkan ke alur kerja harian.

2. Pemahaman Data (*Data Understanding*)

Sumber utama adalah log Wazuh beserta *metadata* terkait, misalnya *timestamp*, *agent*, *rule/decoder*, dan atribut jaringan. Tahap ini memetakan cakupan kolom, kualitas serta konsistensi tipe data, keberadaan nilai *placeholder*, dan pola temporal dasar. Temuan awal dicatat sebagai risiko dan masukan untuk tahap persiapan data.

3. Persiapan Data (*Data Preparation*)

Tahap ini merapikan data agar siap dipakai, menyatukan nama kolom dan format yang beragam, menghapus duplikasi, menangani nilai kosong atau tidak bermakna, serta menyelaraskan waktu agar konsisten. Data lalu dipisah berdasarkan rentang

waktu untuk pelatihan, validasi, dan uji supaya penilaian tidak terbantu oleh informasi masa depan. Dari data yang sudah rapi, dibuat sinyal pendukung yang mudah dipahami, misalnya penanda jam kerja dibanding luar jam kerja, hari kerja dibanding akhir pekan, serta indikator seberapa sering suatu kejadian muncul. Prioritas diberikan pada hal yang tersedia dan stabil di banyak sumber. Hasil tahap ini adalah bahan baku yang bersih, ringkas, dan dapat diulang prosesnya.

4. Pemodelan (*Modeling*)

Beberapa pendekatan akan dicoba untuk menilai keunikan sebuah peringatan dan menyusunnya menjadi daftar prioritas. Kandidat metode diambil dari keluarga algoritma yang lazim digunakan untuk mendeteksi anomali. Semua kandidat diarahkan menghasilkan skor yang bisa diurutkan sehingga mendukung *Top-K/Top-p triage*. Perbandingan tidak hanya melihat hasil angka, tetapi juga kegunaan praktis seperti konsistensi dari hari ke hari, kecepatan pemrosesan, kemudahan dipasang di alur kerja yang ada, serta kemudahan alasan hasil dijelaskan kepada analis. Metode yang paling membantu pekerjaan triase dalam konteks data ini akan dipertimbangkan sebagai pilihan utama.

5. Evaluasi (*Evaluation*)

Evaluasi dirancang pada data historis serta skenario terkontrol melalui *anomaly injection*, misalnya pergeseran ke *off-hours*, *rare rule/decoder* per agen, *severity outlier*, dan variasi *recency*. Tolok ukur berorientasi triase: *Precision@K* dan *Recall@K*, *Lift* terhadap *baseline*, konsistensi peringkat antar hari, serta *sanity check* generalisasi. Selain metrik, akan diperiksa *reason codes* atau fitur kontributor sederhana untuk membantu menjelaskan mengapa suatu *alert* berada di peringkat atas. Model terpilih adalah yang menunjukkan keseimbangan terbaik antara kinerja, stabilitas, dan biaya operasional dalam konteks data ini.

Tugas akhir ini tidak bertujuan mengganti mekanisme inti SIEM, melainkan melengkapinya dengan lapisan prioritisasi berbasis *anomaly ranking*. Luaran yang ditargetkan: (i) prototipe artefak dan bukti konsep yang dapat digunakan pada lingkungan uji atau demonstrasi triase, tanpa penerapan produksi, (ii) panduan

singkat penggunaan untuk analis, serta (iii) rekomendasi langkah pengembangan berikutnya agar solusi dapat ditingkatkan secara berkelanjutan sesuai temuan evaluasi.

BAB II

STUDI LITERATUR

II.1 Prinsip dan Kerangka Kerja Keamanan Siber

Keamanan siber merupakan disiplin ilmu yang berkembang pesat dan menjadi aspek kritis dalam era digital saat ini. Penerapan prinsip-prinsip dasar keamanan informasi menjadi fondasi penting dalam melindungi aset informasi dari berbagai ancaman (Whitman dan Mattord 2021). Bagian ini membahas dua komponen utama dalam prinsip dasar keamanan siber, yaitu Triad CIA (*Confidentiality, Integrity, Availability*) dan lanskap ancaman yang terus berkembang.

II.1.1 Triad CIA (*Confidentiality, Integrity, Availability*)

Kerangka Triad CIA (*Confidentiality, Integrity, Availability*) merupakan model konseptual dasar dalam keamanan informasi yang telah menjadi acuan utama dalam perancangan sistem dan kebijakan keamanan di berbagai organisasi. Ketiga komponen ini mewakili tujuan utama yang harus dicapai dalam implementasi keamanan informasi yang efektif (Whitman dan Mattord 2021).

1) ***Confidentiality* (Kerahasiaan)** merujuk pada perlindungan terhadap akses tidak sah ke informasi sensitif. Prinsip ini memastikan bahwa informasi hanya dapat diakses oleh pihak yang memiliki otorisasi dan memiliki kebutuhan untuk mengetahui (*need-to-know basis*). Menurut NIST (2020), kerahasiaan memerlukan penerapan mekanisme kontrol akses yang tepat dan kebijakan klasifikasi informasi yang jelas untuk melindungi data dari pengungkapan yang tidak sah. Beberapa mekanisme yang digunakan untuk menjaga kerahasiaan meliputi enkripsi data, otentikasi, dan manajemen kata sandi yang kuat.
2) ***Integrity* (Integritas)** berfokus pada pemeliharaan keakuratan dan kelengkapan data. Prinsip ini memastikan bahwa informasi tidak diubah secara tidak sah selama penyimpanan maupun proses transmisi. ISO/IEC

27001 (2022) menekankan pentingnya penerapan kontrol yang memadai untuk melindungi integritas informasi dalam seluruh siklus hidupnya. Beberapa metode untuk menjaga integritas data termasuk fungsi hash kriptografi, tanda tangan digital, dan kontrol versi.

3) ***Availability*** **(Ketersediaan)** menjamin bahwa informasi dan sistem tetap dapat diakses oleh pengguna yang berwenang saat dibutuhkan. Whitman dan Mattord (2021) menjelaskan bahwa ketersediaan mencakup keandalan sistem dan pemulihan tepat waktu saat terjadi gangguan. NIST (2020) menekankan pentingnya penerapan mekanisme redundansi, cadangan (*backup*), dan rencana pemulihan bencana untuk memastikan ketersediaan sistem informasi secara berkelanjutan.

Ketiga komponen Triad CIA ini saling terkait dan seringkali membutuhkan keseimbangan dalam implementasinya. ISO/IEC 27001 (2022) mendorong pendekatan berbasis risiko dalam menerapkan kontrol keamanan untuk memastikan perlindungan yang sesuai untuk setiap komponen Triad CIA berdasarkan nilai aset informasi dan tingkat ancaman yang dihadapi organisasi.

II.1.2 Evolusi Lanskap Ancaman Siber

Lanskap ancaman siber terus berkembang dengan kompleksitas dan kecanggihan yang semakin meningkat. Menurut Whitman dan Mattord (2021), evolusi ancaman siber ditandai dengan peningkatan kecanggihan teknik serangan, meluasnya target potensial, dan motif serangan yang beragam. NIST (2020) mengklasifikasikan ancaman siber berdasarkan sumber seperti aktor negara, kelompok kriminal terorganisir, peretas, dan orang dalam, dimana setiap kategori memiliki kemampuan dan motivasi yang berbeda sehingga memerlukan strategi mitigasi yang berbeda pula.

Lanskap ancaman kontemporer ditandai dengan meningkatnya serangan *targeted* dan *persistent*. *Advanced Persistent Threats* (APT) menjadi perhatian utama bagi organisasi dengan aset informasi bernilai tinggi, dimana penyerang menggunakan strategi jangka panjang dan teknik canggih untuk memperoleh akses ke sistem

target (Whitman dan Mattord 2021). Serangan semacam ini sering sulit dideteksi dengan metode tradisional karena dirancang untuk menghindari deteksi standar.

Meningkatnya kompleksitas lanskap ancaman menuntut solusi keamanan yang lebih canggih dan adaptif. Pendekatan tradisional yang mengandalkan deteksi berbasis tanda tangan (*signature-based*) semakin tidak memadai untuk menghadapi ancaman *zero-day* dan serangan yang terus berevolusi. Dalam konteks ini, *Security Information and Event Management* (SIEM) dengan kemampuan analisis yang ditingkatkan menggunakan kecerdasan buatan dan pembelajaran mesin menjadi semakin penting.

Pendekatan deteksi berbasis anomali dan perilaku (*behavior-based*) menggunakan teknologi *machine learning* menawarkan kemampuan untuk mengidentifikasi pola abnormal yang mungkin mengindikasikan aktivitas berbahaya, bahkan ketika pola tersebut belum pernah terlihat sebelumnya. Pendekatan ini menjadi komplemen penting bagi metode deteksi tradisional dalam ekosistem keamanan yang komprehensif, dengan *Security Operations Center* (SOC) memainkan peran krusial dalam orkestrasi upaya pertahanan siber.

II.1.3 Kerangka Kerja MITRE ATT&CK

MITRE ATT&CK adalah basis pengetahuan terbuka tentang taktik dan teknik adversari yang dihimpun dari observasi dunia nyata, dan dipakai luas untuk *threat-informed defense* di kalangan industri, pemerintah, dan komunitas keamanan siber (MITRE 2025). ATT&CK menyediakan matriks taktik–teknik yang eksplisit untuk berbagai domain sehingga praktisi dapat memetakan indikator dan sinyal dari *log* keamanan ke hipotesis perilaku penyerang yang terstandar lintas organisasi. Dengan kerangka kerja ini, proses *hunting*, *detection engineering*, dan *triage* menjadi lebih konsisten dan dapat diaudit, sebab setiap temuan ditautkan ke teknik dan mitigasi yang terdefinisi.

Dalam konteks operasi harian, sinyal sederhana dari *security telemetry* dapat diangkat menjadi hipotesis berbasis ATT&CK. Pendekatan ini tidak “mencari

jarum di tumpukan jerami", melainkan memprioritaskan anomali yang paling selaras dengan taktik/teknik yang diketahui dipakai penyerang. Di bawah ini, lima *use case* umum diringkas bersama sinyal yang biasanya dapat diinferensikan dari *log*, teknik ATT&CK terkait, dan alasan urgensinya.

1) Otentikasi dan akses jarak jauh yang mencurigakan

   Deteksi berfokus pada *logon* di luar jam atau hari kerja, pola *login* yang menyimpang untuk pengguna atau host tertentu, lonjakan akses jarak jauh, serta kembalinya pola akses setelah lama tidak muncul. Skenario ini selaras dengan penyalahgunaan kredensial sah dan pemanfaatan layanan jarak jauh internal maupun eksternal, yaitu T1078 *Valid Accounts*, T1021 *Remote Services*, dan T1133 *External Remote Services*. Urgensinya tinggi karena kombinasi ini kerap menjadi pijakan awal dan jalur pergerakan lateral yang sulit dibedakan dari aktivitas administratif normal.

2) Eksekusi terjadwal di luar siklus normal.

   Indikasi meliputi kemunculan tugas terjadwal pada jam atau hari tidak lazim, pembuatan atau modifikasi *task* atau *job* baru, serta parameter eksekusi yang menyimpang dari kebiasaan. Praktik ini dipetakan ke T1053 *Scheduled Task/Job* termasuk variasi seperti *cron* dan *scheduler Windows*, yang umum dipakai untuk eksekusi berulang dan persistensi yang *low-noise*. Prioritas respons perlu tinggi karena tugas terjadwal memungkinkan muatan berbahaya berjalan otomatis berulang tanpa interaksi pengguna.

3) Persistensi melalui layanan atau daemon.

   Tanda pentingnya adalah layanan atau daemon baru maupun yang dimodifikasi tanpa jendela perubahan, aktivitas layanan pada jam tidak lazim, atau pola start dan stop yang tidak sesuai baseline. Ini berelasi dengan T1543 *Create or Modify System Process*, khususnya T1543.003 *Windows Service* dan T1543.002 *Systemd Service*, yang menjelaskan pembuatan atau modifikasi proses sistem untuk mengeksekusi *payload* secara berulang. Urgensi tinggi karena mekanisme ini bertahan melewati *reboot* dan mudah berkamuflase sebagai layanan sah.

4) Aktivitas *command* atau *scripting interpreter* yang langka atau meledak. Yang dicari adalah lonjakan *PowerShell, Command Prompt*, atau *Unix Shell* pada host yang biasanya tenang, terutama pada jam sepi atau beriring dengan peristiwa lain yang mencurigakan. Pola tersebut dipetakan ke T1059 *Command and Scripting Interpreter* beserta subteknik seperti *PowerShell* (T1059.001) dan *Windows Command Shell* (T1059.003), karena penyerang memanfaatkan interpreter untuk eksekusi perintah, otomasi, penemuan, hingga *staging*. Deteksi dini membatasi ruang gerak penyerang yang sangat fleksibel melalui antarmuka ini.
5) Pola waktu atau ledakan kejadian yang mengarah pada eksfiltrasi terjadwal. Sinyal kunci berupa aktivitas berulang di jam tertentu atau lonjakan terlokalisasi yang, saat dikorelasikan dengan *log* jaringan atau berkas, mengindikasikan perpindahan data. Praktik ini selaras dengan T1029 *Scheduled Transfer*, yang sering berjalan bersama teknik eksfiltrasi lain seperti T1041 *Exfiltration Over C2 Channel* atau T1048 *Exfiltration Over Alternative Protocol*. Urgensinya kritis karena eksfiltrasi sengaja meniru ritme bisnis agar tidak menonjol, sehingga keterlambatan triase berisiko pada kebocoran data yang baru terlihat setelah menimbulkan dampak.

Tabel II.1 merangkum keterkaitan *use case* dengan sinyal yang dapat diinferensikan dari *log* keamanan, teknik ATT&CK yang relevan, serta alasan urgensinya. Tabel ini dimaksudkan untuk menjadi jembatan konseptual dari *telemetry* lapangan menuju hipotesis berbasis taktik/teknik yang dapat diuji lebih lanjut dalam investigasi.

Tabel II.1 Keterkaitan Insiden Keamanan dengan MITRE Framework

Contoh Kasus	**Sinyal yang dapat diinferensikan dari log**	**Taktik & Teknik ATT&CK (kode)**	**Urgensi**
Otentikasi dan akses jarak jauh mencurigakan	Logon di jam/hari tidak lazim, ritme login menyimpang, lonjakan akses RDP/SSH/VPN, kemunculan kembali pola akses	T1078 Valid Accounts, T1021 Remote Services, T1133 External Remote Services	Jalur masuk dan *lateral movement* yang paling umum; memanfaatkan kredensial sah mempercepat perluasan intrusi.
Eksekusi terjadwal di luar siklus	Eksekusi di jam/hari tak biasa; *task/job* baru/diubah; parameter berbeda dari baseline	T1053 Scheduled Task/Job (termasuk T1053.003 Cron)	Memberi persistensi dan otomasi berulang; mengeksekusi payload tanpa interaksi pengguna.
Persistensi via layanan	Layanan baru/diubah; start/stop pada jam aneh; aktivitas layanan menyimpang	T1543 Create or Modify System Process (T1543.003 Windows Service, T1543.002 Systemd Service)	Persisten melewati *reboot* dan mudah berkamuflase sebagai layanan normal.
Interpreter/scripting langka atau meledak	Spike PowerShell/cmd/Unix Shell pada host yang biasanya tenang; terjadi di jam sepi	T1059 Command and Scripting Interpreter (PowerShell, Windows Command Shell, Unix Shell)	*Interpreter* memfasilitasi eksekusi luas mulai dari *discovery* hingga *payload staging*.

Tabel II.1 lanjutan Keterkaitan Insiden Keamanan dengan MITRE Framework

Contoh Kasus	**Sinyal yang dapat diinferensikan dari log**	**Taktik & Teknik ATT&CK (kode)**	**Urgensi**
Pola waktu mengarah ke eksfiltrasi	Aktivitas berulang pada jam tertentu; burst yang selaras dengan jendela transfer	T1029 Scheduled Transfer; terkait T1041 Exfiltration Over C2 Channel/T1048 Exfiltration Over Alternative Protocol	Eksfil “berirama” berupaya menyaru sebagai trafik bisnis; kebocoran data sering terlambat terdeteksi.

II.2 *Security Operations Center* (SOC)

Security Operations Center (SOC) merupakan bagian integral dari strategi keamanan siber organisasi modern. SOC adalah tim terkoordinasi dari analis keamanan dan insinyur yang memantau, mendeteksi, menganalisis, dan merespons insiden keamanan siber menggunakan teknologi, proses, dan prosedur yang terspesialisasi (Miranda 2024). Bagian ini akan membahas peran, fungsi, dan tantangan yang dihadapi SOC dalam mengelola keamanan informasi organisasi.

II.2.1 Peran dan Fungsi

SOC memiliki peran sentral dalam melindungi aset digital organisasi dengan menggabungkan personel, proses, dan teknologi untuk memastikan identifikasi, analisis, dan respons terhadap insiden keamanan yang tepat waktu. Menurut Miranda (2024), SOC berfungsi sebagai pusat komando bagi seluruh operasi keamanan organisasi, mengkoordinasikan berbagai komponen ekosistem keamanan siber untuk memberikan perlindungan menyeluruh.

Fungsi utama SOC mencakup beberapa aspek kritis. Pertama, pemantauan keamanan berkelanjutan (24/7) terhadap infrastruktur organisasi, termasuk jaringan, *server*, *endpoint*, aplikasi, dan *database* untuk mendeteksi aktivitas mencurigakan atau anomali (Cynet 2024). Pemantauan ini menghasilkan visibilitas terhadap seluruh lingkungan teknologi informasi organisasi.

Kedua, SOC melakukan deteksi ancaman dengan mengidentifikasi potensi insiden keamanan melalui analisis *log*, peringatan, dan indikator kompromi. Cynet (2024) menekankan bahwa tim SOC mengimplementasikan teknologi deteksi ancaman seperti SIEM (*Security Information and Event Management*), EDR (*Endpoint Detection and Response*), dan NDR (*Network Detection and Response*) untuk meningkatkan kemampuan deteksi.

Ketiga, SOC bertanggung jawab atas investigasi dan analisis insiden untuk memahami sifat, ruang lingkup, dan dampak potensial dari peristiwa keamanan.

Proses ini meliputi analisis forensik, analisis *malware*, dan pemburuan proaktif terhadap ancaman yang mungkin telah melewati pertahanan (Miranda 2024).

Keempat, SOC menangani respons insiden, yang mencakup penindakan untuk memitigasi dan memulihkan diri pasca insiden keamanan. Proses ini meliputi isolasi sistem yang terpengaruh, penghapusan malware, dan pemulihan sistem (Cynet 2024). Selain itu, SOC juga memiliki fungsi pemulihan dan remediasi untuk memastikan bahwa sistem kembali ke kondisi operasional normal setelah insiden.

Fungsi penting lainnya adalah intelijen ancaman, di mana SOC mengumpulkan dan menganalisis informasi tentang taktik, teknik, dan prosedur (TTP) yang digunakan oleh aktor ancaman untuk memperkuat postur keamanan organisasi. Miranda (2024) menyoroti pentingnya intelijen ancaman dalam memahami lanskap ancaman yang terus berkembang dan beradaptasi terhadap perubahan tersebut.

Dalam konteks kepatuhan dan manajemen risiko, SOC memastikan kepatuhan terhadap kebijakan keamanan, regulasi industri, dan standar keamanan yang relevan. SOC juga terlibat dalam manajemen kerentanan dengan mengidentifikasi, menilai, dan memitigasi kerentanan dalam infrastruktur organisasi sebelum dieksploitasi oleh penyerang (Cynet 2024).

II.2.2 Tantangan yang Dihadapi

Meskipun berperan penting dalam ekosistem keamanan organisasi, SOC menghadapi berbagai tantangan yang dapat menghambat efektivitasnya. Salah satu tantangan utama adalah *alert fatigue*, yang terjadi ketika tim keamanan dibanjiri oleh volume peringatan keamanan yang besar, banyak di antaranya adalah *false positive*. *Alert fatigue* dapat menyebabkan analis mengabaikan peringatan penting atau terlambat dalam merespons insiden sebenarnya.

Tantangan kedua adalah keterbatasan sumber daya, baik dari segi personel maupun teknologi. Banyak organisasi menghadapi kesulitan dalam merekrut dan mempertahankan profesional keamanan siber yang terampil. Keterbatasan

anggaran juga sering menjadi hambatan dalam mengimplementasikan teknologi keamanan yang dibutuhkan.

Kompleksitas ancaman modern juga menjadi tantangan signifikan bagi SOC. Aktor ancaman terus mengembangkan teknik yang lebih canggih untuk menghindari deteksi, seperti *malware polymorphic*, serangan tanpa *file* (*fileless*), dan teknik-teknik lainnya. Hal ini menuntut SOC untuk terus memperbarui pengetahuan dan teknologi mereka.

Selain itu, berdasarkan Miranda (2024), banyaknya perangkat keamanan yang tidak terintegrasi dengan baik dapat menciptakan tumpukan data yang menghambat kemampuan SOC untuk mendapatkan pandangan menyeluruh. Kondisi ini mempersulit korelasi antara kejadian di berbagai bagian infrastruktur.

Tantangan berikutnya adalah skalabilitas. Seiring pertumbuhan organisasi, jumlah perangkat, aplikasi, dan data yang perlu dipantau juga meningkat, menyebabkan beban kerja SOC menjadi lebih berat. Cynet (2024) menyoroti bahwa banyak SOC mengalami kesulitan dalam menskalakan operasi mereka untuk mengimbangi lingkungan teknologi yang berkembang pesat.

Terakhir, SOC juga menghadapi tantangan dalam mengukur efektivitas dan menunjukkan nilai kepada pemangku kepentingan bisnis. Menurut Miranda (2024), sulit untuk mengkuantifikasi kerugian yang dihindari melalui deteksi dan pencegahan insiden yang efektif, yang dapat menyulitkan justifikasi investasi lebih lanjut dalam keamanan.

Pemahaman tentang SOC memberikan wawasan mengenai tantangan operasional yang ingin diatasi oleh sistem SIEM. Dengan mengidentifikasi masalah-masalah seperti *alert fatigue*, keterbatasan sumber daya, dan kompleksitas ancaman dapat lebih memahami pentingnya mekanisme deteksi dan respons ancaman yang efisien, yang menjadi fokus dari sistem SIEM.

II.3 *Security Information and Event Management* (SIEM)

II.3.1 Definisi dan Evolusi

Security Information and Event Management (SIEM) merupakan solusi keamanan komprehensif yang menggabungkan kemampuan *Security Information Management* (SIM) dan *Security Event Management* (SEM) untuk memberikan analisis *real-time* terhadap peringatan keamanan yang dihasilkan oleh berbagai aplikasi dan perangkat jaringan (Kidd 2025). Sistem SIEM dikembangkan sebagai respons terhadap kebutuhan organisasi untuk memiliki visibilitas terpusat terhadap berbagai aspek keamanan infrastruktur teknologi informasi.

Evolusi SIEM dapat dibagi menjadi beberapa generasi utama menurut Nichols dan Paquette (2024). Generasi pertama SIEM, yang muncul pada awal tahun 2000-an, berfokus terutama pada pengelolaan *log* dan kepatuhan terhadap regulasi. Sistem ini menyediakan kemampuan dasar untuk mengumpulkan, menyimpan, dan mencari *log* keamanan, tetapi memiliki kemampuan analisis yang terbatas.

Generasi kedua SIEM mengalami peningkatan signifikan dalam kemampuan korelasi dan analisis, memungkinkan deteksi ancaman yang lebih canggih. Sistem ini mulai menggabungkan informasi kontekstual tentang aset, kerentanan, dan identitas untuk memperkaya data *log* dan memfasilitasi investigasi keamanan yang lebih efektif.

Generasi saat ini, yang sering disebut sebagai SIEM modern atau *next-generation* SIEM, telah berkembang menjadi *platform* yang lebih komprehensif dengan kemampuan yang diperluas. Hal ini mencakup integrasi dengan *threat intelligence*, analisis perilaku pengguna dan entitas (UEBA), dan orkestrasi keamanan, otomatisasi, dan respons (SOAR). Yang terpenting, SIEM modern telah mulai mengadopsi teknologi kecerdasan buatan (AI) dan pembelajaran mesin (ML) untuk meningkatkan deteksi ancaman, mengurangi false positives, dan mempercepat investigasi keamanan.

Dengan kemunculan kecerdasan buatan generatif, SIEM memasuki fase evolusi baru yang menjanjikan. Teknologi ini dapat menganalisis volume data yang jauh lebih besar, mengidentifikasi pola kompleks yang mungkin terlewatkan oleh manusia, dan bahkan membantu analis keamanan dengan mengotomasi tugas-tugas rutin dan memberikan rekomendasi untuk tindakan selanjutnya.

II.3.2 Komponen Inti

Sistem SIEM pada umumnya, seperti yang terdapat pada gambar II.1, terdiri dari beberapa komponen inti yang bekerja bersama untuk menyediakan solusi manajemen keamanan yang komprehensif. Berdasarkan diagram arsitektur SIEM yang ditampilkan, komponen-komponen ini dapat dijelaskan sebagai berikut:

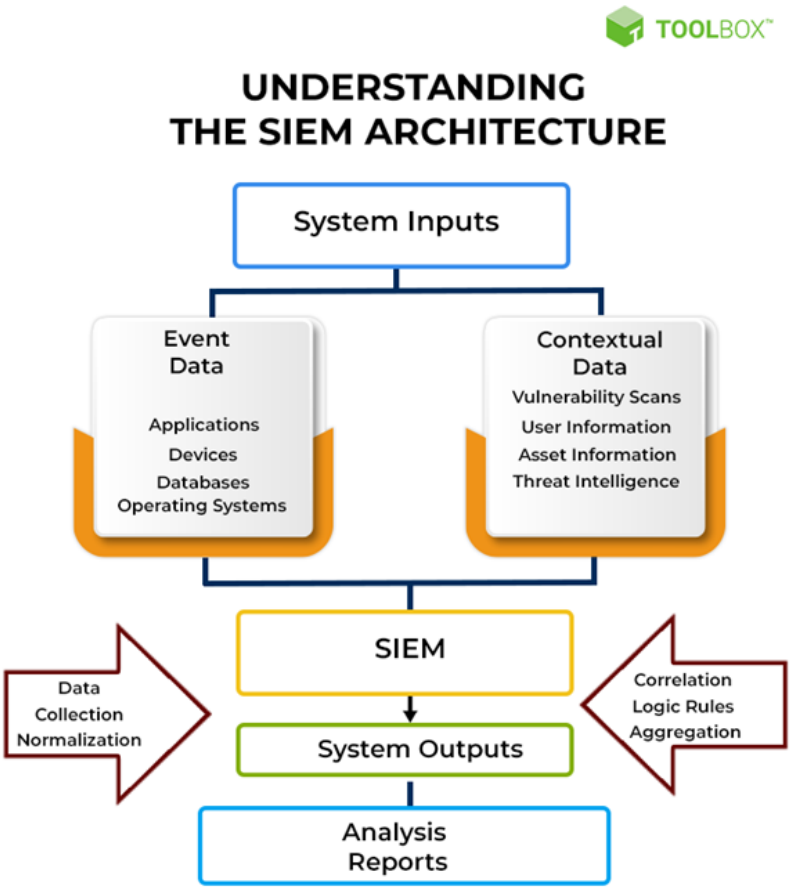

Gambar II.1 Arsitektur dasar SIEM (Mohanan 2022)

1) Input Sistem - Sumber data yang menyediakan informasi bagi SIEM, terbagi menjadi dua kategori utama: **Data Peristiwa** dan **Data Kontekstual**
2) Proses SIEM - Fungsi-fungsi inti yang dilakukan oleh platform SIEM ada dua, yaitu: **Pengumpulan Data dan Normalisasi** yang mengumpulkan *log* dari berbagai sumber dan mengubahnya ke dalam format standar yang dapat diproses oleh SIEM dan fungsi **Korelasi, Logika, Aturan, dan Agregasi** yang bertugas untuk untuk menganalisis data, mengidentifikasi hubungan antar peristiwa, dan menerapkan aturan bisnis untuk mendeteksi pola yang mencurigakan atau indikasi serangan. Komponen ini juga mengagregasi peristiwa serupa untuk mengurangi jumlah *alert*.
3) *Output* Sistem - Hasil dari analisis SIEM, yang kemudian menjadi input untuk proses **Analisis** yang melakukan pemeriksaan mendalam terhadap data keamanan untuk mengidentifikasi tren, pola, dan anomali dan **Laporan** yang menghasilkan dokumentasi terstruktur tentang temuan keamanan, metrik, dan insiden. Laporan dapat disesuaikan untuk berbagai pemangku kepentingan, dari analis keamanan hingga eksekutif bisnis.

Komponen-komponen ini bekerja secara sinergis dalam arsitektur SIEM untuk memberikan visibilitas komprehensif terhadap postur keamanan organisasi, memfasilitasi deteksi ancaman yang cepat, dan mendukung respons yang efektif terhadap insiden keamanan.

Selain komponen dasar yang tercermin dalam diagram, sistem SIEM modern juga mencakup elemen-elemen tambahan seperti:

1) **Penyimpanan Data** - *Database* dan sistem penyimpanan yang dirancang untuk menangani volume besar data *log* dan memungkinkan kueri cepat.
2) **Mesin Analitik** - Prosesor statistik dan algoritma yang menganalisis data untuk mengidentifikasi pola, tren, dan anomali.
3) ***Dashboards* dan Visualisasi** - Antarmuka grafis yang menampilkan postur keamanan organisasi dan membantu analis mengidentifikasi dengan cepat area yang memerlukan perhatian.

4) **Manajemen Kasus** - Alat untuk melacak dan mengelola investigasi insiden keamanan sepanjang siklus hidupnya.
5) **Integrasi API** - Antarmuka yang memungkinkan SIEM berinteraksi dengan sistem dan solusi keamanan lainnya dalam ekosistem organisasi (Splunk, 2024).

II.3.3 Keterbatasan SIEM Tradisional

Meskipun SIEM telah menjadi komponen penting dalam strategi keamanan siber organisasi, sistem SIEM tradisional menghadapi berbagai keterbatasan signifikan yang menghambat efektivitasnya dalam lingkungan keamanan modern. Salah satu masalah utama adalah tingginya tingkat *false positive* yang dihasilkan oleh sistem ini. SIEM tradisional sering menghasilkan banyak peringatan yang tidak valid, menyebabkan fenomena "*alert fatigue*" di kalangan analis keamanan. Hal ini terutama terjadi karena sistem umumnya mengandalkan aturan statis yang kurang mampu membedakan antara aktivitas yang benar-benar berbahaya dan anomali normal dalam operasi sehari-hari.

Ketergantungan pada aturan dan tanda tangan statis menjadi kelemahan mendasar lainnya. SIEM tradisional sangat bergantung pada aturan yang telah ditentukan sebelumnya dan *signature* ancaman yang sudah diketahui, yang membuat mereka kurang efektif dalam mendeteksi serangan *zero-day* dan teknik penyusupan yang canggih. Pendekatan berbasis *signature* ini membatasi kemampuan sistem untuk mengidentifikasi ancaman baru dan teknik serangan yang belum pernah terlihat sebelumnya, membuat organisasi rentan terhadap serangan canggih.

Dengan meningkatnya volume data keamanan secara eksponensial, SIEM tradisional juga menghadapi masalah skalabilitas yang signifikan. Kebanyakan sistem ini mengalami kesulitan dalam menangani dan menganalisis data dalam jumlah besar dengan cepat dan efisien. Keterbatasan ini dapat menyebabkan latensi dalam deteksi ancaman dan sering kali memerlukan investasi perangkat keras yang signifikan untuk mempertahankan kinerja yang dapat diterima. Hal ini

meningkatkan total biaya kepemilikan dan membuat implementasi SIEM menjadi kurang ekonomis bagi banyak organisasi.

Adaptabilitas yang terbatas juga menjadi kendala utama bagi SIEM tradisional. Sistem ini sering kali kekurangan kemampuan untuk dengan cepat beradaptasi dengan lanskap ancaman yang terus berkembang. Pembaruan aturan secara manual memerlukan waktu dan sumber daya yang signifikan, dan sistem sering tertinggal dalam mendeteksi teknik serangan baru. Ketidakmampuan untuk beradaptasi dengan cepat ini menciptakan jendela kerentanan yang dapat dieksploitasi oleh penyerang yang cerdik dan terorganisir (Nichols dan Paquette 2024).

Keterbatasan analitik dan kurangnya konteks dalam peringatan yang dihasilkan lebih lanjut mengurangi efektivitas SIEM tradisional. Kurangnya kemampuan analitik lanjutan membatasi kemampuan sistem untuk mengidentifikasi pola kompleks dan anomali halus yang mungkin mengindikasikan serangan yang canggih. Selain itu, peringatan sering diberikan tanpa konteks yang cukup tentang ancaman potensial, memaksa analis keamanan untuk melakukan investigasi manual tambahan. Hal ini mengurangi efisiensi operasional dan memperlambat waktu respons, memberikan keuntungan bagi penyerang dalam situasi di mana waktu sangat penting.

Terakhir, pendekatan penyimpanan dan pengelolaan data yang tidak efisien dalam SIEM tradisional dapat menyebabkan biaya tinggi dan performa yang buruk saat menganalisis data historis. Sistem sering mengalami kesulitan dalam mempertahankan data historis untuk periode yang panjang atau mengakses data tersebut dengan cepat untuk analisis forensik dan investigasi. Keterbatasan ini menghambat kemampuan organisasi untuk melakukan analisis tren jangka panjang dan memahami pola serangan yang berkembang dari waktu ke waktu.

Keterbatasan-keterbatasan ini telah mendorong evolusi menuju sistem SIEM yang lebih canggih yang menggabungkan kecerdasan buatan dan pembelajaran mesin. Integrasi teknologi ini memungkinkan deteksi ancaman yang lebih akurat, analisis kontekstual yang lebih baik, dan kemampuan respons yang ditingkatkan. Tren ini

mengarah pada pengembangan platform SIEM generasi berikutnya yang lebih adaptif, cerdas, dan mampu memberikan wawasan keamanan yang bermakna dengan mengurangi beban kerja manual analis keamanan.

II.4 Wazuh: Platform SIEM *Open-Source*

Wazuh merupakan *platform* keamanan *open-source* yang berfungsi sebagai solusi SIEM yang komprehensif. Wazuh dirancang untuk melakukan deteksi ancaman, pemantauan integritas, respons insiden, dan kepatuhan regulasi. *Platform* ini dikembangkan sebagai solusi keamanan gratis dan *open-source* yang dapat diimplementasikan pada berbagai skala organisasi, mulai dari infrastruktur kecil hingga lingkungan enterprise yang kompleks (Wazuh 2025).

II.4.1 Arsitektur dan Fitur

Arsitektur Wazuh terdiri dari beberapa komponen utama yang bekerja bersama untuk memberikan solusi SIEM yang komprehensif. Seperti yang ditunjukkan pada Gambar II.2, arsitektur Wazuh terdiri dari tiga komponen utama: *endpoint* (agen), komponen sentral, dan antarmuka pengguna.

Endpoints (Agen Wazuh) dipasang pada sistem yang akan dipantau, seperti *server*, *desktop*, *laptop*, instansi *cloud*, dan mesin *virtual*. Agen Wazuh bertugas untuk mengumpulkan data *log* dan kejadian keamanan, mendeteksi *malware* dan perilaku anomali, memantau integritas file dan registri, mengidentifikasi kerentanan pada aplikasi dan sistem operasi, dan mengevaluasi kepatuhan terhadap standar keamanan seperti PCI DSS, GDPR, HIPAA, dan lainnya.

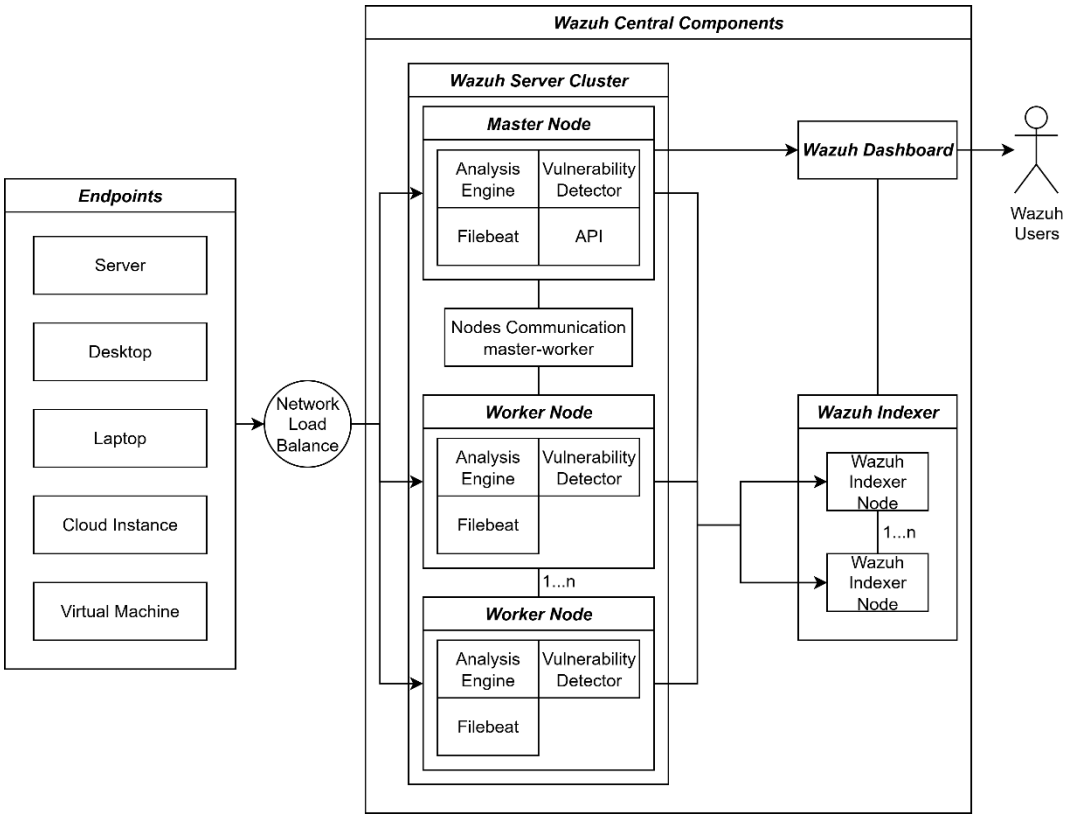

Gambar II.2 Arsitektur SIEM Wazuh (Wazuh 2025)

Komponen sentral Wazuh terdiri dari beberapa elemen penting yang mengelola dan menganalisis data dari agen yang dapat dibagi menjadi beberapa klaster sebagai berikut:

1) *Master Node*: Merupakan *node* utama yang bertanggung jawab untuk konfigurasi dan administrasi. Komponen utamanya meliputi *analysis engine* yang berfungsi untuk menganalisis data yang diterima dari agen, *Filebeat* yang mengirimkan alert ke Wazuh *Indexer,* dan *Vulnerability Detector* yang bertugas untuk mendeteksi kerentanan pada sistem yang dipantau.
2) *Worker Node*: *Node* tambahan yang dapat diskalakan untuk menangani beban kerja yang lebih besar, dengan komponen yang sama seperti *master node*.

Dua komponen terakhir dari komponen sentral Wazuh adalah Wazuh *Indexer* yang merupakan komponen yang menyimpan, mengindeks, dan mencari *alert* yang

dikirimkan dari *server* Wazuh dan Wazuh *Dashboard* yang berisi antarmuka *web* yang memungkinkan pengguna untuk memvisualisasikan data, mengelola setelan, dan memantau status keseluruhan infrastruktur keamanan.

Wazuh sebagai platform keamanan yang memiliki berbagai fitur utama, di antaranya analisis *log* dan deteksi ancaman yang memungkinkan identifikasi aktivitas mencurigakan melalui mesin korelasi berbasis aturan. Selain itu, fitur pemantauan integritas *file* membantu mendeteksi perubahan tidak sah pada *file* sistem dan registri. Wazuh juga mampu mendeteksi kerentanan secara otomatis dengan mengidentifikasi perangkat lunak yang rentan. Untuk kepatuhan, *platform* ini menyediakan alat untuk memastikan kesesuaian dengan standar seperti PCI DSS, GDPR, HIPAA, dan NIST 800-53. Terakhir, Wazuh mendukung respons insiden otomatis yang mempercepat penanganan dan meminimalkan dampak insiden keamanan.

II.4.2 Keunggulan dan Keterbatasan

Sebagai *platform* SIEM *open-source*, Wazuh memiliki keunggulan utama dalam hal efektivitas biaya karena menghilangkan biaya lisensi yang terkait dengan solusi SIEM komersial. Aspek *open-source* ini juga mendorong terciptanya komunitas pengguna dan pengembang yang aktif yang berkontribusi pada perbaikan berkelanjutan platform melalui forum daring, GitHub, dan saluran Slack.

Keunggulan lain yang signifikan adalah skalabilitas Wazuh melalui arsitektur berbasis *cluster* yang memungkinkan platform tumbuh dari implementasi sederhana hingga *cluster* kompleks dengan banyak *node*. Platform ini juga menggunakan pendekatan keamanan berlapis dengan mengintegrasikan deteksi ancaman berbasis *host* dan jaringan, pemantauan integritas *file*, deteksi kerentanan, dan pemantauan kepatuhan dalam satu *platform*, sehingga mengurangi kebutuhan akan beberapa alat keamanan terpisah.

Namun, Wazuh juga memiliki beberapa keterbatasan. Pertama, terdapat kurva pembelajaran yang cukup tajam bagi pengguna baru. Kedua, implementasi yang

efektif memerlukan sumber daya komputasi yang memadai, terutama untuk komponen Wazuh *Indexer* yang memerlukan pertimbangan khusus dalam hal RAM dan penyimpanan.

Keterbatasan lain meliputi kompleksitas integrasi dengan sistem khusus yang mungkin memerlukan pengembangan kustom melalui API Wazuh. dan tantangan dalam pengelolaan volume *alert* yang tinggi. Selain itu, kemampuan pemantauan jaringan Wazuh tidak sekomprehensif solusi *Network Intrusion Detection System* (NIDS) khusus, sehingga sering memerlukan integrasi dengan solusi seperti Suricata atau Snort.

Meskipun terdapat keterbatasan, Wazuh menawarkan alternatif yang layak dan hemat biaya terhadap solusi SIEM komersial. Kemampuan integrasi yang luas dan sifat *open-source*-nya membuat Wazuh menjadi pilihan menarik bagi organisasi yang ingin meningkatkan postur keamanan mereka. Pemahaman tentang Wazuh dan komponen-komponennya sangat penting untuk penelitian ini, karena platform ini akan menjadi dasar untuk penerapan solusi deteksi ancaman berbasis *machine learning*.

Analisis terhadap komponen dan mekanisme kerja SIEM tradisional mengkonfirmasi bahwa keterbatasan fundamental dalam pendekatan rule-based correlation dan static threshold detection menjadi bottleneck utama dalam efektivitas sistem keamanan modern. Kondisi ini membuka peluang untuk mengeksplorasi pendekatan alternatif yang dapat memberikan capability deteksi yang lebih adaptif dan intelligent, khususnya melalui penerapan teknologi machine learning untuk analisis behavioral.

II.5 *Machine Learning*

Berdasarkan analisis tantangan deteksi behavioral yang telah diidentifikasi pada bagian sebelumnya, serta keterbatasan operasional SOC dan SIEM tradisional, machine learning menawarkan paradigma solusi yang menjanjikan untuk mengatasi gap dalam sistem keamanan contemporary. Kemampuan machine learning untuk

mengidentifikasi pola kompleks dalam data berskala besar, beradaptasi dengan perubahan baseline behavioral, dan melakukan deteksi anomali tanpa memerlukan prior knowledge tentang signature serangan menjadikannya pendekatan yang ideal untuk mengatasi limitation yang telah diidentifikasi.

Machine Learning (ML) adalah cabang dari kecerdasan buatan yang memungkinkan sistem komputer untuk belajar dan membuat prediksi atau keputusan tanpa diprogram secara eksplisit (Mohri, Rostamizadeh, dan Talwalkar 2012). Dalam konteks *cybersecurity*, *machine learning* menawarkan kemampuan untuk mendeteksi pola serangan yang kompleks, menganalisis volume data yang besar, dan beradaptasi dengan ancaman yang terus berkembang.

Machine learning dapat diklasifikasikan menjadi tiga paradigma utama:

1) **Pembelajaran Terawasi (***Supervised Learning*)

Pembelajaran terawasi menggunakan *dataset* berlabel dimana algoritma mempelajari pemetaan dari *input* ke *output* yang diinginkan. Dalam *cybersecurity*, pembelajaran terawasi berguna untuk klasifikasi serangan yang sudah diketahui pola atau *signaturenya* (Russell dan Norvig 2021). Model dilatih menggunakan data historis di mana jenis serangan telah diidentifikasi, sehingga dapat mengklasifikasikan serangan serupa di masa depan. Contoh penerapan dalam *cybersecurity* meliputi klasifikasi email *phishing*, deteksi *malware* berdasarkan karakteristik yang diketahui, dan kategorisasi *traffic* jaringan berbahaya

2) **Pembelajaran Tidak Terawasi (***Unsupervised Learning*)

Pembelajaran tidak terawasi bekerja dengan data tanpa label, mengidentifikasi pola dan struktur yang menarik. Dalam *cybersecurity*, metode ini sangat berharga untuk mendeteksi anomali dan serangan baru (*zero-day*) yang belum memiliki *signature* (Goldstein dkk. 2013). Algoritma ini mencari penyimpangan dari perilaku normal yang mungkin menunjukkan aktivitas berbahaya. Contoh penerapan dalam *cybersecurity* meliputi deteksi anomali dalam *traffic* jaringan, identifikasi perilaku

pengguna yang mencurigakan, dan pengelompokan jenis serangan yang belum dikenal

3) **Pembelajaran Penguatan (***Reinforcement Learning*)

Pembelajaran penguatan melibatkan agen yang berinteraksi dengan lingkungan, belajar melalui *trial and error* untuk memaksimalkan *reward*. Dalam *cybersecurity*, pendekatan ini dapat digunakan untuk mengotomatisasi respons terhadap serangan dan mengoptimalkan strategi pertahanan (Russell dan Norvig 2021). Contoh penerapan dalam *cybersecurity* meliputi respons otomatis terhadap serangan dan adaptasi dinamis terhadap taktik penyerang

II.5.1 Algoritma *Machine Learning*

Berbagai algoritma *machine learning* telah diimplementasikan dalam konteks *cybersecurity*, masing-masing dengan kelebihan dan kekurangan yang berbeda. Berikut adalah beberapa algoritma yang paling relevan untuk deteksi dan prioritisasi ancaman siber:

II.5.1.1 Algoritma Berbasis *Ensemble*

Algoritma *ensemble* menggabungkan beberapa model untuk mencapai performa yang lebih baik dibandingkan model individual (Mohri, Rostamizadeh, dan Talwalkar 2012). Algoritma ini sangat efektif untuk klasifikasi serangan siber karena kemampuannya menangani data kompleks dengan dimensi tinggi.

1) Decision Tree

Decision Tree adalah algoritma klasifikasi yang membagi data berdasarkan fitur-fitur menjadi segmen yang semakin homogen. Dalam konteks keamanan siber, *Decision Tree* dapat mengklasifikasikan *traffic* jaringan berdasarkan atribut seperti *port*, protokol, dan ukuran paket (Ban dkk. 2023). Kelebihannya termasuk tingkat interpretasi yang tinggi, memungkinkan analis keamanan untuk memahami alasan di balik klasifikasi tertentu.

2) *Random Forest*

Random Forest adalah *ensemble* dari *decision tree* yang menggunakan teknik *bagging* dan pemilihan fitur acak untuk meningkatkan performa dan mengurangi *overfitting*. Dalam SIEM, *Random Forest* telah terbukti efektif untuk klasifikasi *alert* dan deteksi anomali dengan tingkatan akurasi hingga 97% (Alatawi dan Albalawi 2025).

3) *XGBoost* (*Extreme Gradient Boosting*)

XGBoost adalah implementasi *gradient boosting* yang dioptimalkan untuk performa dan skalabilitas. Teknik *boosting* secara berurutan melatih model baru untuk memperbaiki kesalahan pada model sebelumnya (Al-Dahasi dan Khan 2024). Dalam konteks SIEM, *XGBoost* sangat efektif untuk prioritasi *alert*, dengan kemampuan menangani data yang tidak seimbang dan fitur yang kompleks. Keunggulan *XGBoost* adalah kecepatan pemrosesan dan akurasi yang tinggi, menjadikannya pilihan ideal untuk analisis *real-time* di lingkungan SOC.

II.5.1.2 Algoritma Klasifikasi Konvensional

1) *Support Vector Machine* (SVM)

Support Vector Machine (SVM) bekerja dengan mencari *hyperplane* optimal yang memisahkan kelas-kelas data dengan margin maksimal. Dalam *cybersecurity*, SVM telah digunakan untuk deteksi intrusi, klasifikasi *malware*, dan analisis *traffic* jaringan (Muhammad, Sukarno, dan Wardana 2022). SVM mampu menangani data dimensi tinggi yang umum ditemukan dalam log keamanan.

2) k-*Nearest Neighbors* (k-NN)

k-NN adalah algoritma klasifikasi yang mengklasifikasikan data berdasarkan mayoritas kelas dari k tetangga terdekat. Dalam konteks SIEM, k-NN dapat digunakan untuk mendeteksi anomali berdasarkan kesamaan dengan pola serangan yang diketahui (Goldstein dkk. 2013). Algoritma ini memperhitungkan jarak spasial antara data serangan, memungkinkan identifikasi serangan yang memiliki karakteristik serupa.

3) Naïve Bayes

Naïve Bayes adalah algoritma klasifikasi berbasis probabilitas yang menggunakan *Teorema Bayes* dengan asumsi independensi antar fitur. Dalam *cybersecurity*, Naïve Bayes sering digunakan untuk klasifikasi email dan deteksi spam karena efisiensi komputasinya (Mohri, Rostamizadeh, dan Talwalkar 2012). Meskipun asumsi independensi fitur jarang terpenuhi dalam praktik, algoritma ini tetap memberikan hasil yang baik untuk banyak aplikasi keamanan siber.

II.5.1.3 Algoritma Deteksi Anomali

1) Isolation Forest

Isolation Forest adalah algoritma deteksi anomali yang berbasis pada prinsip isolasi *outlier*. Algoritma ini memisahkan data menggunakan pohon keputusan acak, di mana *outlier* memerlukan lebih sedikit partisi untuk diisolasi (Aminanto dkk. 2019). Dalam konteks SIEM, *Isolation Forest* efektif untuk mendeteksi serangan *zero-day* dan aktivitas yang menyimpang dari pola normal.

2) *One-Class* SVM

One-Class SVM adalah varian SVM yang dilatih hanya menggunakan data dari satu kelas (biasanya kelas normal). Algoritma ini mempelajari batas keputusan yang mencakup data normal dan mengidentifikasi anomali sebagai data yang berada di luar batas tersebut (Ban dkk. 2023). *One-Class* SVM sangat bermanfaat dalam lingkungan di mana data serangan langka atau tidak tersedia.

II.5.2 Evaluasi Model

Evaluasi model pada konteks *budgeted triage* harus memotret kualitas bagian teratas dari daftar berperingkat yang benar-benar akan dibaca analis setiap hari, bukan akurasi di seluruh korpus. Kerangka temu-balik informasi (IR) telah lama menekankan evaluasi "*top of the list*" melalui *precision at K* karena pengguna hanya meninjau halaman teratas; gagasan ini diadopsi untuk triase harian (Manning, Raghavan, dan Schütze 2008). Di sisi lain, tinjauan taksonomi metrik

deteksi anomali menegaskan bahwa pemilihan metrik harus mengikuti tujuan operasional dan batasan domain, sehingga penggunaan metrik berbasis irisan (Top-K atau Top-p) menjadi wajar ketika kapasitas telaah manusia terbatas (Sørbø dan Ruocco 2024).

Secara operasional, daftar skor model diurutkan menurun dan kita menetapkan ambang τ sehingga jumlah prediksi positif tepat sama dengan kapasitas telaah: Top-K (jumlah tetap) atau Top-p (persentase tetap). Seluruh metrik diturunkan dari matriks kebingungan pada ambang τ tersebut: *True Positive* (TP), *False Positive* (FP), *False Negative* (FN), dan *True Negative* (TN). Dua metrik utama pada irisan ini adalah Precision@K/p dan Recall@K/p. Dengan indikator relevansi $1\{relevan_i\}$ kita definisikan sebagai

$$Precision@K = \frac{\sum_{i=1}^{K} 1\{relevan_i\}}{K} \quad \text{(II.1)}$$

$$Recall@K = \frac{\sum_{i=1}^{K} 1\{relevan_i\}}{R} \quad \text{(II.2)}$$

dengan R jumlah total kejadian relevan. Varian *@p* adalah generalisasi langsung pada populasi berukuran N

$$Precision@p = Precision@K \; dengan \; K = [pN] \quad \text{(II.3)}$$

$$Recall@p = Recall@K \; dengan \; K = [pN] \quad \text{(II.4)}$$

sehingga evaluasi secara alamiah mengikuti kapasitas harian (misalnya 1% teratas) ketika volume *alerts* berfluktuasi. Formulasi *@K* untuk evaluasi berperingkat merupakan praktik baku (Manning, Raghavan, dan Schütze 2008), sementara kebutuhan menyesuaikan metrik dengan skenario anomali yang beragam ditegaskan oleh taksonomi metrik *Time Series Anomaly Detection* (TSAD) (Sørbø dan Ruocco 2024).

Untuk menormalkan variasi prevalensi harian (*base rate*), kami melaporkan Lift@p sebagai "berapa kali lebih baik dari acak" pada irisan operasional.

$$Prevalensi = \frac{R}{N} \tag{II.5}$$

$$Lift@p = \frac{Precision@p}{Prevalensi} \tag{II.6}$$

Dengan demikian, *precision*@1% yang sama nilainya dapat dibedakan maknanya lintas hari. *Lift* lebih tinggi berarti konsentrasi sinyal yang lebih baik pada irisan yang sama besar. Pendekatan ini konsisten dengan praktik evaluasi berperingkat yang menimbang manfaat relatif dibanding baseline, sekaligus selaras dengan anjuran memilih metrik yang merefleksikan tujuan operasional (Manning, Raghavan, dan Schütze 2008; Sørbø dan Ruocco 2024)

Karena setiap *false positive* memakan kuota telaah yang mahal, kami juga melaporkan FPR@K/p pada ambang τ(K) atau τ(p) yang sama.

$$FPR@K/p = \frac{FP(\tau)}{FP(\tau)+TN(\tau)} \tag{II.7}$$

Ini adalah definisi baku *False Positive Rate* yang dievaluasi pada suatu ambang; dalam kerangka IR/ROC, ambang dipindahkan sepanjang skor, dan pada konteks triase kita mengambil nilai tepat di ambang yang memotong daftar menjadi *Top-K* atau *Top-p*. Dengan kombinasi Precision@K/p, Recall@K/p, Lift@p, FPR@K/p, serta laporan matriks kebingungan pada ambang yang sama, evaluasi memusat pada irisan yang benar-benar dibaca analis dan karenanya langsung memetakan *hit-rate*, *coverage*, keuntungan relatif atas acak, serta biaya kebisingan, sebuah *metric set* yang koheren dengan tradisi evaluasi berperingkat di IR dan dengan prinsip pemilihan metrik berbasis kebutuhan operasional di TSAD (Manning, Raghavan, dan Schütze 2008; Sørbø dan Ruocco 2024).

II.6 Tinjauan Penelitian Terkait

Bagian ini menyajikan kajian terhadap penelitian-penelitian yang relevan dan menjelaskan bagaimana tugas akhir ini membangun atau melengkapi pendekatan mereka. Tinjauan ini membantu memetakan posisi kontribusi tugas akhir ini di antara upaya-upaya sebelumnya dalam mengintegrasikan *machine learning* dengan sistem SIEM untuk meningkatkan deteksi dan prioritisasi ancaman siber.

II.6.1 *Breaking Alert Fatigue: AI-Assisted SIEM Framework for Effective Incident Response*

Ban dkk. (2023) mengusulkan sebuah kerangka kerja SIEM generasi berikutnya yang mengatasi masalah "*alert fatigue*" atau kelelahan *alert* yang sering dihadapi tim keamanan. Penelitian ini menerapkan pendekatan "*divide-and-conquer*" untuk mengatasi masalah *alert* berlebih yang berkualitas rendah dari berbagai produk keamanan. Kerangka kerja yang diusulkan mengintegrasikan kemampuan *Security Orchestration Automation and Response* (SOAR) dan memanfaatkan teknik *machine learning* dan visualisasi data lanjutan.

Penelitian ini berfokus pada dua masalah utama: proses *filtering* dan korelasi. Untuk *filtering*, mereka menggunakan *Instance-weighted Support Vector Machine* (IWSVM) yang merupakan metode *cost-sensitive learning* untuk menyaring *alert* palsu. Sedangkan untuk korelasi, mereka menggunakan algoritma yang memanfaatkan homogenitas dan kebetulan temporal dari *alert* untuk mengelompokkannya menjadi *event*. Penelitian ini juga memperkenalkan teknik visualisasi yang disebut *Augmented Tile Graph* (ATG) untuk membantu analisis data *alert* keamanan.

Hasil penelitian menunjukkan bahwa kerangka kerja yang diusulkan mampu mengurangi jumlah *alert* secara signifikan dan meningkatkan efisiensi penanganan insiden. Pendekatan ini efektif dalam mengatasi kelelahan *alert* dan memberikan solusi terintegrasi untuk SIEM generasi berikutnya.

II.6.2 *Automated Threat-Alert Screening with Temporal Isolation Forest*

Aminanto dkk. (2019) memperkenalkan metode *screening alert* otomatis yang menggunakan algoritma *Isolation Forest* dengan pertimbangan temporal untuk mendeteksi anomali dalam lalu lintas jaringan. Penelitian ini memanfaatkan sifat *unsupervised* dari algoritma *Isolation Forest*, yang tidak memerlukan pelabelan data sebelumnya, menjadikannya cocok untuk implementasi di lingkungan *Intrusion Detection System* (IDS).

Pendekatan yang digunakan adalah dengan mengolah *alert* dari IDS sebagai *string* teks, mentransformasikannya menjadi representasi numerik, dan kemudian mengelompokkannya menggunakan metode *clustering*. Penelitian ini menyoroti keuntungan menggunakan *Isolation Forest* untuk mendeteksi ancaman, termasuk kemampuannya untuk bekerja dengan dataset kecil pada tahap pelatihan dan kompleksitas waktu linear dengan skalabilitas yang baik.

Hasil menunjukkan bahwa model tersebut mampu mengurangi jumlah *alert* yang perlu diinvestigasi secara manual hingga sekitar 91,74%, dengan hanya 12 *false negative* dari keseluruhan dataset. Pendekatan ini terbukti efektif dalam memerangi kelelahan *alert* dan meningkatkan efisiensi operasional dalam menangani ancaman keamanan.

II.6.3 *AI and Machine Learning in SIEM: Enhancing Threat Detection and Response with Predictive Analytics*

Jangampeta (2022) melakukan survei komprehensif tentang penerapan *Artificial Intelligence* (AI) dan *Machine Learning* (ML) dalam sistem SIEM. Penelitian ini mengidentifikasi bagaimana teknologi AI/ML telah mengubah pendekatan keamanan data dengan memanfaatkan kemampuan pembelajaran mandiri dan algoritma berbasis data. Jangampeta menyoroti bahwa sistem SIEM yang diperkuat dengan AI/ML dapat mengidentifikasi dan merespons insiden keamanan dengan lebih efektif dan cepat, serta mampu beradaptasi dengan sifat ancaman keamanan yang terus berubah.

Studi ini menguraikan beberapa fitur utama yang menjadi keunggulan SIEM berbasis AI, antara lain identifikasi ancaman tingkat lanjut, inspeksi dan peringatan *real-time*, analitik prediktif, pembelajaran adaptif, dan respons *event* otomatis. Jangampeta juga menyoroti tantangan dalam implementasi, termasuk kompleksitas arsitektur, kepatuhan dan privasi data, serta pertimbangan kebijakan seperti kerangka kerja berbagi informasi, kemitraan publik-swasta, dan kerjasama internasional.

Hasil survei menunjukkan bahwa integrasi AI/ML ke dalam SIEM adalah langkah penting untuk menghadapi ancaman keamanan siber yang semakin kompleks, memungkinkan deteksi ancaman yang lebih proaktif dan adaptif.

II.6.4 *Analysis of Explainable AI Methods in Security Information and Event Management Systems*

Bulgakova dkk. (2025) menganalisis penerapan metode *Explainable Artificial Intelligence* (XAI) dalam sistem SIEM. Penelitian ini membahas pentingnya transparansi dan interpretabilitas dalam keputusan yang dibuat oleh model AI dalam konteks keamanan informasi. Penulis mengkaji metode XAI seperti LIME (*Local Interpretable Model-agnostic Explanations*), SHAP (*SHapley Additive exPlanations*), GradCAM (*Gradient-weighted Class Activation Mapping*), dan LRP (*Layer-wise Relevance Propagation*).

Studi ini menunjukkan adanya *trade-off* antara akurasi dan interpretabilitas model AI. Model yang lebih kompleks cenderung memiliki akurasi lebih tinggi tetapi sulit dipahami, sementara model yang lebih sederhana lebih mudah dijelaskan tetapi mungkin kurang akurat. Untuk mengatasi masalah ini, peneliti mengusulkan penggunaan metode LIME yang memecah model kompleks menjadi model linear yang lebih sederhana namun tetap mempertahankan akurasi yang tinggi.

Hasil eksperimen pada sistem SIEM dengan *add-on* berbasis XAI menunjukkan bahwa integrasi XAI tidak hanya mengotomasi analisis data dan deteksi anomali, tetapi juga memberikan informasi insiden yang lebih detail, termasuk deskripsi ancaman yang lengkap. Hal ini sangat menyederhanakan analisis dan respons insiden.

II.6.5 *Enhancing Security Event Management Systems with Unsupervised Anomaly Detection*

Goldstein dkk. (2013) mengusulkan peningkatan sistem SIEM dengan deteksi anomali *unsupervised* untuk mengatasi keterbatasan sistem berbasis aturan tradisional. Penelitian ini berfokus pada penerapan algoritma deteksi anomali tanpa

pengawasan pada data *event* yang dikumpulkan dari SIEM, khususnya untuk mendeteksi upaya otentikasi mencurigakan, serangan penebakan password, dan aktivitas akun pengguna yang tidak biasa.

Para peneliti menerapkan enam algoritma deteksi anomali yang berbeda dan mengevaluasinya secara kualitatif. Mereka menyimpulkan bahwa pendekatan k-NN global paling efektif untuk kasus penggunaan mereka. Sistem mereka berhasil mendeteksi kesalahan konfigurasi dan memberikan wawasan yang lebih mendalam tentang proses dalam jaringan yang tidak terdeteksi oleh SIEM berbasis aturan tradisional.

Hasil penelitian menunjukkan bahwa deteksi anomali tanpa supervisi dapat menjadi komplemen yang berharga untuk sistem SIEM berbasis aturan, memungkinkan identifikasi anomali dan potensi ancaman yang mungkin tidak terdeteksi oleh pendekatan tradisional.

II.6.6 *Automating Security Incident Response in SCADA Systems via SIEM-ML Integration*

Al-Dahasi dan Khan (2024) menyajikan penelitian tentang integrasi teknik *machine learning* dengan SIEM untuk meningkatkan deteksi dan respons terhadap ancaman keamanan dalam sistem SCADA (*Supervisory Control and Data Acquisition*). Penelitian ini mengembangkan sistem SIEM berbasis analisis langsung menggunakan *machine learning* pada *Intrusion Detection System* (IDS).

Para peneliti menggunakan kombinasi Elastic (ELK) Stack, Slips (untuk analisis *machine learning*), dan Zeek IDS untuk membangun sistem mereka. Pendekatan ini memungkinkan analisis lalu lintas jaringan secara *real-time* dan mendeteksi anomali menggunakan teknik *machine learning*. Sistem ini juga dirancang untuk memberikan peringatan melalui *Telegram* dan email ketika deteksi anomali terjadi.

Hasil pengujian menunjukkan bahwa sistem yang diusulkan berhasil mendeteksi serangan DoS dalam jaringan, dengan Elasticsearch merupakan komponen yang paling banyak mengkonsumsi sumber daya CPU (78%) dan RAM (2300 Mb).

Pendekatan ini terbukti efektif dalam mendeteksi dan memonitoring serangan siber dalam lingkungan SCADA.

II.6.7 *SIEM Data Acquisition and Analysis with ML Principles*

Tendikov dkk. (2024) meneliti metode akuisisi dan analisis data SIEM menggunakan prinsip-prinsip *machine learning*. Penelitian ini berfokus pada pengembangan *robust network intrusion detection* menggunakan teknik *machine learning*. Para peneliti mengumpulkan data dari sistem SIEM yang menangkap statistik *real-time* dari mesin virtual Windows yang di-host di lingkungan *cloud*, dan menggabungkannya dengan *log* serangan web dari dataset CICIDS2017.

Studi ini mengevaluasi berbagai model klasifikasi dan *clustering*, termasuk *K-Nearest Neighbors (KNN), Support Vector Machine (SVM), Classification and Regression Trees (CART), Random Forest (RF), AdaBoost, Logistic Regression (LR), Naive Bayes (NB), Linear Discriminant Analysis (LDA), Quadratic Discriminant Analysis (QDA),* dan *Multilayer Perceptron (MLP).* Model-model ini dioptimalkan melalui *tuning hyperparameter* dan teknik seleksi fitur.

Hasil penelitian menunjukkan bahwa *Random Forest Classifier* (RFC) berkinerja paling baik, mencapai skor F1 0,97. Penelitian ini menyoroti pentingnya menggunakan dataset yang beragam dan teknik optimalisasi lanjutan untuk meningkatkan kemampuan deteksi intrusi jaringan.

Tabel II.2 Ringkasan Tinjauan Penelitian Terkait

Penelitian	**Fokus Utama**	**Metode/Teknologi**	**Hasil Utama**
Ban dkk. (2023)	Mengatasi *alert fatigue* dalam SIEM via SOAR	*Instance-weighted* SVM (IWSVM), algoritma korelasi *event*, *Augmented Tile Graph* (ATG)	Reduksi signifikan jumlah *alert* dan peningkatan efisiensi penanganan insiden
Aminanto dkk. (2019)	*Screening* otomatis *alert* Ancaman via IDS	Isolation Forest dengan pendekatan temporal pada data historis	Reduksi *alert* yang perlu diinvestigasi manual secara signifikan
Jangampeta (2022)	Survei penerapan AI/ML dalam SIEM	Ulasan komprehensif berbagai pendekatan ML untuk SIEM	Integrasi AI/ML ke SIEM meningkatkan deteksi ancaman proaktif dan adaptif
Bulgakova dkk. (2025)	Metode XAI dalam SIEM	LIME, SHAP, GradCAM, LRP	Integrasi XAI menghasilkan informasi insiden yang lebih detail dan menyederhanakan analisis
Goldstein dkk. (2013)	Deteksi anomali *unsupervised* dalam SIEM	k-NN global dan 5 algoritma unsupervised lainnya	Deteksi efektif terhadap kesalahan konfigurasi dan wawasan mendalam tentang aktivitas jaringan
Muhammad dkk. (2022)	Integrasi ML-SIEM untuk sistem SCADA	ELK Stack, Slips, Zeek IDS	Deteksi DoS efektif dengan catatan konsumsi sumber daya tinggi
Tendikov dkk. (2024)	Akuisisi dan analisis data SIEM dengan ML	KNN, SVM, CART, RF, AdaBoost, LR, NB, LDA, QDA, MLP	RFC berkinerja terbaik dengan skor F1 0,97

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

Sistem *Security Information and Event Management* (SIEM) memegang peranan penting dalam strategi pertahanan keamanan siber organisasi dengan menyediakan visibilitas terpusat terhadap aktivitas keamanan di seluruh infrastruktur. Dalam bagian ini, akan dianalisis arsitektur dan mekanisme kerja sistem SIEM Wazuh saat ini, serta diidentifikasi keterbatasan-keterbatasan yang dihadapi oleh sistem tersebut dalam konteks deteksi dan prioritisasi ancaman siber.

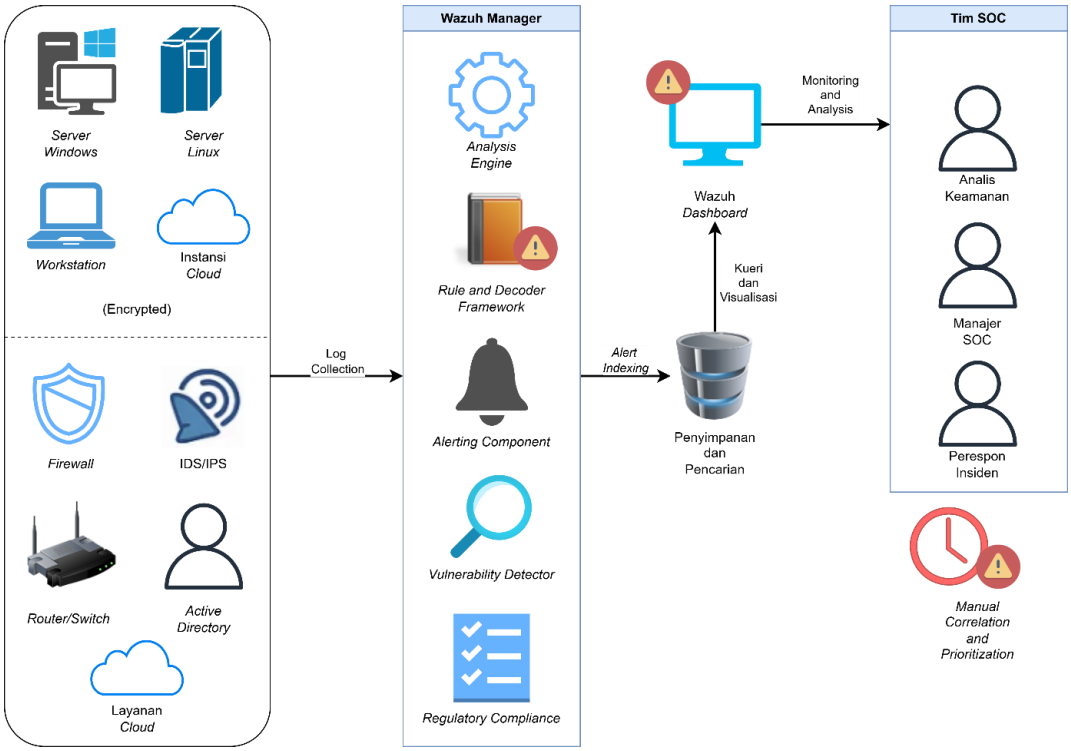

Gambar III.1 Skema Pengolahan Data SIEM pada Alur Kerja SOC

Arsitektur SIEM Wazuh yang diimplementasikan saat ini ditunjukkan pada Gambar III.1. Sistem ini terdiri dari beberapa komponen utama sebagai berikut.

Wazuh *Agents* dipasang pada berbagai *endpoint* seperti *server* Windows, Linux, atau Unix, *workstation*, perangkat jaringan, infrastruktur *cloud* (AWS, Azure, Google Cloud), dan *container* Docker atau Kubernetes. Agen ini mengumpulkan *log* sistem operasi, aplikasi, audit, perubahan *file*, dan informasi kerentanan, kemudian mengirimkan data ke Wazuh *Manager* melalui koneksi terenkripsi.

Sumber *Log* Eksternal meliputi perangkat keamanan jaringan (*firewall*, IDS/IPS, WAF), perangkat jaringan, aplikasi *cloud*, sistem identitas, dan *threat intelligence feeds*. Data dikumpulkan melalui Syslog, API, atau konektor khusus.

Wazuh *Manager* berfungsi sebagai komponen sentral dengan lima modul utama: *Analysis Engine* untuk deteksi berbasis aturan dengan lebih dari 3.000 aturan bawaan, *Rule and Decoder Framework* untuk interpretasi format *log*, *Alerting Component* untuk menghasilkan peringatan, *Vulnerability Detector* untuk identifikasi kerentanan, dan *Regulatory Compliance* untuk pemeriksaan standar PCI DSS, GDPR, dan HIPAA.

Wazuh *Dashboard* menyediakan antarmuka *web* untuk visualisasi *log* dan *alert*, pemantauan postur keamanan, manajemen agen dan aturan, manajemen kasus investigasi, serta pencarian dan *filtering alert*.

Tim SOC terdiri dari analis keamanan siber, manajer SOC, dan *responder* insiden yang bertanggung jawab memantau *alert*, menyelidiki insiden, dan merespons ancaman.

Implementasi Wazuh menghadapi lima keterbatasan utama: ketergantungan pada deteksi berbasis aturan statis yang kurang efektif untuk anomali kompleks dan serangan *zero-day*, *alert fatigue* akibat volume besar dan tingginya *false positive* yang menyebabkan sepertiga profesional IT mengabaikan peringatan, keterbatasan prioritisasi otomatis karena tidak ada mekanisme penilaian risiko dinamis, kemampuan korelasi *alert* terbatas yang mengharuskan analisis manual, dan

visualisasi konteks minimal yang mempersulit pemahaman keparahan dan dampak *alert*.

III.2 Analisis Kebutuhan

III.2.1 Identifikasi Masalah Pengguna

Berdasarkan evaluasi arsitektur Wazuh saat ini, ditemukan beberapa permasalahan yang dihadapi pengguna sistem SIEM dalam proses deteksi dan mitigasi ancaman siber. Wazuh sebagai *platform* SIEM *open-source* mengandalkan mesin pendeteksi berbasis aturan (*rule-based*) yang efektif untuk pola serangan yang sudah dikenal, namun pendekatan statis ini menimbulkan berbagai keterbatasan serius dalam menghadapi lanskap ancaman siber modern yang terus berevolusi. Keterbatasan-keterbatasan tersebut berdampak langsung pada efektivitas operasional tim keamanan dan kemampuan organisasi dalam merespons ancaman secara tepat waktu.

Identifikasi masalah pengguna dalam tugas akhir ini difokuskan pada tiga kategori utama pengguna sistem SIEM Wazuh: analis keamanan siber, manajer *Security Operations Center* (SOC), dan administrator sistem serta jaringan. Setiap kategori pengguna menghadapi tantangan spesifik yang berkaitan dengan keterbatasan sistem deteksi berbasis aturan statis dalam menangani kompleksitas ancaman siber kontemporer.

1. Analis Keamanan Siber (*Security Analyst*)

Analis keamanan siber bertanggung jawab untuk memeriksa, menganalisis, dan merespons *alert* keamanan yang dihasilkan oleh sistem SIEM. Mereka menghadapi permasalahan operasional yang signifikan akibat keterbatasan sistem deteksi berbasis aturan tradisional.

Analis keamanan mengalami *alert fatigue* yang parah akibat volume *alert* yang mencapai ribuan hingga jutaan per hari (Ban dkk. 2023). Kondisi ini disebabkan oleh sistem deteksi berbasis aturan yang menghasilkan tingkat *false positive* tinggi

karena ketidakmampuan mempertimbangkan konteks lingkungan spesifik organisasi. Penelitian menunjukkan bahwa hingga 70% waktu analis dihabiskan untuk menyaring *alert* yang tidak relevan, bukan untuk menyelidiki dan merespons ancaman nyata (Tendikov dkk. 2024). Fenomena ini menciptakan risiko keamanan serius dimana ancaman nyata dapat terlewatkan dalam lautan *alert* yang tidak signifikan.

Sistem Wazuh saat ini menghasilkan *alert* berdasarkan aturan statis yang tidak memperhitungkan perilaku normal pengguna atau konteks operasional khusus organisasi. Analis menghadapi kesulitan signifikan dalam membedakan antara *alert* yang mengindikasikan ancaman serius dengan aktivitas normal yang memicu *false positive*. Tidak adanya mekanisme otomatis untuk mengkorelasikan *alert* terkait dan menyediakan konteks keparahan menyulitkan analis untuk memahami gambaran besar dari sebuah serangan multi-tahap. Kondisi ini mengharuskan investigasi manual tambahan untuk menentukan signifikansi suatu *alert*, yang menghabiskan waktu dan sumber daya berharga dalam lingkungan SOC yang beroperasi nonstop (Coralogix, 2024).

Mesin pendeteksi berbasis aturan Wazuh memiliki keterbatasan dalam mendeteksi pola anomali yang tidak sesuai dengan *signatures* yang telah didefinisikan sebelumnya. Analis mengalami kesulitan mengidentifikasi aktivitas mencurigakan yang menggunakan teknik *living off the land* atau serangan yang memanfaatkan perangkat legal untuk melakukan serangan. Keterbatasan ini sangat relevan dalam konteks ancaman modern dimana penyerang semakin menggunakan teknik yang beroperasi dalam batas normal sistem untuk menghindari deteksi tradisional.

2. Manajer *Security Operations Center* (SOC)

Manajer SOC bertanggung jawab untuk mengawasi operasi keamanan dan memastikan efektivitas tim dalam mendeteksi serta merespons ancaman. Mereka menghadapi tantangan strategis dalam mengelola sumber daya dan mengoptimalkan performa operasional SOC.

Manajer SOC menghadapi kesulitan dalam menentukan alokasi analis berdasarkan prioritas risiko yang akurat karena tidak adanya mekanisme penilaian dinamis untuk alert. Sistem prioritisasi statis tidak mempertimbangkan faktor-faktor seperti kritikalitas aset, tingkat *exposure*, atau konteks temporal yang dapat mempengaruhi urgensi respons. Miranda (2024) menyoroti bahwa banyak organisasi menghadapi kesulitan dalam merekrut dan mempertahankan profesional keamanan siber yang terampil, sehingga optimalisasi alokasi sumber daya yang terbatas menjadi aspek krusial dalam operasi SOC yang efektif.

Dashboard Wazuh tradisional menyediakan visualisasi *alert* individual namun tidak memberikan wawasan analitis mendalam tentang tren ancaman jangka panjang atau evolusi pola serangan. Manajer SOC kesulitan mendapatkan gambaran menyeluruh tentang postur keamanan organisasi tanpa kemampuan analisis data yang lebih canggih. Keterbatasan ini menghambat pengambilan keputusan strategis dan perencanaan pertahanan proaktif karena tidak tersedianya informasi tambahan tentang perubahan pola ancaman dari waktu ke waktu (Coralogix, 2024).

Proses triase dan eskalasi *alert* masih memerlukan intervensi manual yang signifikan, memperlambat waktu respons rata-rata terhadap insiden keamanan. Tidak adanya mekanisme otomasi untuk menangani ancaman dengan pola yang sudah dikenal meningkatkan beban kerja tim dan mengurangi efisiensi operasional. Muhammad, Sukarno, dan Wardana (2022) menekankan pentingnya respons otomatis dalam meminimalkan *mean time to detection* (MTTD) dan *mean time to response* (MTTR) untuk mengurangi dampak potensial serangan terhadap aset kritikal organisasi.

3. Administrator Sistem dan Jaringan

Administrator bertanggung jawab untuk mengelola dan memelihara infrastruktur SIEM serta memastikan operasional sistem yang optimal. Mereka menghadapi tantangan teknis dalam implementasi dan perawatan sistem yang semakin kompleks.

Administrator menghadapi kurva pembelajaran yang curam dalam mengonfigurasi Wazuh untuk lingkungan dengan persyaratan keamanan spesifik. Pemeliharaan dan pembaruan aturan deteksi memerlukan upaya manual yang intensif, terutama dalam menyesuaikan dengan perubahan infrastruktur atau munculnya ancaman baru. Kurangnya panduan berbasis data untuk mengoptimalkan konfigurasi sistem berdasarkan karakteristik lingkungan spesifik menambah kompleksitas tugas administratif dan meningkatkan risiko kesalahan konfigurasi sistem.

Integrasi Wazuh dengan sistem keamanan khusus atau aplikasi *proprietary* sering memerlukan pengembangan konektor kustom yang kompleks. Administrator mengalami kesulitan mengintegrasikan data kontekstual dari berbagai sumber untuk memperkaya analisis keamanan, seperti *threat intelligence feeds*, *vulnerability scanners*, atau sistem manajemen aset. Keterbatasan ini menghambat terciptanya sistem orkestrasi keamanan yang efektif dan mengurangi nilai analitis dari data yang dikumpulkan.

Implementasi Wazuh yang efektif memerlukan perencanaan sumber daya komputasi yang cermat, terutama untuk lingkungan dengan volume data besar dan persyaratan *real-time processing*. Administrator menghadapi tantangan dalam mempertahankan performa sistem yang konsisten seiring dengan peningkatan volume data dan kompleksitas aturan deteksi. Keterbatasan ini dapat mempengaruhi kemampuan sistem untuk memproses dan menganalisis event secara tepat waktu, yang berpotensi mengurangi efektivitas deteksi ancaman.

Masalah-masalah yang diidentifikasi di atas memiliki korelasi langsung dengan isu-isu keamanan yang telah didefinisikan berdasarkan framework MITRE ATT&CK. Keterbatasan sistem berbasis aturan dalam mendeteksi pola temporal, anomali jaringan, *attack chain correlations*, dan perubahan konfigurasi mencerminkan celah fundamental dalam menghadapi pola serangan yang kompleks yang digunakan aktor penyerang modern.

Isu temporal dan pola waktu yang tidak biasa, seperti aktivitas di luar jam kerja (*off-hours activities*), sulit dideteksi secara efektif oleh sistem berbasis aturan karena

membutuhkan pembentukan *baseline behavior* yang bersifat dinamis dan adaptif. Sistem statis tidak mampu membedakan antara aktivitas sah di luar jam kerja dengan potensi kompromi tanpa adanya pemahaman kontekstual terhadap pola normal dalam organisasi.

Anomali jaringan dan geografis juga menuntut analisis korelasi yang kompleks, melampaui kemampuan pencocokan sederhana berbasis aturan. Deteksi alamat IP yang pertama kali muncul (*first-seen IP addresses*), koneksi geografis yang tidak biasa, maupun kombinasi protokol langka membutuhkan analisis historis dan pengenalan pola yang tidak dapat dicapai melalui pendekatan aturan tradisional.

Selain itu, pengenalan pola dalam rantai serangan (*attack chains*) menghadapi keterbatasan fundamental dalam sistem berbasis aturan yang cenderung mengevaluasi peristiwa secara individual alih-alih dalam urutan. Serangan bertahap (*multi-stage attacks*) yang memanfaatkan alat sah serta rentang waktu yang panjang untuk menghindari deteksi tidak dapat diidentifikasi tanpa adanya kapabilitas korelasi komprehensif yang mempertimbangkan hubungan temporal serta kombinasi teknik yang digunakan.

Log data yang dihasilkan oleh sistem SIEM Wazuh memiliki karakteristik yang mendukung pengembangan solusi untuk mengatasi masalah-masalah yang diidentifikasi. Justifikasi ini didasarkan pada struktur, volume, dan kekayaan informasi dari data *log* Wazuh.

Log Wazuh menyediakan data yang terstruktur dengan kolom informasi yang konsisten dan telah dinormalisasi, memungkinkan proses analisa yang sistematis dari kejadian keamanan. *Coverage* data mencakup berbagai dimensi yang relevan untuk proses analisa *behavioral*, termasuk informasi temporal (*timestamps* dengan granularitas tinggi), indikator jaringan (*source/destination IPs, ports, protocols*), konteks geografis (Kolom Geolokasi), informasi proses, dan dana pengawasan integritas *file*. Kolom berkardinalitas tinggi seperti nama agen, alamat IP, akun pengguna, dan deskripsi aturan yang terpanggil menyediakan variasi pola yang cukup untuk melakukan analisis secara mendalam.

Volume data yang dihasilkan Wazuh dalam lingkungan *enterprise* dapat mencapai ribuan hingga jutaan *events* per hari, sehingga menyediakan dataset yang memadai untuk analisis statistik dan pengenalan pola. Tingkat granularitas temporal yang cukup halus (*fine-grained*) memungkinkan dilakukannya analisis terhadap perilaku berurutan (*sequential behaviors*) serta deteksi anomali waktu yang sering kali menjadi indikator serangan canggih. Retensi data historis juga mendukung pembentukan *baseline* perilaku normal serta identifikasi penyimpangan signifikan dari pola tersebut.

Dari sisi *enrichment* dan informasi kontekstual, *logs* Wazuh telah diperkaya dengan data seperti pemetaan teknik MITRE ATT&CK, tingkat keparahan (*severity levels*), dan deskripsi aturan, yang menyediakan konteks semantik penting bagi setiap *security event*. Informasi terkait agen, termasuk detail sistem operasi, lokasi geografis, dan unit organisasi, turut memberikan konteks berharga dalam memahami perbedaan antara perilaku normal dan anomali dalam lingkungan spesifik.

Selain itu, kemampuan *stream processing* dari *log* Wazuh memungkinkan pengembangan analisis secara *real-time*, sehingga mendukung deteksi tepat waktu dan rekomendasi respons yang cepat. Integrasi dengan infrastruktur Wazuh yang telah ada menjadikan implementasi solusi lebih mulus tanpa mengganggu alur kerja operasional, sekaligus menghadirkan kapabilitas deteksi yang lebih canggih.

Dengan kombinasi karakteristik data yang kaya, terstruktur, dan *real-time*, serta volume yang memadai, Wazuh menyediakan fondasi optimal bagi pengembangan kapabilitas deteksi lanjutan. Solusi yang dikembangkan dapat memanfaatkan kekayaan data ini untuk menghadirkan mekanisme deteksi yang adaptif, kontekstual, dan terukur, sehingga secara signifikan meningkatkan efektivitas operasional SOC serta memperkuat *security posture* organisasi.

III.2.2 Kebutuhan Fungsional

Kebutuhan fungsional sebagaimana tertulis pada tabel III.1 menjelaskan fungsi-fungsi spesifik yang harus disediakan oleh sistem untuk mengatasi masalah yang diidentifikasi pada Bagian III.2.1.

Tabel III.1 Identifikasi Kebutuhan Fungsional Sistem

Kode	**Deskripsi Kebutuhan**
FR-01	Sistem harus dapat mengurangi volume *alert* melalui mekanisme filtering dan prioritisasi
FR-02	Sistem harus dapat memberikan skor prioritas untuk setiap *alert* berdasarkan tingkat risiko dan keparahan
FR-03	Sistem harus menyediakan informasi kontekstual yang memadai untuk mendukung proses investigasi analis
FR-04	Sistem harus dapat mengkorelasikan *alert* terkait untuk memberikan gambaran serangan yang komprehensif
FR-05	Sistem harus dapat terintegrasi dengan infrastruktur Wazuh saat ini tanpa mengganggu operasional yang ada

III.2.3 Kebutuhan Nonfungsional

Kebutuhan nonfungsional pada tabel III.2 menentukan kriteria kualitas sistem yang harus dipenuhi agar solusi dapat beroperasi secara efektif dalam lingkungan produksi SOC.

Kebutuhan-kebutuhan pada tabel III.2 dirancang untuk memastikan bahwa sistem yang dikembangkan tidak hanya mampu mengatasi masalah *alert fatigue* dan meningkatkan efektivitas deteksi ancaman, tetapi juga dapat dioperasikan secara efisien dalam lingkungan SOC yang sesungguhnya. Kebutuhan fungsional berfokus pada kemampuan inti sistem dalam mengurangi beban kerja analis dan meningkatkan kualitas investigasi, sedangkan kebutuhan nonfungsional memastikan sistem dapat beroperasi dalam standar performa yang diperlukan untuk lingkungan produksi.

Tabel III.2 Identifikasi Kebutuhan Nonfungsional Sistem

Kode	Deskripsi Kebutuhan
NF-01	Efektivitas: Sistem harus mencapai pengurangan *false positive* minimal 50% dari kondisi awal pada kondisi *budgeted triage*
NF-02	Kecepatan: Sistem harus dapat memproses dan memberikan hasil analisis alert dalam waktu maksimal 1 menit
NF-03	Skalabilitas: Sistem harus mampu memproses minimal 10.000 *alert* per hari tanpa penurunan performa signifikan
NF-04	Reliabilitas: Sistem harus memiliki uptime minimal 99.5% dan tidak mengganggu operasional SIEM saat ini
NF-05	Kompatibilitas: Sistem harus dapat berjalan pada lingkungan yang kompatibel dengan infrastruktur Wazuh (*Linux-based*)

III.3 Analisis Pemilihan Solusi

III.3.1 Alternatif Solusi

Berdasarkan analisis masalah pengguna dan kebutuhan sistem yang telah diidentifikasi, dikembangkan lima alternatif solusi yang dapat mengatasi permasalahan *alert fatigue*, prioritisasi *alert*, dan optimalisasi operasional SOC pada sistem SIEM Wazuh. Setiap alternatif memiliki pendekatan yang berbeda dalam menangani keterbatasan sistem berbasis aturan dan menyediakan kemampuan deteksi serta analisis yang lebih efektif.

Alternatif A: Peningkatan Sumber Daya Manusia dan Proses Manual

Pendekatan ini fokus pada peningkatan kapasitas tim SOC melalui penambahan analis keamanan, pelatihan lanjutan, dan optimalisasi proses manual untuk menangani volume *alert* yang tinggi.

Implementasi melibatkan perekrutan analis keamanan tambahan dengan spesialisasi dalam *threat hunting* dan *incident response*, pengembangan program pelatihan berkelanjutan untuk meningkatkan skill pengenalan pola serangan dan investigasi manual, standardisasi prosedur operasional untuk proses triase dan

prioritisasi *alert* berdasarkan checklist dan *decision tree* yang komprehensif, serta penyusunan jadwal kerja bergilir selama 24/7 dengan *redundancy* untuk memastikan pengawasan yang terus-menerus.

Pendekatan manual memungkinkan fleksibilitas tinggi dalam menangani kasus-kasus *edge case* dan skenario ancaman yang kompleks yang mungkin tidak tertangkap oleh sistem otomatis. Keahlian manusia dalam pemahaman kontekstual dan pengetahuan domain dapat memberikan informasi yang berharga untuk investigasi yang memerlukan pemikiran kreatif dan analisis. Implementasi relatif mudah tanpa memerlukan perubahan teknis yang sangat signifikan terhadap infrastruktur yang ada saat ini.

Namun, pendekatan ini memiliki keterbatasan dalam hal skalabilitas karena kapasitas pemrosesan manusia secara inheren terbatas. Biaya operasional menjadi sangat tinggi akibat kebutuhan untuk mempertahankan tim besar dengan ketersediaan nonstop. Selain itu, kelangkaan tenaga kerja terampil di bidang keamanan siber secara global menimbulkan tantangan dalam merekrut personel yang berkualifikasi, sementara tingkat perputaran tenaga kerja yang tinggi di industri ini semakin menambah kompleksitas dalam menjaga konsistensi kapabilitas tim.

Alternatif B: Optimalisasi Sistem Berbasis Aturan (Rule-Based Enhancement)

Pendekatan ini berupaya meningkatkan efektivitas sistem SIEM yang telah ada melalui proses *fine-tuning* aturan deteksi, penyesuaian ambang batas (*threshold adjustment*), serta penguatan aturan korelasi tanpa memanfaatkan sistem analitis. Implementasi dilakukan dengan melibatkan audit komprehensif dan penyesuaian aturan Wazuh yang sudah ada untuk mengurangi jumlah *false positives* melalui kustomisasi sesuai lingkungan, pengembangan pola perilaku normal (*baseline normal behavior patterns*) berdasarkan analisis historis untuk setiap agen maupun pengguna, perancangan aturan korelasi lanjutan yang mampu mengidentifikasi pola serangan bertahap (*multi-stage attack patterns*) dengan merujuk pada kerangka kerja MITRE ATT&CK, serta penerapan sistem penilaian statis (*static scoring*

system) yang didasarkan pada bobot terdefinisi untuk aspek kritikalitas aset, tingkat keparahan ancaman, dan faktor berbasis waktu.

Pendekatan berbasis aturan ini memiliki keunggulan dalam hal prediktabilitas dan sifat deterministik yang memudahkan proses *troubleshooting* maupun validasi. Kompleksitas implementasinya relatif rendah karena masih berada dalam paradigma sistem yang ada tanpa memerlukan perubahan arsitektural yang signifikan. Selain itu, proses pemeliharaan dapat dijalankan oleh tim keamanan yang sudah tersedia tanpa memerlukan keahlian khusus dalam *advanced analytics* atau *machine learning*.

Namun pada lingkungan kerja yang terus berkembang, pendekatan ini cepat menghadapi hambatan skalabilitas, khususnya untuk prioritisasi dan deteksi pola perilaku. Misalnya, dalam 12 bulan organisasi menambah lima unit bisnis baru, memigrasikan layanan internal ke Kubernetes, serta mengadopsi beberapa SaaS inti seperti Microsoft 365, GitHub, dan Slack. Tenaga kerja menjadi *hybrid* lintas zona waktu, perangkat bersifat *ephemeral*, dan sumber log bertambah dari EDR, WAF, hingga identitas *cloud* (Azure AD atau Okta). Untuk memantau perilaku seperti *login* di luar jam kerja, *reset* kata sandi *admin* yang tidak biasa, atau rantai proses aneh pada *host* tertentu, aturan perlu "dipecah" menurut kombinasi peran pengguna, kelompok agen, zona waktu, sumber jaringan, dan status perangkat. Variasi kombinasi ini membuat jumlah aturan tumbuh sangat cepat. Sebagai ilustrasi, hanya untuk kasus *login* saja, jika terdapat 600 pengguna, 6 *bucket* waktu, 8 kombinasi geolokasi, dan 5 tipe sumber perangkat, maka ruang kondisi mencapai 600 × 6 × 8 × 5 atau 144.000 kombinasi yang harus dicakup oleh aturan atau pengecualian. Setiap pengecualian operasional seperti jadwal *maintenance*, IP sementara untuk *pod*, atau pola kerja musiman akan menambah aturan turunan, memicu *rule sprawl* yang menumpuk dan saling tumpang-tindih. Dampaknya, prioritisasi menjadi tidak konsisten karena skor statis tidak mengikuti *drift* perilaku harian atau musiman, sementara pengujian *regression testing* atas perubahan satu aturan dapat berimbas ke ratusan aturan korelasi lain sehingga *overhead* verifikasi meningkat pesat. Pada titik ini, siklus hidup aturan bergeser dari "mudah ditambah" menjadi "sulit

dikelola", dan kompleksitasnya tumbuh nyaris eksponensial seiring bertambahnya entitas, sumber log, serta skenario perilaku yang harus ditangani.

Meski penambahan aturan mudah dan mulus ke lingkungan SIEM, rekayasa aturan yang efektif adalah proses yang riset-intensif. Petugas perlu mengidentifikasi pola serangan, merumuskan sinyal yang dapat diamati, menyusun logika deteksi, dan mereplikasi serangan secara aman untuk validasi, yang semuanya menuntut keahlian tinggi. Di sisi lain, sifatnya yang statis memerlukan pembaruan manual berkelanjutan dan berisiko *rule sprawl* (tumpang tindih atau konflik aturan), sehingga kompleksitas dan kebutuhan *regression testing* terus meningkat.

Alternatif C: Implementasi SOAR (*Security Orchestration, Automation, and Response*)

Platform SOAR (*Security Orchestration, Automation, and Response*) mengintegrasikan kapabilitas untuk mengotomatisasi alur kerja, mengorkestrasi berbagai *security tools*, serta menyederhanakan proses *incident response* guna mengurangi beban kerja manual dan meningkatkan efisiensi respons.

Implementasi melibatkan penerapan platform SOAR yang terintegrasi dengan Wazuh serta berbagai perangkat keamanan lain dalam lingkungan organisasi. Selain itu, dilakukan pengembangan *automated playbooks* untuk jenis insiden umum seperti deteksi malware, *brute force attacks*, dan upaya *data exfiltration*. Mekanisme agregasi dan korelasi peringatan yang cerdas (*intelligent alert aggregation and correlation*) juga diimplementasikan untuk mengurangi duplikasi peringatan serta menyediakan pengelompokan kontekstual. Lebih lanjut, ditetapkan pula tindakan respons otomatis untuk *containment* dan remediasi awal.

Platform SOAR menawarkan peningkatan signifikan dalam efisiensi operasional melalui otomatisasi tugas-tugas berulang dan standardisasi prosedur respons. Kemampuan integrasi yang dimilikinya memungkinkan orkestrasi terpusat atas berbagai *security tools*, sehingga menyediakan pandangan terpadu serta koordinasi respons yang lebih baik. Skalabilitas dalam menangani volume insiden yang tinggi

melalui alur kerja otomatis juga dapat secara substansial mengurangi *mean time to response* (MTTR).

Meskipun demikian, terdapat sejumlah keterbatasan. Investasi awal yang besar diperlukan untuk lisensi platform dan biaya implementasi. Kompleksitas dalam pengembangan serta pemeliharaan *automated playbooks* menuntut keahlian khusus dan usaha berkelanjutan. Ketergantungan pada pengambilan keputusan otomatis juga berpotensi menimbulkan risiko apabila *playbooks* tidak dirancang atau diuji dengan tepat. Selain itu, efektivitas SOAR terbatas dalam menghadapi ancaman baru yang tidak tercakup oleh *playbooks* yang telah ditentukan sebelumnya.

Alternatif D: Sistem Deteksi Anomali Berbasis *Advanced Analytics*

Sistem ini mengintegrasikan teknik *advanced analytics* untuk mendeteksi anomali perilaku, melakukan pengenalan pola, serta menyusun prioritisasi insiden secara cerdas berdasarkan analisis statistik dan pendekatan berbasis data.

Implementasi mencakup pengembangan sistem deteksi anomali yang mampu mengidentifikasi pola tidak lazim dalam dimensi temporal, jaringan, dan perilaku. Selain itu, sistem dilengkapi dengan mekanisme penilaian cerdas (*intelligent scoring mechanisms*) yang mempertimbangkan berbagai faktor seperti kelangkaan, tingkat keparahan, dan informasi kontekstual. Kapabilitas analisis historis turut diintegrasikan untuk mendukung identifikasi tren dan pengenalan pola, sementara *adaptive baselines* dikembangkan agar dapat berevolusi mengikuti perubahan lingkungan maupun lanskap ancaman.

Pendekatan *advanced analytics* memiliki keunggulan dalam mendeteksi ancaman yang sebelumnya tidak dikenal, termasuk *zero-day attacks*, yang tidak dapat diidentifikasi melalui pendekatan berbasis tanda tangan (*signature-based*). Sifat adaptif memungkinkan sistem untuk terus meningkatkan kinerjanya seiring dengan masuknya data baru dan perubahan pola ancaman. Skalabilitasnya mendukung pemrosesan volume data yang sangat besar dengan kinerja yang konsisten, sekaligus memberikan wawasan penjelasan (*explanatory insights*) yang dapat membantu analis dalam proses investigasi.

Namun demikian, terdapat sejumlah tantangan. Kompleksitas implementasi menuntut keahlian khusus dalam analitik dan pemodelan statistik. Fase pengembangan membutuhkan investasi waktu yang signifikan untuk pelatihan dan validasi model secara tepat. Pada fase awal penerapan, potensi *false positives* relatif tinggi sehingga diperlukan *tuning* dan validasi yang cermat. Selain itu, performa optimal sistem sangat bergantung pada kualitas dan kelengkapan data pelatihan yang tersedia.

Alternatif E: Adopsi Platform SIEM komersil berbasis AI

Solusi ini melibatkan migrasi ke platform SIEM komersial yang telah mengintegrasikan kapabilitas *artificial intelligence* dan *machine learning* sebagai fitur bawaan.

Implementasi mencakup evaluasi dan pemilihan platform SIEM komersial dengan kemampual AI/ML yang telah terbukti, seperti Splunk Enterprise Security, Microsoft Sentinel, atau CrowdStrike Falcon Next-Gen SIEM. Tahapan implementasi meliputi perencanaan migrasi data dan konfigurasi dari infrastruktur Wazuh yang sudah ada, integrasi dengan *security tools* dan *workflow* saat ini, serta pelatihan tim keamanan untuk menguasai kapabilitas dan antarmuka baru.

Platform komersial menawarkan solusi yang matang dengan rekam jejak yang teruji di lingkungan perusahaan berskala besar. Fitur AI/ML bawaan memungkinkan organisasi memperoleh akses langsung ke *advanced analytics* tanpa perlu melakukan pengembangan internal. Dukungan vendor yang komprehensif, disertai dokumentasi resmi, memfasilitasi implementasi serta operasi berkelanjutan. Selain itu, pembaruan rutin dari vendor memastikan sistem tetap selaras dengan ancaman dan teknologi terbaru.

Namun demikian, keterbatasan utama dari pendekatan ini mencakup biaya lisensi yang sangat besar, yang dapat berkisar dari ratusan ribu hingga jutaan dolar setiap tahun. Sifat *closed-architecture* dari platform komersial menciptakan keterbatasan transparansi: organisasi tidak dapat sepenuhnya mengetahui bagaimana model AI/ML internal bekerja, bagaimana inferensi dilakukan, serta bagaimana sistem

mengambil keputusan. Hal ini berarti *fine-tuning* atau penyesuaian sistem sesuai kebutuhan organisasi hanya dapat dilakukan sejauh vendor mengizinkan. Konsekuensinya, organisasi menjadi sangat bergantung pada *vendor lock-in* dan terikat dengan peta jalan (*roadmap*) maupun keputusan strategis vendor. Selain itu, kompleksitas migrasi berpotensi menimbulkan gangguan selama fase transisi, sementara keterbatasan fleksibilitas kustomisasi dapat menyulitkan adaptasi untuk kebutuhan unik organisasi, termasuk potensi hilangnya investasi yang sudah ditanamkan dalam infrastruktur Wazuh yang ada.

Kelima alternatif solusi ini secara keseluruhan mencerminkan spektrum pendekatan yang berbeda untuk meningkatkan efisiensi operasional SIEM, mulai dari penguatan metode konvensional hingga adopsi teknologi mutakhir. Masing-masing alternatif membawa keunggulan dan keterbatasan tersendiri dalam hal biaya, kompleksitas, efektivitas, serta keberlanjutan jangka panjang, yang harus dievaluasi untuk menentukan solusi yang paling optimal.

III.3.2 Analisis Penentuan Solusi

Untuk menentukan solusi optimal dari lima alternatif yang telah diidentifikasi, digunakan metode *Analytical Hierarchy Process* (AHP) yang dikembangkan oleh Thomas Saaty. Metode AHP dipilih karena kemampuannya dalam menangani pengambilan keputusan multi-kriteria yang kompleks dengan pendekatan sistematis dan terukur. Berdasarkan analisis kebutuhan fungsional dan non-fungsional yang telah ditetapkan, tujuh kriteria evaluasi dikembangkan untuk menilai efektivitas setiap alternatif solusi.

Setiap alternatif dievaluasi berdasarkan kriteria yang telah ditetapkan pada tabel III.3 menggunakan skala penilaian 1 hingga 5, di mana nilai 5 merepresentasikan performa terbaik. Proses penilaian ini didasarkan pada kajian literatur, analisis empiris, serta praktik terbaik (*best practices*) dalam implementasi SIEM.

Tabel III.3 Kriteria Evaluasi dan Pembobotan AHP

Kode	**Kriteria**	**Bobot**	**Justifikasi Pembobotan**
K1	Efektivitas Reduksi *Alert Fatigue*	0,25	Menjadi kriteria utama karena secara langsung menjawab masalah primer.
K2	Kemampuan Kontekstualisasi dan Prioritisasi	0,20	Esensial dalam memenuhi kebutuhan dalam aspek penilaian *alert* dan penyediaan informasi kontekstual.
K3	Kompleksitas Implementasi	0,15	Menentukan kelayakan praktis serta mempengaruhi estimasi waktu dan sumber daya dalam proses implementasi.
K4	Biaya dan *Sustainability*	0,15	Pertimbangan ekonomis jangka panjang yang terkait dengan keberlangsungan operasional dan *viability*.
K5	Skalabilitas dan *Performance*	0,10	Relevan dengan NF02 dan NF03 yang menekankan kecepatan pemrosesan serta kemampuan menangani volume data besar.
K6	Integrasi dengan Wazuh	0,10	Penting untuk memastikan kesesuaian dengan FR06 dan NF04 terkait aspek kompatibilitas dan reliabilitas.
K7	Efektivitas Korelasi dan *Feedback*	0,05	Mendukung FR04 dan FR05 dalam hal kemampuan korelasi lanjutan dan mekanisme perbaikan berkelanjutan.
Total		**1,00**	

Tabel III.4 Matriks Penilaian Alternatif Solusi

Kriteria	**Bobot**	**Alternatif Solusi**				
		A	**B**	**C**	**D**	**E**
K1: Efektivitas Reduksi Alert Fatigue	0,25	2	3	4	5	4
K2: Kemampuan Kontekstualisasi	0,20	3	2	3	5	4
K3: Kompleksitas Implementasi	0,15	5	3	3	2	3
K4: Biaya dan Sustainability	0,15	2	4	2	4	2
K5: Skalabilitas dan Performance	0,10	2	3	4	5	5
K6: Integrasi dengan Wazuh	0,10	5	5	3	4	1
K7: Efektivitas Korelasi dan Feedback	0,05	2	2	4	5	4

Alternatif A (Peningkatan SDM) menunjukkan performa yang lemah pada sebagian besar kriteria kritis. Efektivitas dalam mengurangi *alert fatigue* hanya memperoleh skor 2, karena pendekatan manual tidak secara fundamental menyelesaikan permasalahan volume data, melainkan hanya menambah kapasitas pemrosesan. Kemampuan kontekstualisasi memperoleh skor 3 berkat keunggulan analisis berbasis keahlian manusia, namun aspek skalabilitas sangat terbatas dengan skor 2 akibat keterbatasan inheren dalam kapasitas pemrosesan manusia. Dari sisi biaya dan keberlanjutan, alternatif ini juga dinilai lemah dengan skor 2, mengingat tingginya biaya operasional untuk mempertahankan tim besar dengan ketersediaan.

Alternatif B (*Rule Enhancement*) memperlihatkan performa moderat dengan fokus pada optimalisasi infrastruktur yang sudah ada. Efektivitas reduksi *alert fatigue* mendapat skor 3, didasarkan pada potensi pengurangan *false positives* sebesar 50–70% melalui *rule tuning*, sebagaimana dilaporkan dalam berbagai studi industri. Kompleksitas implementasi relatif cukup baik dengan skor 3, karena masih berada dalam paradigma sistem yang ada. Namun, kemampuan kontekstualisasi dan korelasi tetap terbatas, hanya memperoleh skor 2, akibat sifat statis pendekatan berbasis aturan.

Alternatif C (*SOAR Platform*) menunjukkan performa yang lebih seimbang dengan penekanan pada otomatisasi alur kerja. Efektivitas reduksi *alert fatigue* memperoleh skor 4, didukung oleh laporan pengurangan waktu respons dan beban pemrosesan peringatan melalui otomatisasi. Kemampuan korelasi dinilai cukup kuat dengan skor 3 berkat kapabilitas orkestrasi yang canggih. Namun, biaya dan keberlanjutan hanya mendapat skor 3 karena kebutuhan investasi signifikan, yaitu sekitar USD 200.000–500.000 per tahun. Integrasi dengan Wazuh juga masih terbatas, memperoleh skor 3 karena memerlukan pengembangan kustom.

Alternatif D (*Advanced Analytics*) menawarkan performa superior pada kriteria utama. Efektivitas reduksi *alert fatigue* memperoleh skor maksimal 5, berdasarkan temuan riset yang menunjukkan pengurangan peringatan sebesar 45–91% melalui *intelligent filtering* dan deteksi berbasis anomali. Kemampuan kontekstualisasi juga mendapat skor 5, karena kemampuan pengenalan pola yang canggih dapat memberikan wawasan kontekstual yang lebih kaya dibandingkan pendekatan tradisional. Skalabilitas memperoleh skor 5 berkat efisiensi komputasional dalam menghadapi pertumbuhan data. Namun, kompleksitas implementasi relatif tinggi, hanya memperoleh skor 2, mengingat kebutuhan keahlian khusus dan upaya pengembangan yang substansial.

Alternatif E (*Commercial SIEM*) menunjukkan performa teknis yang sangat kuat, namun dibatasi oleh faktor biaya dan arsitektural. Efektivitas reduksi *alert fatigue* serta kemampuan kontekstualisasi masing-masing memperoleh skor 4, didukung oleh bukti empiris mengenai kapabilitas teruji pada berbagai platform komersial. Skalabilitas mencapai skor maksimal 5, karena rancangan arsitektur *enterprise-grade* mendukung pemrosesan volume data yang sangat besar dengan kinerja konsisten. Namun demikian, biaya dan keberlanjutan memperoleh skor rendah 2, karena biaya lisensi tahunan yang sangat tinggi (USD 150.000 hingga lebih dari 1 juta). Integrasi dengan Wazuh juga mendapat skor 1, akibat sifat arsitektur yang tertutup (*closed architecture*), sehingga menimbulkan keterbatasan dalam fleksibilitas, kompatibilitas, serta sering menuntut migrasi penuh yang disruptif.

Tabel III.5 Hasil Perhitungan Skor AHP

Alternatif	**Skor Akhir**	**Ranking**
Alternatif A (SDM)	2,95	5
Alternatif B (*Rules*)	3,10	4
Alternatif C (SOAR)	3,25	3
Alternatif D (*Analytics*)	4,30	1
Alternatif E (*Commercial*)	3,35	2

Berdasarkan Tabel III.5, alternatif D (*Advanced Analytics*) muncul sebagai solusi yang paling optimal dengan skor tertimbang sebesar 4,30, menunjukkan kinerja superior pada kriteria dengan bobot tertinggi. Keunggulan utama terletak pada kapabilitas yang sangat efektif dalam mengurangi *alert fatigue* (K1; bobot 25%) dan penyediaan wawasan kontekstual (K2; bobot 20%), yang secara kombinasi merepresentasikan 45% dari total bobot evaluasi.

Meskipun Alternatif D memperoleh skor rendah (2) pada aspek kompleksitas implementasi, keterbatasan ini dapat dimitigasi melalui pendekatan implementasi bertahap (*phased implementation*). Tahap awal dapat dimulai dengan *proof-of-concept* menggunakan himpunan data terbatas untuk validasi, sebelum dilakukan penerapan penuh. Strategi mitigasi risiko meliputi penyusunan dokumentasi yang komprehensif, program pelatihan tim, serta penyediaan mekanisme *fallback* ke sistem berbasis aturan yang sudah ada selama periode transisi.

Alternatif C (SOAR *Platform*) menempati posisi kedua dengan skor 3,50, menunjukkan kinerja kuat dalam otomasi dan optimalisasi alur kerja. Namun demikian, keterbatasannya dalam menangani ancaman baru (*novel threats*) serta biaya berkelanjutan yang substansial menjadi faktor pembatas utama.

Alternatif E (Commercial SIEM) memperoleh skor 3,35, menegaskan keunggulan teknis dalam hal performa dan skalabilitas. Namun, hambatan praktis berupa biaya lisensi yang sangat tinggi serta potensi gangguan signifikan terhadap infrastruktur

eksisting membuat alternatif ini kurang sesuai untuk konteks tugas akhir, yang berfokus pada peningkatan sistem Wazuh yang telah ada.

Berdasarkan hasil evaluasi, rekomendasi akhir adalah implementasi Alternatif D (*Advanced Analytics*) dengan pendekatan bertahap. Proses dimulai dengan penerapan percontohan (*pilot deployment*) pada *use cases* spesifik yang telah diidentifikasi melalui analisis MITRE ATT&CK, kemudian dilanjutkan dengan ekspansi bertahap berdasarkan hasil validasi dan pengalaman operasional. Pendekatan ini menyeimbangkan potensi inovasi dengan pertimbangan praktis implementasi, sehingga diyakini mampu memberikan solusi optimal dalam menjawab tantangan operasional SIEM yang telah diidentifikasi.

Sebagai penguat justifikasi, solusi berbasis *machine learning* dinilai lebih unggul dibanding pendekatan algoritmik sederhana karena mampu menangkap interaksi multi-fitur yang bersifat *non-linear* dan konteks lokal lintas agen tanpa menyebabkan ledakan aturan; adaptif terhadap *concept drift* melalui *retraining* bertahap dan umpan balik analis dalam *feedback loop* atau *active learning*; menghasilkan skor kontinu untuk *ranking* prioritas yang selaras dengan *budgeted triage* sehingga meningkatkan *precision@K/p* dan *lift@p* dibanding skema skoring diskret; bekerja meski label terbatas lewat pendekatan *unsupervised* atau *semi-supervised* yang lebih realistis untuk data SIEM; menyediakan *reason codes* dan *post-hoc explainability* agar keputusan auditabel; serta terukur pada beban data tinggi melalui pemrosesan *batch* atau *streaming* yang mudah diotomatiskan. Pendekatan algoritmik sederhana tetap bermanfaat sebagai *guardrails* dan *safety checks*, tetapi dalam lingkungan dinamis berskala besar, kombinasi keduanya dengan peran utama pada *machine learning* menawarkan *trade-off* terbaik antara akurasi, stabilitas, dan biaya operasi.

BAB IV

DESAIN DAN IMPLEMENTASI SISTEM

IV.1 Gambaran Umum Sistem

Modul pembelajaran mesin dibangun sebagai *pipeline* berlapis dengan kontrak data eksplisit antar-tahap, memisahkan pemrosesan data, pelatihan, inferensi, dan penyajian hasil. Komponen inti mencakup: (i) pembersihan/kanonisasi, (ii) rekayasa fitur, (iii) pelatihan model dan manajemen artefak di registri, serta (iv) inferensi sebagaimana digambarkan pada Gambar IV.1. Artefak model (berkas model dan daftar fitur) diserialisasi dan disimpan di gudang artefak agar dapat dimuat secara *stateless* saat inferensi.

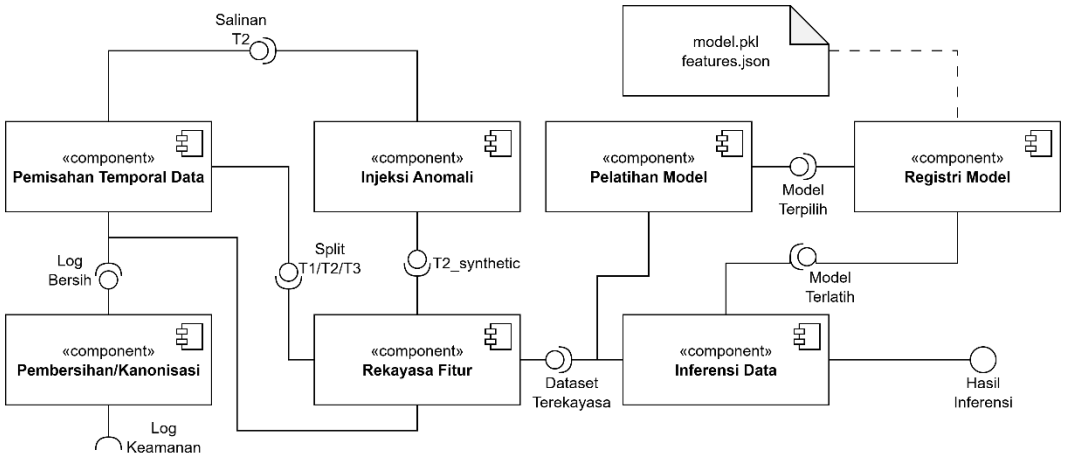

Gambar IV.1 Diagram Komponen Modul Pembelajaran Mesin

Solusi pembelajaran mesin dioperasikan sebagai layanan pendamping seperti yang terlihat pada Gambar IV.2 yang terpisah dari jalur kritis Wazuh dan berjalan dengan akses *read-only* terhadap *feed alerts* yang sudah tersedia, misalnya melalui Wazuh API, *file-based feed* terjadwal, atau *mirroring syslog*. Modul menarik data secara *pull* dengan *backpressure* sehingga tidak menambah beban pada *ingestion path* maupun mengubah *Rule and Decoder Framework*, *Analysis Engine*, atau konfigurasi agen. Hasil *inference* ditulis ke penyimpanan terpisah sebagai *enrichment* yang bersifat *immutable* berisi *score*, *rank*, dan *reason codes*, lalu di-

join kembali ke *alert* asli melalui *correlation key* seperti *alert_id* untuk penyajian di *dashboard* pendamping atau *panel* tambahan tanpa memodifikasi Wazuh Dashboard inti. Arsitektur ini bersifat *stateless* pada saat *inference*, *idempotent*, serta mendukung *batch* berkala atau *near real-time streaming* sesuai kebutuhan. Jika modul berhenti atau gagal, alur SIEM tetap berjalan normal karena tidak ada *inline dependency* pada *pipeline* Wazuh. Pengaktifan fitur dilakukan melalui *feature flag* dan *routing* terpisah sehingga *rollback*, *canary*, atau *blue–green* dapat dilakukan tanpa *downtime*. Dengan pendekatan *sidecar* ini, solusi baru menyatu dengan sistem di Bab III.1 secara non-invasif, menjaga *SLA* operasional sambil menambahkan kemampuan *ranking* dan prioritisasi berbasis pembelajaran mesin.

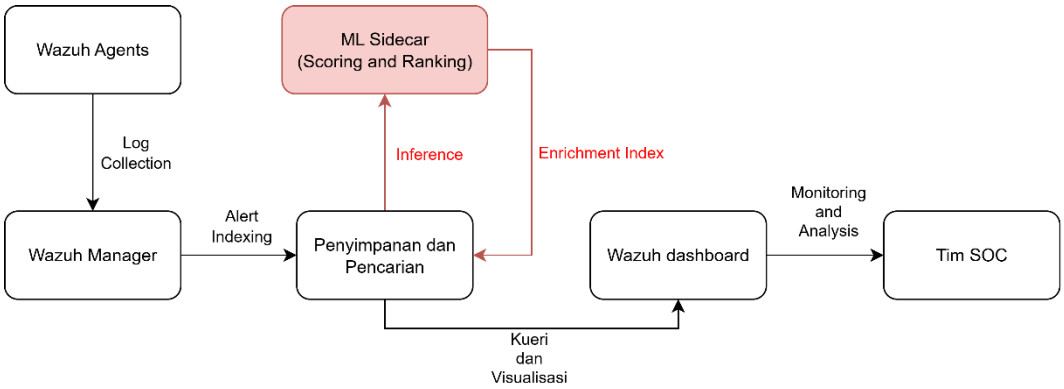

Gambar IV.2 Integrasi Modul ML dengan Arsitektur Sistem As-Is

IV.1.1 Proses Pelatihan

Proses pelatihan model yang digunakan untuk memprioritaskan kejadian anomali menghasilkan artefak model yang stabil dan dapat direproduksi, sehingga alur inferensi dapat berjalan deterministik dengan kontrak data yang jelas. Proses pelatihan dirancang dengan pemisahan yang tegas antara tahap *feature engineering* dan pemodelan agar *coupling* tetap rendah dan uji banding model dapat dilakukan tanpa mengubah antarmuka data.

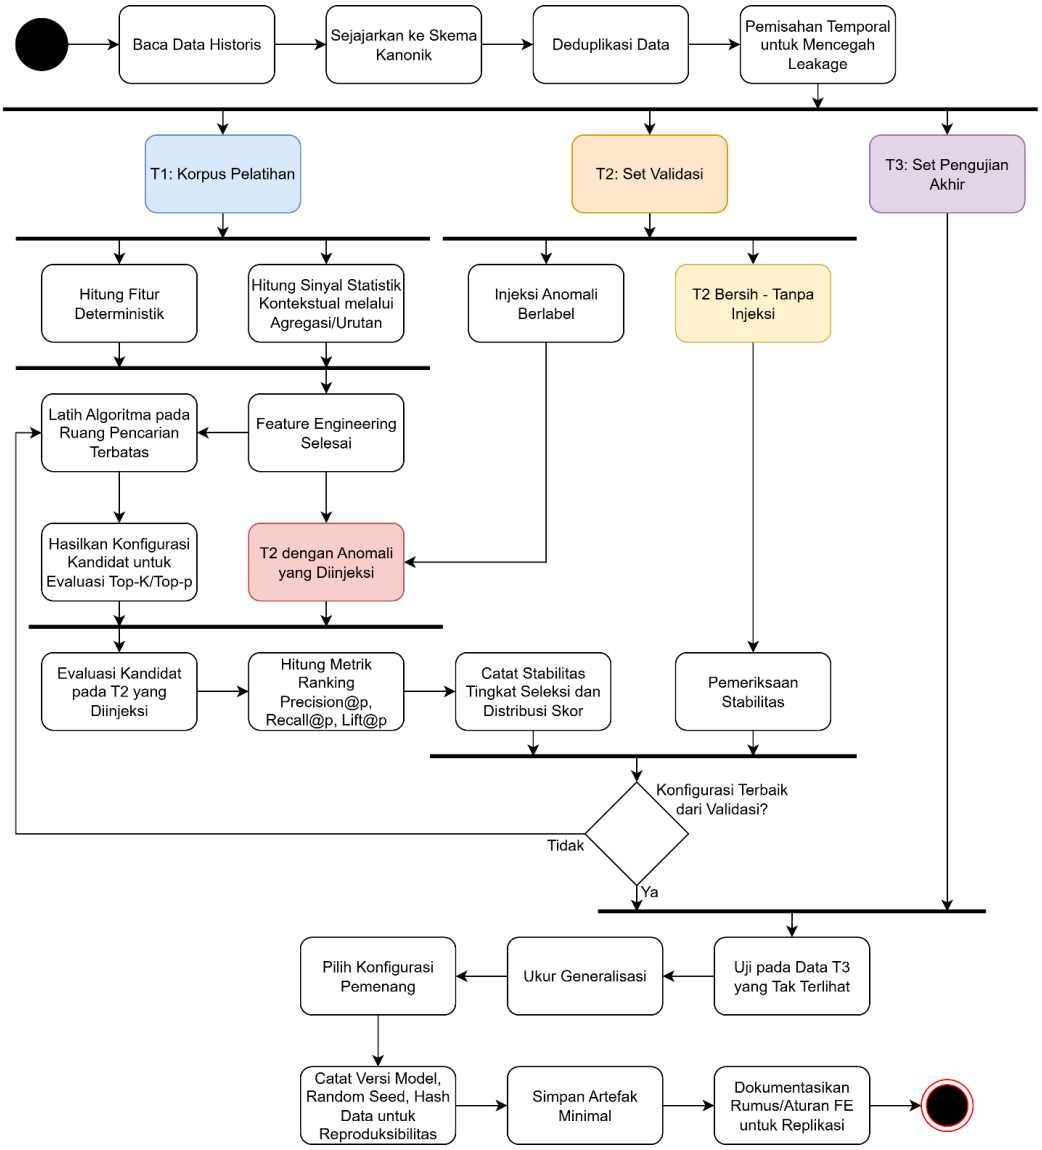

Gambar IV.3 Diagram Aktivitas Proses Pelatihan

Sebagaimana ditunjukkan pada Gambar IV.3, pelatihan disusun untuk menghasilkan model yang stabil dan logika rekayasa fitur yang konsisten, sehingga inferensi pada data baru dapat berjalan *stateless* (menerapkan pola perhitungan yang sama tanpa ketergantungan *state* khusus). Prosedurnya ringkas sebagai berikut.

1. Data historis dibaca, disejajarkan ke skema kanonik (kolom inti, tipe, zona waktu), dideduplikasi, lalu dipisah secara temporal untuk mencegah *leakage*: T1 sebagai korpus pelatihan (*fit*), T2 untuk validasi, dan T3 untuk pengujian akhir. Kontrak data ini menjadi fondasi seluruh tahap berikutnya.
2. Fitur deterministik dihitung langsung, sedangkan sinyal statistik kontekstual dihitung saat memproses T1 melalui agregasi atau urutan. Tidak ada kewajiban serialisasi parameter FE; pola perhitungan yang sama diterapkan konsisten pada T2, T3, dan data inferensi.
3. Algoritma yang relevan operasional (misalnya k-NN, Isolation Forest, LOF) dilatih pada ruang pencarian yang dibatasi dan realistis terhadap latensi. Tahap ini menghasilkan sekumpulan konfigurasi kandidat yang siap dievaluasi dengan skenario Top-K atau Top-p.
4. Untuk menilai performa model secara terkontrol, T2 yang diinjeksi dengan anomali berlabel yang merepresentasikan pola serangan (misalnya aktivitas *off-hours*, *rule/decoder* langka, dan lonjakan *severity*). Kandidat model kemudian dievaluasi pada T2 yang diinjeksi menggunakan metrik ranking seperti *Precision@p, Recall@p*, dan *Lift@p* pada beberapa nilai p atau K yang mewakili *budgeted triage*. Selain akurasi, dicatat pula stabilitas tingkat seleksi dan distribusi skor.
5. Dataset T2 tanpa injeksi tidak memiliki label, sehingga tidak digunakan untuk metrik utama. Namun, tetap dimanfaatkan untuk pemeriksaan stabilitas non-metrik, seperti distribusi skor anomali, tingkat seleksi harian, dan indikasi adanya *drift.*
6. Konfigurasi terbaik dari tahap validasi kemudian diuji pada T3 sebagai data tak terlihat. Fokusnya adalah mengukur kemampuan generalisasi: apakah model tetap stabil dalam tingkat seleksi, distribusi skor, dan relevansi anomali yang terdeteksi pada kondisi baru.
7. Konfigurasi pemenang dipilih berdasarkan metrik utama T2 yang diinjeksi dengan pengikat seperti latensi, jejak memori, dan kemudahan *explainability*, serta konsistensi perilaku pada T2 tanpa injeksi dan T3. Versi

model, *random seed*, serta *hash data* dicatat untuk menjamin reproduksibilitas.

8. Artefak minimal yang disimpan mencakup berkas model dan manifest versi. Parameter FE tidak diserialisasi pada implementasi saat ini; seluruh rumus/aturan FE terdokumentasi sehingga proses dapat direplikasi dan, bila diperlukan di masa depan, parameter dapat disimpan ke registry bersama training logs dan laporan metrik.

Untuk memperjelas alur masukan dan keluaran setiap tahap, ringkasannya disajikan pada Tabel IV.1 berikut.

Tabel IV.1 Ringkasan Tahapan Proses Pelatihan

Tahap	**Input**	**Proses**	**Output**
Pemuatan dan Kanonisasi	*raw logs*	Normalisasi skema, deduplikasi, *split temporal* T1, T2, T3	Dataset kanonik per-*split*
Rekayasa Fitur Data Latihan	T1	Hitung fitur deterministic, *baseline* statistik secara implisit via *groupby*/urutan	T1 berfitur; *baseline* implisit (tanpa *serialisasi*); rumus *FE* terdokumentasi
Pelatihan Model	T1 (berfitur)	Latih kandidat (*k-NN*/*IF*/*LOF*) dengan ruang *hyperparameter* realistis	Kumpulan model kandidat/konfigurasi
Validasi	T2 yang diinjeksi	Terapkan pola *FE* yang sama (tanpa *refit*/*serialisasi*); *skoring*; hitung *Precision@p*, *Recall@p*, *Lift@p* pada beberapa p/K	Skor evaluasi per kandidat + rekomendasi konfigurasi
Sanity check	T2 tanpa injeksi	Terapkan pola *FE* yang sama; penilaian; cek distribusi skor, tingkat seleksi, indikasi *drift*	Indikasi stabilitas dan konsistensi

Tabel IV.1 lanjutan Ringkasan Tahapan Proses Pelatihan

Tahap	**Input**	**Proses**	**Output**
Pengujian (T3)	T3 (*unseen*)	Terapkan pola *FE* yang sama; penilaian; evaluasi stabilitas & relevansi pada data baru	Bukti generalisasi pada kondisi *unseen*
Pemilihan Konfigurasi Akhir	Hasil T2 yang diinjeksi	Pilih konfigurasi pemenang berdasar metrik utama + kinerja/stabilitas; catat *model_version*, *seed*, *data hash*, *experiment log*	Model final siap inferensi
Artefak dan Dokumentasi	Model final + catatan versi	Simpan berkas model dan *manifest* versi; *FE* tidak diserialisasi (rumus/aturan *FE* terdokumentasi untuk replikasi)	Artefak minimal (model + *manifest*) dan dokumentasi replikasi

Rangkaian tahap pelatihan ini membentuk alur yang utuh, dari persiapan data hingga penyimpanan artefak. Pemisahan peran T1, T2 yang diinjeksi, T2 tanpa injeksi, dan T3 membuat dataset yang akan digunakan tepat sasaran: T1 untuk *fitting* model dan penetapan *baseline* fitur secara implisit, T2 yang diinjeksi untuk validasi berbasis metrik, T2 tanpa injeksi untuk *sanity check* non-metrik, dan T3 untuk menguji generalisasi. Skema ini memastikan konfigurasi terpilih bukan hanya optimal pada data validasi, tetapi juga stabil, *reproducible*, dan siap dipakai secara *stateless* dalam skenario operasional nyata.

IV.1.2 Proses Inferensi

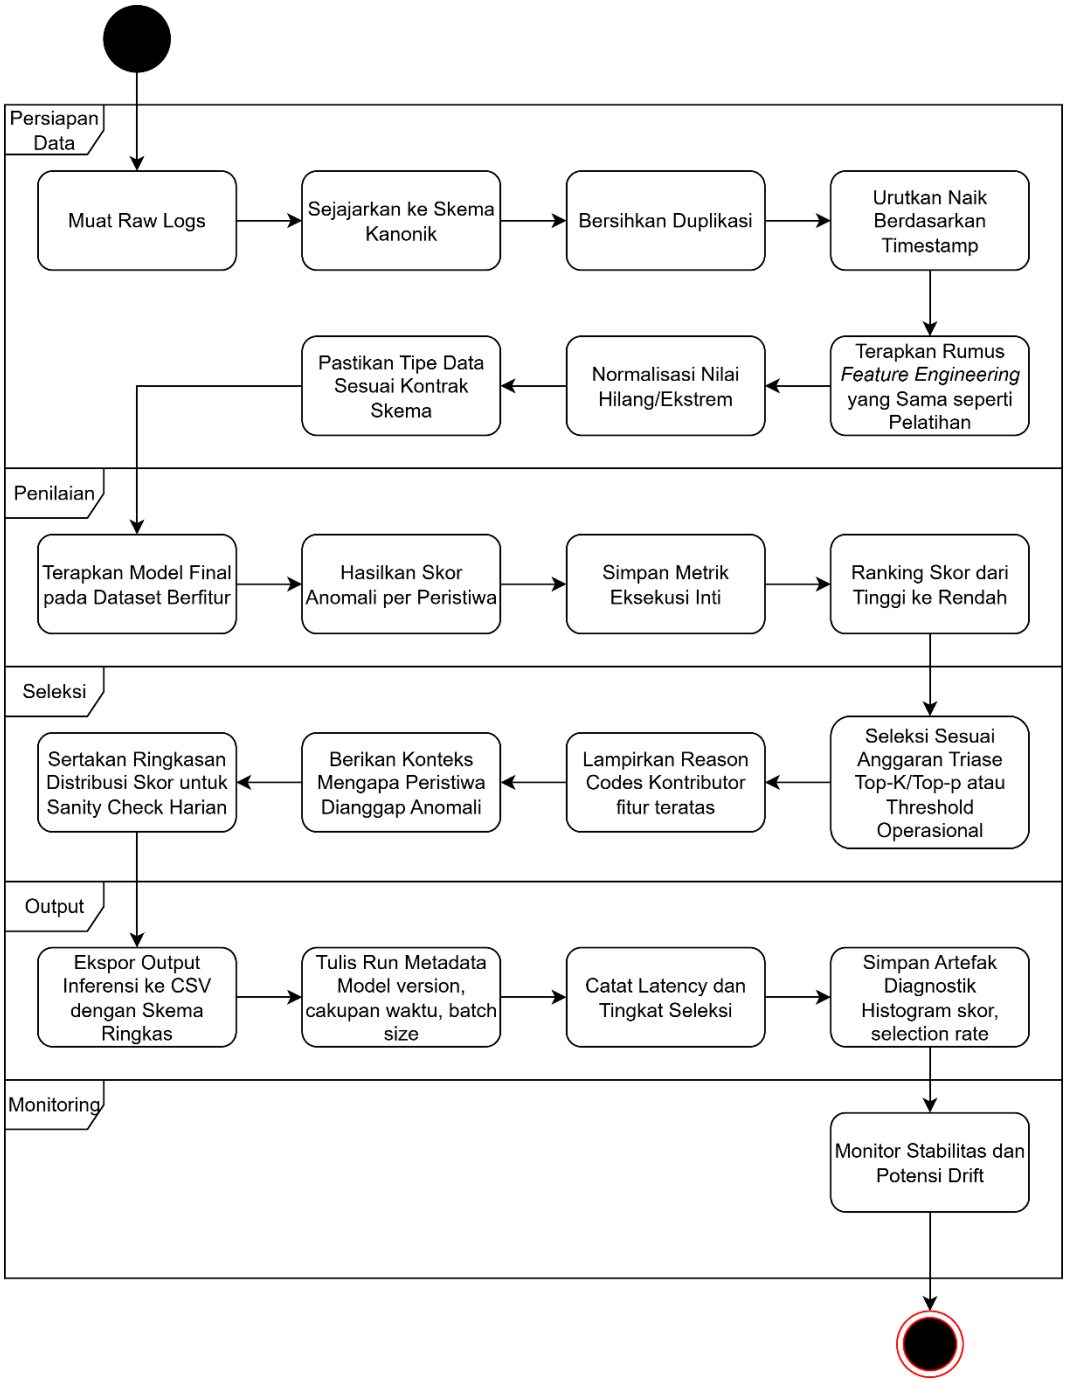

Gambar IV.4 Diagram Aktivitas Proses Inferensi

Sebagai kelanjutan dari proses pelatihan, tahap Proses Inferensi memanfaatkan model final dan logika rekayasa fitur yang telah ditetapkan pada bagian

sebelumnya. Berbeda dengan pelatihan, inferensi tidak lagi melakukan *fit* sehingga dapat dijalankan secara *stateless* di atas *pipeline* operasional. Masukan berupa ekspor log harian yang telah dikanonisasi diproyeksikan ke ruang fitur yang sama, kemudian diberi skor anomali, diurutkan, dan diseleksi sesuai anggaran triase (*Top-K*/*Top-p*). Hasilnya diperkaya dengan *explainability* ringan dan disiapkan untuk integrasi lebih lanjut agar analis SOC segera memperoleh daftar prioritas yang dapat ditindaklanjuti.

Untuk menjembatani dari pelatihan ke eksekusi harian, Proses Inferensi menerapkan *model* final dan pola *feature engineering* yang sama seperti pada T1. Seluruh langkah seperti pada gambar IV.4 berjalan *stateless* di atas *pipeline* operasional dan diproses kronologis.

1. Muat *raw logs*, selaraskan ke skema kanonik, bersihkan duplikasi, lalu urutkan naik berdasarkan *timestamp*.
2. Terapkan rumus *feature engineering* yang sama seperti pada proses pelatihan.
3. Normalisasi nilai hilang/ekstrem (mis. *clipping*), tetapkan nilai bawaan untuk kategori yang belum pernah muncul, dan pastikan tipe data sesuai kontrak skema.
4. Terapkan *model* final pada dataset berfitur untuk menghasilkan skor anomali per peristiwa (*scoring*). Simpan metrik eksekusi inti (jumlah baris, durasi, *latency* inferensi).
5. Lakukan *ranking* skor dari tinggi ke rendah, lalu seleksi sesuai anggaran triase (*Top-K*/*Top-p* atau *threshold* operasional).
6. Lampirkan *reason codes* (kontributor fitur teratas) pada setiap *alert* terpilih guna memberi konteks “mengapa” suatu peristiwa dianggap anomali. Sertakan ringkasan distribusi skor untuk *sanity check* harian.

7. Output inferensi diekspor ke media yang disepakati seperti CSV dengan skema ringkas yang mencakup identitas peristiwa, waktu, konteks sumber, skor anomali, peringkat, dan ringkasan penjelasan.
8. Tulis *run metadata* (versi model, cakupan waktu data, ukuran *batch*, *latency*, tingkat seleksi) dan simpan artefak diagnostik (histogram skor, *selection rate*) untuk memantau stabilitas dan potensi *drift*.

Rancangan Proses Inferensi ini memastikan alur yang konsisten dengan pelatihan yang terdiri atas perhitungan fitur diterapkan tanpa *fit* ulang dan *scoring* berjalan secara *stateless* di atas *pipeline* operasional. Sistem siap dioperasionalkan oleh SOC dengan keluaran yang deterministik, dapat direplikasi, dan mudah diaudit dengan pencatatan *run metadata* serta pemantauan stabilitas dan indikasi *drift*.

IV.1.3 Evolusi Skema Data

Skema data dalam tugas akhir ini sengaja dirancang bertahap dimulai dari "tulang punggung" (*spine*) yang sangat minimal dan andal berdasarkan apa yang dikirim SIEM, lalu dievolusikan menjadi representasi yang lebih kaya konteks untuk kebutuhan analitik dan operasional. Tujuannya adalah untuk menyeimbangkan jejak asal-usul data (*auditability*) dengan sinyal yang cukup informatif untuk pemeringkatan anomali, tanpa membuat skema rapuh atau sulit direplikasi.

Gambar IV.5 menampilkan contoh log mentah sebagaimana diekspor dari SIEM. *Log* tersebut memperlihatkan karakteristik umum data mentah yang panjang dan semi terstruktur yang di dalamnya berisi struktur *JSON* bersarang, variasi nama kolom antar *decoder*, serta keberadaan kolom yang jarang muncul. Pada kondisi ini, transformasi menuju bentuk kanonik diperlukan agar pemodelan dapat bergantung pada subset fitur yang stabil lintas sumber.

YhYrEpgBc39YxYtcK5OB,wazuh-alerts-4.x-2025.07.16,1,2025-07-
16 14:37:50.858000+00:00, , , , , ,0, ,,wazuh-manager-
vm.asia-southeast2-b.c.telkom-mdr.internal, , , , , , , , ,
,,, , , , , ,, , , , , , , , , , , , , , ,,, , , , , ,,, ,,
,, , , , ,,, , , , ,, , ,, , , ,, ,, ,, , , , , , , , , , , ,
, , , , ,,,, ,,,,,,
,,,,,,

MSIE)"","reference"":""o5,8v6,14t:urlDecodeUni,t:cmdLine,t
:normalizePath,t:lowercase"","ruleId"":""932160"","file""
and Chrome friendly error page -->\r\n<!-- a padding to
disable MSIE and Chrome friendly error page --
>\r\n"","http_code"":403,""headers"":{""Server"":""nginx/1
.24.0 (Ubuntu)"","Date"":""Wed, 16 Jul 2025 07:37:50
GMT"","Content-Length"":""564"","Content-
Type"":""text/html"","Connection"":""keep-
alive""}},""producer"":{""modsecurity"":""ModSecurity
v3.0.12 (Linux)"","connector"":""ModSecurity-nginx
v1.0.3"","secrules_engine"":""Enabled"","components"":[""
OWASP_CRS/3.3.5\""""]},""messages"":[{""message"":""Host
header is a numeric IP
address"","details"":{""match"":""Matched \""Operator `Rx'
with parameter `^[\\d.:]+$' against variable
`REQUEST_HEADERS:Host' (Value: `35.219.17.237:8080'
)"","reference"":""o0,18v38,18"","ruleId"":""920350"","f
ile"":""/usr/share/modsecurity-crs/rules/REQUEST-920-
PROTOCOL-
ENFORCEMENT.conf"","lineNumber"":""719"","data"":""35.219
.17.237:8080"","severity"":""4"","ver"":""OWASP_CRS/3.3.5
"","rev"":"""","tags"":[""application-multi"","language-
multi"","platform-multi"","attack-protocol"","paranoia-
level/1"","OWASP_CRS"","capec/1000/210/272"","PCI/6.5.10
""],""maturity"":""0"","accuracy"":""0""}},{""message"":""
Remote Command Execution: Direct Unix Command
Execution"","details"":{""match"":""Matched \""Operator
`Rx' with parameter
`(?:^|=)\\s*(?:{|\\s*\\(\\s*|\\w+=(?:[^\\s]*|\\$.*|\\$.*|<.
|>.|\\'.*\\'|\\\"".*\\\"")\\s+|!\\s*|\\$)*\\s*(?:'|\\\"")
(?:[\\?\\[\\]\\(\\)\\-
\\|+\\w'\\\""\\./\\\\\\\\]+/)?[\\\\\\\\'\\\""]*(?:l[\\\\\\\
\'\\\""]*(?:s(?:[\\\\\\\\'\\\""]*(?:b[\\\\\\\\'\\\""]*_[\\\
\\\\\'\\\""]*r (6252 characters omitted)' against variable
`ARGS_NAMES:exec /bin/bash' (Value: `exec /bin/bash'
)"","reference"":""o0,5v6,14"","ruleId"":""932150"","fil
e"":""/usr/share/modsecurity-crs/rules/REQUEST-932-
APPLICATION-ATTACK-
RCE.conf"","lineNumber"":""444"","data"":""Matched Data:
exec found within ARGS_NAMES:exec /bin/bash: exec
/bin/bash"","severity"":""2"","ver"":""OWASP_CRS/3.3.5"",
""rev"":"""","tags"":[""application-multi"","language-
shell"","platform-unix"","attack-rce"","paranoia-
level/1"","OWASP_CRS"","capec/1000/152/248/88"","PCI/6.5
.2""],""maturity"":""0"","accuracy"":""0""}},{""message"":
""Remote Command Execution: Unix Shell Code
Found"","details"":{""match"":""Matched \""Operator
`PmFromFile' with parameter `unix-shell.data' against

Gambar IV.5 lanjutan Contoh *Log Alert* mentah dari Wazuh

```
variable `ARGS_NAMES:exec /bin/bash' (Value: `exec
/bin/bash':""/usr/share/modsecurity-crs/rules/REQUEST-932-
APPLICATION-ATTACK-
RCE.conf"","lineNumber"":""481"","data"":""Matched Data:
bin/bash found within ARGS_NAMES:exec /bin/bash:
exec/bin/bash"","severity"":""2"","ver"":""OWASP_CRS/3.3.
5"","rev"":""""","tags"":[""application-
multi"","language-shell"","platform-unix"","attack-
rce"","paranoia-
level/1"","OWASP_CRS"","capec/1000/152/248/88"","PCI/6.5
.2""],""maturity"":""0"","accuracy"":""0""}},{""message"":
""Inbound Anomaly Score Exceeded (Total Score:
13)"","details"":{""match"":""Matched \""Operator `Ge'
with parameter `5' against variable `TX:ANOMALY_SCORE'
(Value: `13'
)"","reference"":""""","ruleId"":""949110"","file"":""/us
r/share/modsecurity-crs/rules/REQUEST-949-BLOCKING-
EVALUATION.conf"","lineNumber"":""81"","data"":""""","sev
erity"":""2"","ver"":""OWASP_CRS/3.3.5"","rev"":""""","ta
gs"":[""application-multi"","language-multi"","platform-
multi"","attack-
generic""],""maturity"":""0"","accuracy"":""0""}}]}}",1752
651470.3687274,log,35.219.17.237,wazuh-manager-vm.asia-
southeast2-b.c.telkom-mdr.internal,target-vuln-web-
waf,modsec,Jul 16 07:37:50, , , , , ,ModSecurity log
detected,6, , , ,"[""modsec""]", ,100100, , ,5,False, , ,
,,,, , , , , ,,,
```

```
YhYrEpgBc39YxYtcK5OB,2025-07-16 14:37:50.858,wazuh-manager-
vm.asia-southeast2-b.c.telkom-mdr.internal,100100,5,modsec
```

Gambar IV.6 Contoh *log alert* kanonik

Setelah berada pada bentuk kanonik, data kemudian ditransformasi lebih lanjut menjadi matriks fitur melalui proses *feature engineering*. Proses ini menghasilkan fitur-fitur numerik yang bersifat deterministik sehingga dapat digunakan baik pada tahap pelatihan maupun inferensi dengan hasil yang konsisten. Fitur yang dibangun menekankan cakupan lintas agent dan decoder yang tinggi. Hasil akhir dari tahap ini seperti pada gambar IV.7 adalah sekumpulan kolom numerik yang telah diselaraskan dengan daftar fitur yang dianggap penting dalam mendeteksi anomali, sehingga kamus fitur yang dipakai saat pelatihan identik dengan yang digunakan pada inferensi.

```
YhYrEpgBc39YxYtcK5OB,2025-07-16 14:37:50.858,wazuh-manager-
vm.asia-southeast2-b.c.telkom-
mdr.internal,100100,5,modsec,14,0,2,0,3,2,0.149932702267272
04,1.6,0.9555114450274363,0,0.0,0.0,4.777557225137182,0.773
3470568837009,9.328212292571072
```

Gambar IV.7 Hasil Rekayasa Fitur pada *log* Wazuh

Evolusi skema data pada gambar IV.8 menegaskan dua prinsip utama: keterlacakan dan kesiapan model. Seluruh atribut inti dari data mentah dipertahankan tanpa perubahan nama untuk menjaga *lineage*, kemudahan audit, serta kemampuan rekonsiliasi kembali ke sumber SIEM. Di atas "*spine*" yang konsisten ini, tahap kanonisasi menetapkan kontrak data yang rapi dan seragam, sementara tahap *feature engineering* menambahkan lapisan sinyal yang relevan operasional. Dengan demikian, arsitektur skema yang bertahap ini bukan hanya memperkaya informasi, tetapi juga memastikan konsistensi antar-tahap, memudahkan penjelasan hasil (*explainability*), dan menyiapkan data yang benar-benar siap pakai untuk proses pemodelan dan inferensi pada bagian berikutnya.

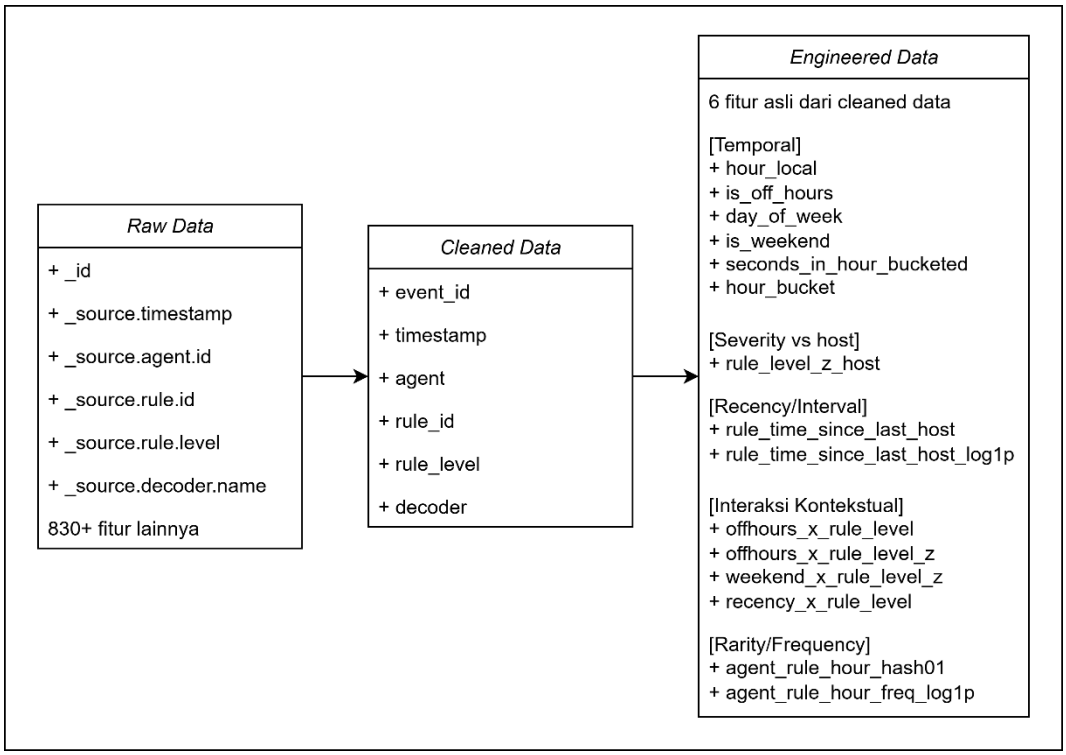

Gambar IV.8 Diagram Kelas Evolusi Skema Data

IV.2 Dataset

Bagian ini menguraikan dataset yang menjadi fondasi pengembangan dan evaluasi artefak. Uraian dimulai dari pemahaman struktur dan cakupan kolom untuk menegaskan kontrak data serta batasannya, dilanjutkan pembersihan guna menormalkan tipe, waktu, dan kualitas rekaman. Berikutnya, rekayasa fitur membentuk dataset yang konsisten dan deterministik agar siap dipakai model. Terakhir, pemodelan data merangkum representasi akhir beserta artefak yang dibekukan untuk pelatihan dan inferensi pada *pipeline* berikutnya.

IV.2.1 Pemahaman Data dan Cakupan Kolom

Dataset yang digunakan berasal dari indeks alert Wazuh yang dikumpulkan melalui arsitektur SIEM organisasi. Data ini bersifat "*alert-centric*", yaitu didominasi artefak waktu, identitas host/agen, serta atribut rule/decoder hasil pemrosesan mesin korelasi Wazuh. Rentang data yang digunakan (lokal/Asia-Jakarta) tetap: 10 Juli 2025 17:40 hingga 12 Agustus 2025 15:44, dengan total 277.499 baris. Selama

rentang tersebut, sistem mencatat lima agen aktif, 2.359 alamat sumber yang valid, 200 alamat tujuan yang valid, serta 13.515 dan 568 port sumber/tujuan yang terobservasi secara valid. Ringkasan angka pokok disajikan pada Tabel IV.2.

Tabel IV.2 Informasi Umum Dataset

Metrik	**Nilai**
Jumlah baris	277.499
Rentang waktu (lokal)	2025-07-10 17:40 → 2025-08-12 15:44
Jumlah agen	5
Unique source IP (valid)	2.359
Unique dest IP (valid)	200
Unique source port (valid)	13.515
Unique dest port (valid)	568

Terdapat dua alasan pemilihan dataset ini. Pertama, secara operasional ia merepresentasikan realitas beban kerja SOC yang ingin ditingkatkan, sehingga setiap temuan eksplorasi langsung relevan terhadap perumusan fitur dan evaluasi model pada konteks produksi. Kedua, secara ilmiah, profil data Wazuh yang kaya dimensi temporal dan rule/decoder, meski minim cakupan jaringan/geo pada sebagian kolom, sangat sesuai untuk membangun *baseline* perilaku per *host* dan mendeteksi penyimpangan (*behavioral anomaly*) melalui pendekatan *unsupervised* seperti *k-Nearest Neighbor* atau *Isolation Forest*. Dengan demikian, dataset ini memberikan keseimbangan antara ketersediaan, relevansi operasional, dan kelayakan metodologis.

Cakupan nilai tidak-null tertinggi terdapat pada *timestamp*, *agent.name*, *rule.groups*, *rule.id*, dan *rule.level* (100%). Kolom *decoder.name* memiliki cakupan tinggi (≈87,6%), sedangkan artefak jaringan dan geolokasi cenderung jarang: *event_type* dan *proto* sekitar 34,8%, *dest_port* 33,4%, *srcip* 17,3%, *country_name* 17,2%, serta pemetaan MITRE (*tactic/technique*) sekitar 11,9%.

Rangkuman cakupan inti disajikan pada Tabel IV.3. Distribusi cakupan ini menjelaskan mengapa rekayasa fitur difokuskan terlebih dahulu pada dimensi temporal, identitas host, serta statistik rule/decoder yang *coverage*-nya dominan.

Tabel IV.3 Cakupan Fitur Inti Keseluruhan

Kolom	**Isi**	**Kolom**	**Isi**
_source.timestamp	100%	_source.data.dest_port	33,4%
_source.agent.name	100%	_source.data.srcip	17,3%
_source.rule.groups	100%	_source.GeoLocation.country	17,2%
_source.rule.id	100%	_source.rule.mitre.tactic	11,9%
_source.rule.level	100%	_source.rule.mitre.technique	11,9%
_source.decoder.name	≈87,6%	_source.data.direction	11,6%
_source.agent.ip	≈70,7%	_source.data.srcport	7,9%
_source.full_log	≈59,9%	_source.data.srcuser	7,9%
_source.data.event_type	34,8%	_source.GeoLocation.city/region	6–7%
_source.data.proto	34,8%		

Pola temporal harian menunjukkan variasi volume yang nyata sepanjang periode pengamatan. Gambar IV.9 memperlihatkan jumlah event per hari yang membentuk *baseline* ritme operasional. Distribusi per jam lokal pada Gambar IV.10 mengindikasikan puncak aktivitas di sekitar rentang pagi awal (sekitar pukul 06) dan sore hingga awal malam (sekitar pukul 16–20), yang berimplikasi pada fitur jam dan ritme harian untuk setiap *host*. Secara mingguan, sebagaimana digambarkan pada Gambar IV.11, Kamis dan Selasa tercatat sebagai hari dengan volume tertinggi. Proporsi *off-hours* (00:00–06:59) cukup besar, sekitar 29,3% dari seluruh *event* pada Gambar IV.12. Pemetaan jam dengan hari pada Gambar IV.13 mempermudah identifikasi slot waktu aneh per *host* dan akan kita jadikan referensi untuk perhitungan pergeseran temporal.

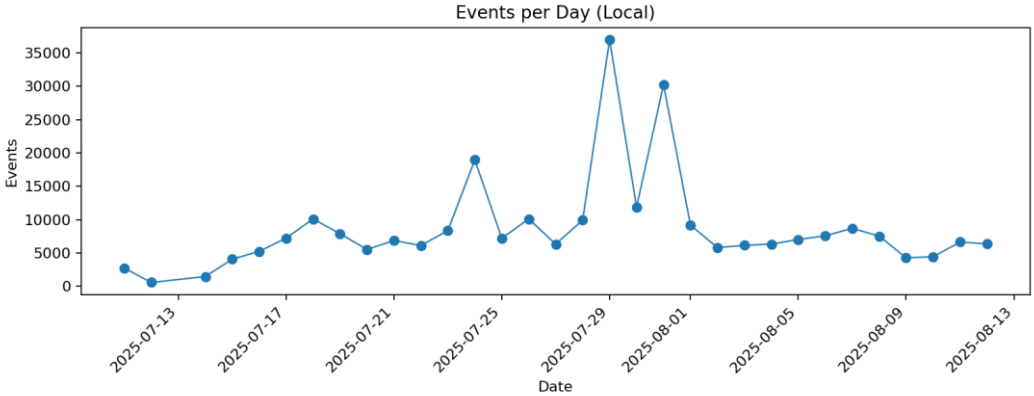

Gambar IV.9 Diagram jumlah *alert* per hari

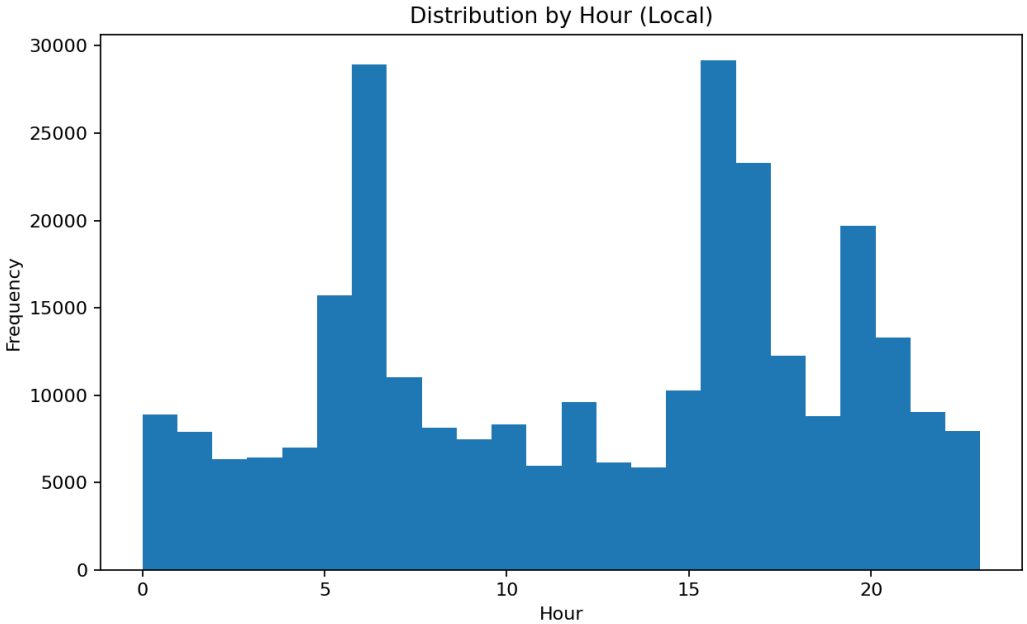

Gambar IV.10 Histogram distribusi *alert* dalam rentang 24 jam

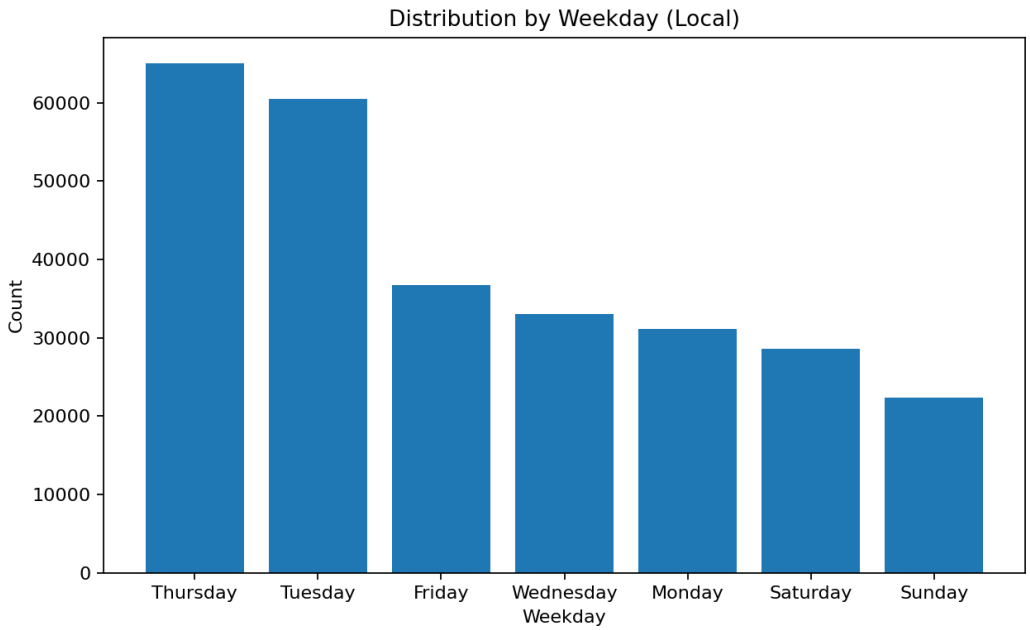

Gambar IV.11 Distribusi jumlah *alert* berdasarkan hari

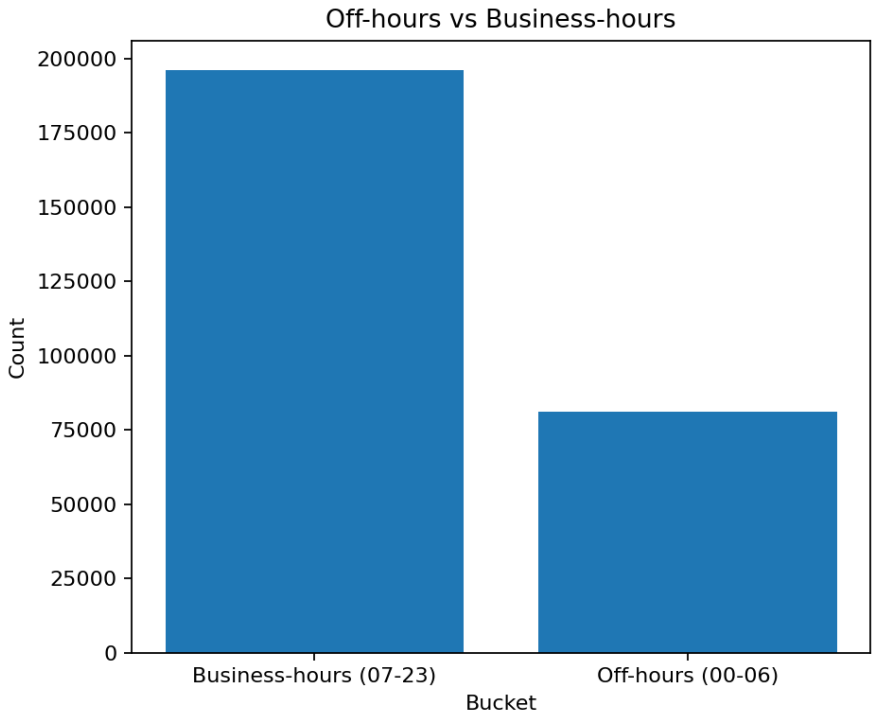

Gambar IV.12 Pembagian jumlah *alert* dalam rentang jam kerja

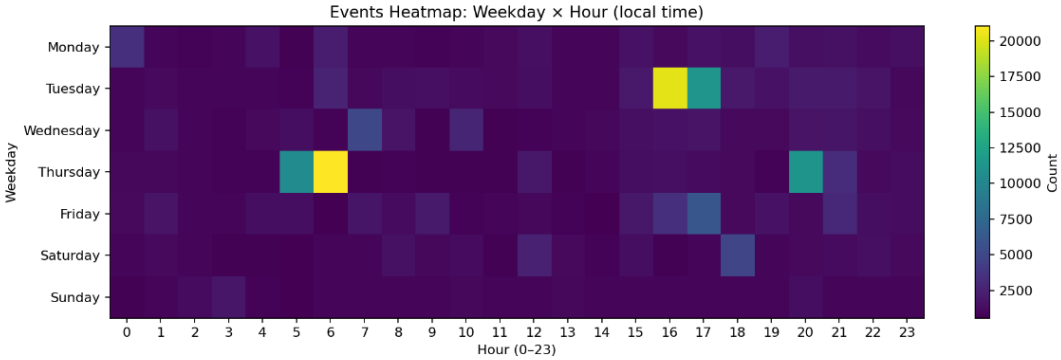

Gambar IV.13 *Heatmap* jumlah *alert* dalam jam dan hari tertentu

Karakter *rule.level* memperlihatkan dominansi level menengah, khususnya sekitar level 5 dan 3, sementara level sangat tinggi (≥10) relatif jarang (Gambar IV.14). Konsentrasi pada level menengah ini menjadi referensi untuk merumuskan *outlier* lokal per *host* dan per jam ketika terjadi lompatan tingkat keparahan. Gambar IV.15 dan Gambar IV.16 memperlihatkan *Rule ID* dan kelompok *rule* teratas. Temuan ini menunjukkan ekosistem kombinasi *ids/suricata/modsec/syslog* yang konsisten dengan lingkungan *web-facing* dan sistem *logging* umum. Gambar IV.17 menampilkan *decoder* teratas, dengan *json*, *modsec*, dan *web-accesslog* menonjol. Secara fitur, frekuensi dan "usia kemunculan pertama" dari *Rule ID/decoder* per *host* dapat diekstraksi sebagai skor kelangkaan (*rarity*) yang sensitif terhadap perubahan pola.

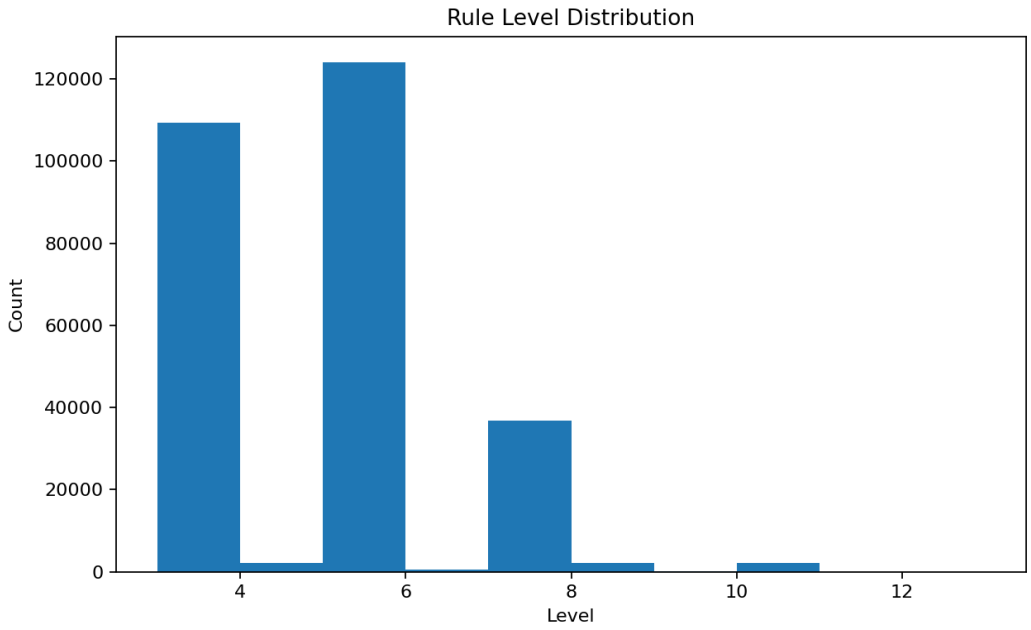

Gambar IV.14 Distribusi tingkat aturan *alert*

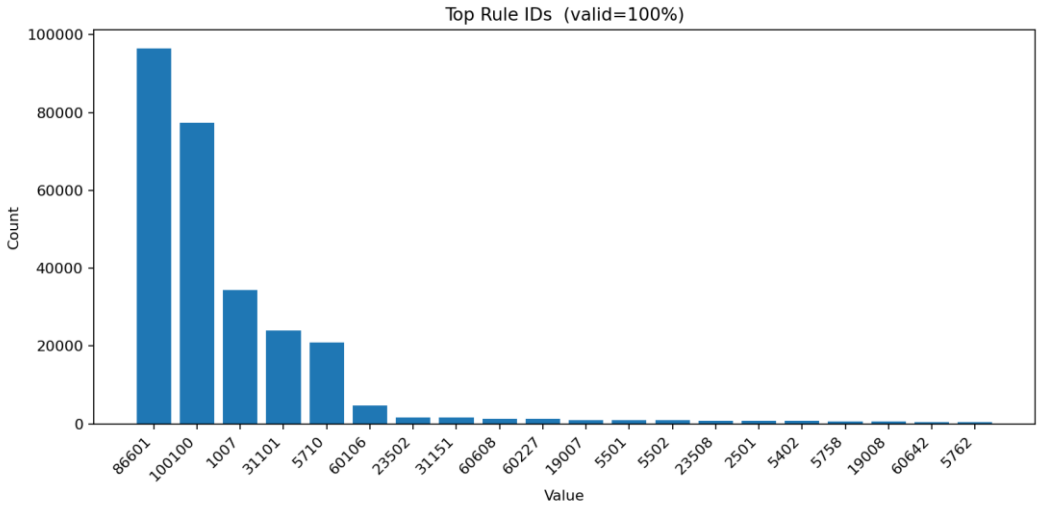

Gambar IV.15 Distribusi ID aturan yang ditampilkan *alert*

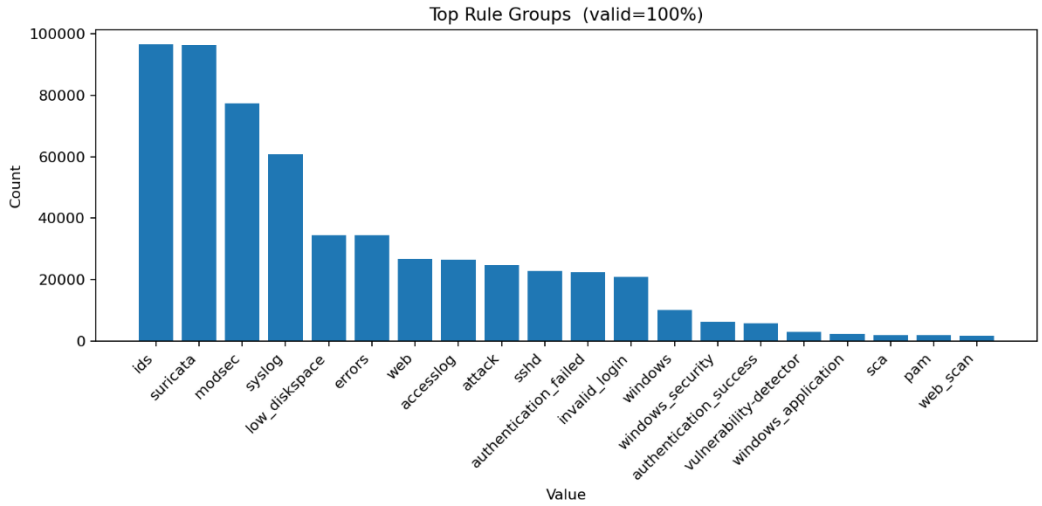

Gambar IV.16 Distribusi kelompok aturan yang dihasilkan oleh *alert*

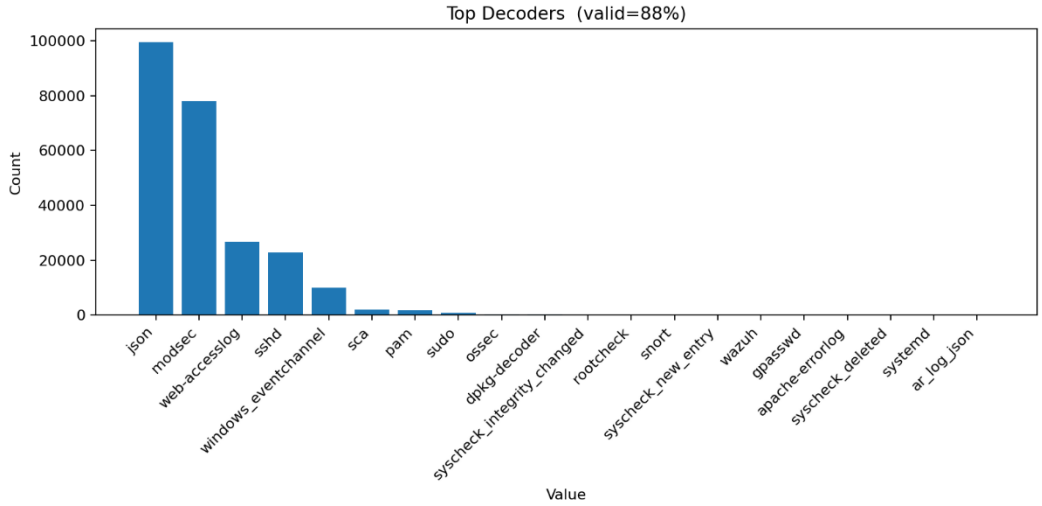

Gambar IV.17 Distribusi dekoder aturan yang menghasilkan *alert*

Komposisi agen menunjukkan beberapa *host* dominan yang konsisten menghasilkan volume terbesar (Gambar IV.18). Pola ini mengarahkan rancangan fitur ke *baseline* perilaku per *host*, termasuk vektor profil *rule/decoder* historis untuk mendeteksi *host identity drift* ketika sebuah *host* tiba-tiba menampilkan pola yang lazimnya milik *host* lain. Pada tahap evaluasi, peringkat anomali per *host* per hari juga penting agar prioritisasi tidak bias oleh *host* bervolume besar.

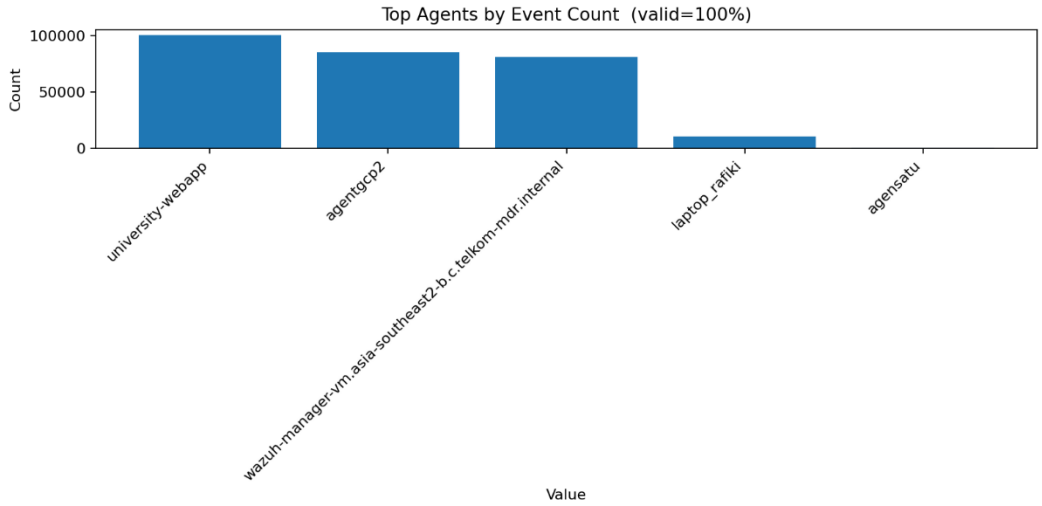

Gambar IV.18 Distribusi agen

Karakteristik dataset yang dianalisa menegaskan fokus rekayasa fitur pada ritme waktu, keparahan relatif per *host*, dan kelangkaan kombinasi *agent-rule-decoder*, karena cakupan tertinggi berada pada *timestamp*, identitas *host*, serta *rule/decoder* sementara sinyal jaringan dan geolokasi lebih jarang. Pembersihan dan kanonisasi menghasilkan korpus kanonik yang stabil; artefak fitur dan skala dibekukan untuk pelatihan serta inferensi dengan prinsip *no peeking*. Keterbatasan cakupan jaringan/geo dicatat sebagai batas studi dan dimitigasi melalui baseline per *host* dan validasi temporal.

IV.2.2 Pembersihan Data

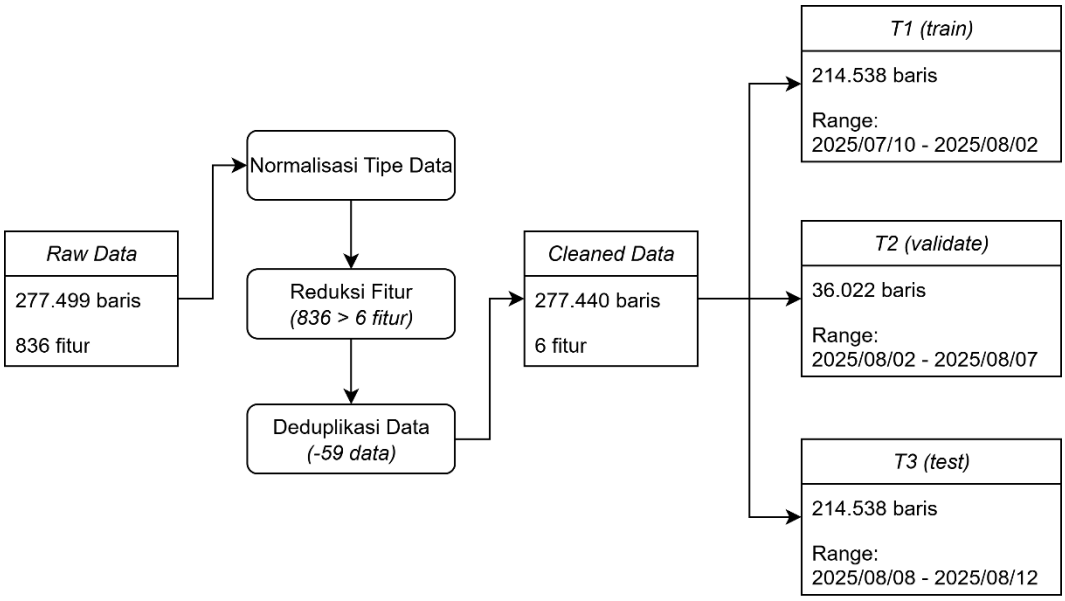

Gambar IV.19 Gambaran Umum Proses dan Transformasi Pembersihan Data

Proses pembersihan seperti yang terlihat pada gambar IV.19 dimulai dari dataset mentah berukuran 277.499 baris dengan 836 kolom. Tahap pertama adalah seleksi enam kolom kanonik yang menjadi fondasi seluruh analisis berikutnya, mencakup identitas kejadian, konteks waktu, identitas agen, serta identitas dan tingkat keparahan aturan bersama nama *decoder*. Pemetaan dilakukan secara eksplisit dari skema Wazuh/Elastic yang heterogen, dengan prioritas pada *_source.agent.name* dan mekanisme *fallback* ke *_source.agent.id* untuk memastikan ketersediaan nilai pada seluruh baris. Setelah itu, normalisasi tipe data dan *parsing* waktu ditegakkan sehingga *event_id, agent, rule_id*, dan *decoder* berwujud string, *rule_level* bertipe bilangan bulat *nullable* (*Int64*), dan *timestamp* berada pada tipe *datetime64[ns]*. Hasil validasi menunjukkan tidak ada nilai hilang pada keenam kolom tersebut, sehingga integritas skema setelah normalisasi dapat dipertanggungjawabkan.

Reduksi fitur dilakukan dengan membuang ratusan kolom berisikan *placeholder* atau berderajat keterisian rendah sehingga skema menyusut dari 836 kolom menjadi 6 kolom, setara pengurangan 99,28 persen. Pada tahap akhir, deduplikasi berbasis kunci *event_id* menghapus 59 baris ganda atau redundan, yang berimbas pada

penurunan ukuran dataset sebesar 0,02 persen. Keluaran akhir berupa korpus bersih berukuran 277.440 baris dan 6 kolom. Seluruh keputusan dan hasil setiap langkah terdokumentasi dan memuat ringkasan pemetaan skema, tipe data, jumlah nilai hilang, daftar kolom yang dibuang, serta statistik deduplikasi. Dengan demikian, dokumentasi ini memberikan gambaran ringkas namun lengkap mengenai lintasan transformasi data, sekaligus menyajikan angka-angka kunci yang menjadi dasar justifikasi metodologis pada bagian-bagian berikutnya.

Tahap pertama pembersihan adalah pemetaan skema ke enam kolom kanonik, yaitu *event_id, timestamp, agent, rule_id, rule_level,* dan *decoder*. Pemetaan ini memanfaatkan daftar kandidat nama kolom dari berbagai varian skema Wazuh/Elastic sehingga skrip dapat secara *robust* menemukan sumber nilai yang benar pada dataset mentah. Sebagai contoh, *event_id* diprioritaskan dari *_id*, sementara *timestamp* dipetakan dari *_source.timestamp*, identitas agen diperoleh dari *agent.name* atau *agent.id*, dan atribut aturan diperoleh dari *_source.rule.id* serta *_source.rule.level*, sedangkan nama *decoder* berasal dari *_source.decoder.name*.

Normalisasi nilai dilakukan dengan menegakkan tipe data dan format waktu yang konsisten. Kolom *event_id* dikonversi ke tipe string; *timestamp* diurai menggunakan pola waktu Kibana ("%b %d, %Y @ %H:%M:%S.%f") dengan toleransi kesalahan sehingga nilai tidak valid akan dipaksa menjadi hilang (NaT); *agent, rule_id,* dan *decoder* dikonversi ke string; sedangkan *rule_level* ditegakkan sebagai bilangan bulat *nullable* (Int64). Keenam kolom inilah yang kemudian dipertahankan sebagai keluaran. Implementasi teknis tahap ini diperlihatkan dalam fungsi normalisasi pada skrip pembersihan.

Setelah normalisasi, dilakukan deduplikasi berbasis event_id. Skrip menjatuhkan baris duplikat dengan kunci *event_id* sehingga mengurangi 59 baris dari hasil normalisasi awal. Informasi deduplikasi tersebut direkam baik pada laporan Markdown maupun JSON, lengkap dengan kunci yang digunakan. Dengan demikian, kohesi rekaman per kejadian terjaga sebelum data memasuki tahapan analitik berikutnya.

Keputusan untuk menyusutkan skema dari ratusan kolom ke enam kolom didasarkan pada profil keterisian dan kualitas atribut yang teramati dalam eksplorasi awal. Banyak famili kolom, seperti geolokasi, parameter *ModSecurity*, *Windows EventChannel* yang sangat spesifik, serta berbagai statistik flow dan transaksi HTTP, memiliki tingkat keterisian yang rendah atau didominasi *placeholder* sehingga kurang layak dipakai sebagai fitur generik di seluruh agen. Laporan pembersihan mencatat secara eksplisit keluarga kolom yang ditanggalkan, misalnya atribut geolokasi *(_source.GeoLocation.**), berbagai subbidang *flow.** dan statistik decoder, serta parameter transaksi HTTP dan ModSecurity, yang seluruhnya dikeluarkan pada tahap ini karena tidak konsisten tersedia lintas sumber dan berpotensi memasukkan *noise*. Observasi ini juga sejalan dengan panduan fitur yang menunjukkan bahwa kolom geolokasi dan MITRE sering kali berisi placeholder, sementara keluarga-keluarga sumber tertentu (Windows, ModSecurity, SCA, kerentanan, flow) lebih tepat untuk deteksi yang sangat terarah dibandingkan diperlakukan sebagai fitur universal.

Validasi akhir terhadap kualitas hasil pembersihan ditunjukkan oleh tipe data dan jumlah nilai hilang pada keenam kolom yang dipertahankan. Laporan menunjukkan bahwa *event_id, timestamp, agent, rule_id, rule_level,* dan *decoder* masing-masing bertipe string, datetime64[ns], string, string, Int64, dan string, serta tidak ditemukan nilai hilang pada seluruh kolom tersebut setelah pembersihan. Konsistensi ini penting untuk memastikan integritas transformasi temporal pada tahap rekayasa fitur serta mencegah kegagalan saat pelatihan model akibat tipologi data yang ambigu.

Ringkasan numerik dari proses pembersihan disajikan pada Tabel IV.4. Tabel ini memadatkan metrik utama, pemetaan skema, tipe data kanonik, serta hasil deduplikasi yang dihasilkan oleh skrip.

Tabel IV.4 Ringkasan Proses Pembersihan Data

Aspek	**Nilai**
Ukuran korpus mentah	277.499 baris, 836 kolom
Ukuran korpus bersih	277.440 baris, 6 kolom
Kolom kanonik yang dipertahankan	event_id, timestamp, agent, rule_id, rule_level, decoder
Pemetaan sumber (contoh realisasi)	_id → event_id _source.timestamp → timestamp _source.agent.name/_source.agent.id → agent _source.rule.id → rule_id _source.rule.level → rule_level _source.decoder.name → decoder
Tipe data kanonik	string, datetime64[ns], string, string, Int64, string
Nilai hilang (enam kolom)	0 pada seluruh kolom
Deduplikasi	59 baris dihapus berdasarkan kunci event_id

Seluruh proses pembersihan dapat direproduksi melalui pemanggilan skrip dengan argumen jalur masukan, keluaran, dan direktori laporan. Eksekusi tersebut secara deterministik menghasilkan berkas laporan yang memuat bentuk data, pemetaan kolom, daftar kolom yang dibuang, d tipe data, jumlah nilai hilang, serta ringkasan deduplikasi.

Akhirnya, strategi pembersihan yang menitikberatkan pada kolom-kolom kanonik tersebut konsisten dengan temuan eksplorasi bahwa sebagian besar kolom berderajat kelengkapan rendah, banyak yang berupa placeholder, dan cenderung bersifat spesifik-sumber sehingga tidak stabil lintas agen. Korpus yang dihasilkan siap untuk dipisahkan secara temporal, diinjeksi anomali secara terkontrol, dan direkayasa fiturnya tanpa terbebani oleh *noise* struktural dari data mentah dengan memusatkan skema pada enam atribut fundamental dan memastikan integritas tipologi serta deduplikasi.

Data hasil pembersihan kemudian dipisahkan secara temporal ke dalam tiga himpunan T1, T2, dan T3 untuk mendukung tahapan pengembangan pembelajaran mesin, masing-masing berperan sebagai korpus pelatihan historis (T1), validasi dan penyetelan *hyperparameter* (T2), serta pengujian prospektif (T3). Batas waktu ditetapkan sebagai berikut: T1 mencakup seluruh kejadian hingga 2 Agustus 2025 pukul 23:59:59.999999; T2 mencakup rentang 3–7 Agustus 2025; sedangkan T3 mencakup kejadian sejak 8 Agustus 2025 pukul 00:00:00 hingga 12 Agustus 2025. Penetapan batas ini memastikan tidak terjadi kebocoran informasi lintas waktu sehingga metrik validasi dan uji merefleksikan kinerja model pada data "masa depan" relatif terhadap korpus pelatihan. Ringkasan statistik pemisahan menunjukkan T1 berisi 214.538 baris dengan rentang waktu teramati 10 Juli 2025 17:40:07.032 hingga 2 Agustus 2025 23:59:53.010, T2 berisi 36.022 baris dengan rentang waktu teramati 3 Agustus 2025 00:00:01.448 hingga 7 Agustus 2025 23:59:27.744, dan T3 berisi 26.880 baris dengan rentang waktu teramati 8 Agustus 2025 00:00:01.976 hingga 12 Agustus 2025 15:44:59.718.

Tabel IV.5 Skema Pembagian Dataset Secara Temporal

Subset	**Rentang waktu (kebijakan)**	**Rentang waktu teramati**	**Jumlah baris**	**Peran dalam ML**
T1	≤ 2025-08-02 23:59:59.999999	2025-07-10 17:40:07.032 – 2025-08-02 23:59:53.010	214.538	Pelatihan (baseline historis)
T2	2025-08-03 00:00:00 – 2025-08-07 23:59:59.999999	2025-08-03 00:00:01.448 – 2025-08-07 23:59:27.744	36.022	Validasi dan penyetelan hiperparameter
T3	≥ 2025-08-08 00:00:00	2025-08-08 00:00:01.976 – 2025-08-12 15:44:59.718	26.880	Pengujian prospektif

Tabel IV.5 merangkum kebijakan dan realisasi pemisahan temporal, jumlah baris per subset, serta fungsi masing-masing subset dalam siklus pengembangan model.

Dalam kerangka evaluasi yang diusulkan, T1 digunakan untuk melatih model dan membentuk *baseline* perilaku; T2 dipakai untuk validasi, termasuk penyuntikan kelas anomali secara sintetis dari keseluruhan *split* data agar proses penyetelan *hyperparameter* dan pengujian sensitivitas lebih terkendali; sementara T3 disisihkan ketat sebagai set uji akhir untuk mengukur kemampuan generalisasi pada data yang tidak pernah dilihat model. Skema klasifikasi yang digunakan terdiri atas dua kelas, yakni normal dan anomali, dengan kelas anomali ditambahkan secara sintetis khusus pada T2 sebagai lapisan validasi tambahan yang memungkinkan kalibrasi ambang, penilaian metrik ranking, dan analisis ketahanan model terhadap variasi pola kejadian sebelum dievaluasi secara prospektif pada T3.

IV.2.3 Rekayasa Fitur

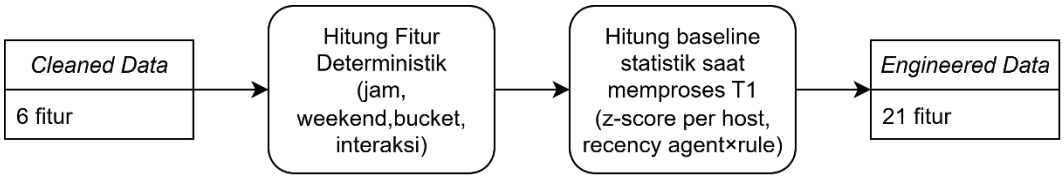

Gambar IV.20 Gambaran Umum Proses dan Transformasi Rekayasa Fitur

Proses *feature engineering* merupakan tahap penting dalam membangun model deteksi anomali, karena kualitas representasi data akan secara langsung menentukan kemampuan model dalam mengenali pola normal maupun perilaku yang menyimpang. Dalam konteks tugas akhir ini, data yang tersedia dari Wazuh memiliki karakteristik tertentu yang membatasi ruang lingkup transformasi, antara lain jumlah agen yang relatif kecil, cakupan aturan (*rule*) yang cenderung stabil, serta distribusi variabel tambahan seperti geolokasi atau teks log yang sangat jarang terisi. Oleh karena itu, strategi *feature engineering* harus didasarkan pada prinsip parsimoni, yaitu memilih fitur yang sederhana, memiliki cakupan data yang tinggi, serta secara konseptual dapat dipertanggungjawabkan sebagai sinyal yang relevan untuk mendeteksi anomali.

Pendekatan yang digunakan berangkat dari tiga kategori sinyal utama, yakni temporal, keparahan (*severity*), serta keterulangan (*recency*). Fitur-fitur dasar ini

kemudian dikombinasikan dalam bentuk interaksi sederhana untuk memperkuat konteks ketika sebuah sinyal tunggal terlalu lemah. Pemilihan ini bukan semata karena keterbatasan data, melainkan juga karena pertimbangan praktis: fitur yang dipilih dapat dihitung secara ringan, tidak membutuhkan sumber eksternal, dan tetap dapat dijelaskan secara intuitif kepada analis keamanan. Dengan demikian, model yang dibangun tidak hanya bekerja secara matematis, tetapi juga memberikan dasar interpretasi yang kuat ketika hasil deteksi dipresentasikan.

Tabel IV.6 merangkum fitur-fitur yang dipertahankan dalam tugas akhir ini, lengkap dengan sumber asalnya, penjelasan teknis mengenai cara perhitungannya, alasan pemilihan, serta indikasi anomali yang ingin ditangkap.

Tabel IV.6 Dekomposisi Fitur yang Direkayasa

Jenis Fitur	**Nama Fitur**	**Sumber dan Transformasi**	**Alasan Pemilihan**	**Indikasi Anomali**
Temporal	hour_local, is_off_hours	Ekstraksi jam lokal dari *timestamp*; f*lag off-hours* jika 00:00–06:59	Sederhana, *robust*, merepresentasikan ritme aktivitas harian	Aktivitas pada tengah malam atau di luar jam kerja
Temporal	day_of_week, is_weekend	Ekstraksi hari dari *timestamp*; *flag* akhir pekan	Memberi konteks mingguan; banyak agen hanya aktif di hari kerja	Aktivitas mencurigakan yang muncul pada akhir pekan
Temporal	seconds_in_hour_bucketed	(*minute* × 60 + *second*) di-*bin* 10 menit	Menangkap periodisitas tanpa *jitter* detik	Kejadian yang biasanya terjadwal rapi tetapi muncul di *bucket* berbeda
Temporal	hour_bucket	Pengelompokan jam ke rentang (0–6, 7–12, 13–18, 19–23)	Menyederhanakan pola waktu harian untuk ko-analisis	Aktivitas yang bergeser ke rentang jam yang tidak lazim
Severity	rule_level_z_host	Z-score tingkat keparahan relatif terhadap distribusi masing-masing *host*	Menekankan deviasi pada konteks *host*, bukan nilai absolut	Lonjakan *severity* yang tidak wajar disbanding standar *host*
Recency	rule_time_since_last_host	Selisih waktu sejak *rule* terakhir muncul pada *host* yang sama (detik/menit)	Memberi konteks keterulangan dan jeda	*Rule* kembali muncul setelah jeda panjang

Tabel IV.6 lanjutan Dekomposisi Fitur yang Direkayasa

Jenis Fitur	**Nama Fitur**	**Sumber dan Transformasi**	**Alasan Pemilihan**	**Indikasi Anomali**
Recency	rule_time_since_last_host_log1p	Transformasi log1p dari *recency* mentah	Menstabilkan skala, mengurangi pengaruh *outlier*	Sensitivitas lebih baik pada perbedaan *recency* pendek–menengah
Interaksi	offhours_x_rule_level	Perkalian indikator *off-hours* dan *rule_level*	Menggabungkan waktu dan intensitas untuk memperkuat sinyal	*Severity* tinggi yang terjadi pada tengah malam
Interaksi	offhours_x_rule_level_z	*Off-hours* dikombinasikan dengan *rule_level_z_host*	Menyaring *outlier* berdasarkan konteks waktu per-*host*	Keparahan relatif tinggi di luar jam kerja
Interaksi	weekend_x_rule_level_z	Akhir pekan dikombinasikan dengan *rule_level_z_host*	Menambah konteks musiman mingguan terhadap *severity*	Lonjakan keparahan yang hanya terjadi di akhir pekan
Interaksi	recency_x_rule_level	Produk antara *recency* dan *severity*	Menyorot *rule* dorman yang kembali dengan intensitas tinggi	Aktivitas berisiko yang muncul kembali setelah lama hilang
Ko-occurence/ Rarity	agent_rule_hour_hash01	Tanda tangan *hashed* dari kombinasi *agent* × *rule_id* × *hour_bucket*	Representasi ringan pola ko-*occurence* untuk pemetaan cepat	*Rule* yang biasanya *benign* tetapi muncul pada jam tidak wajar

Tabel IV.6 lanjutan Dekomposisi Fitur yang Direkayasa

Jenis Fitur	**Nama Fitur**	**Sumber dan Transformasi**	**Alasan Pemilihan**	**Indikasi Anomali**
Ko-occurence/ Rarity	agent_rule_hour_freq_log1p	Frekuensi historis *agent–rule* pada jam terkait lalu log1p	Mengukur kelangkaan/*rarity* berbasis waktu; stabil terhadap skala	Kemunculan jarang atau lonjakan mendadak pada jam tertentu

Selain fitur yang dipertahankan di atas, terdapat sejumlah kandidat fitur yang secara eksplisit dieliminasi setelah dilakukan evaluasi distribusi data. Fitur berbasis *novelty* seperti frekuensi *rule* atau *decoder* per *host* pada dasarnya memiliki nilai konseptual, tetapi dalam dataset yang digunakan, hampir seluruh *rule* dan *decoder* yang muncul di data validasi (T2) dan pengujian (T3) sudah pernah muncul pada data latih (T1). Akibatnya, fitur ini mengalami saturasi dan tidak lagi mampu memberikan diskriminasi yang berarti. Hal serupa berlaku untuk geolokasi, yang pada lebih dari 80% baris berisi nilai kosong atau *placeholder*, serta variabel teks mentah yang tidak konsisten. *Port* sumber maupun tujuan juga dieliminasi karena distribusinya sangat berat pada layanan umum (SSH/HTTP), sehingga tidak memberi nilai tambah dalam deteksi. Eliminasi ini memperkuat argumen bahwa setiap fitur yang dipertahankan benar-benar memiliki cakupan luas, keterhubungan langsung dengan perilaku yang ingin dideteksi, dan dapat dipertanggungjawabkan dalam praktik analisis keamanan.

Dengan kerangka ini, dapat ditegaskan bahwa *feature engineering* tidak diarahkan untuk menghasilkan sebanyak mungkin atribut, tetapi untuk memilih atribut yang paling relevan dan dapat menjelaskan fenomena anomali secara sederhana namun kuat. Model yang dihasilkan akan lebih stabil, dapat dijelaskan, dan sesuai dengan tujuan tugas akhir, yaitu melakukan prioritisasi alert berbasis deteksi anomali yang praktis digunakan dalam konteks SIEM.

IV.2.4 Pemodelan Data

Subbab ini memformulasikan permasalahan prioritisasi *alert* pada sistem SIEM sebagai masalah deteksi anomali dengan keluaran berupa *ranking* skor keanehan per peristiwa, bukan klasifikasi biner. Formulasi tersebut dipilih karena karakter dataset log yang dominan tidak berlabel, berukuran besar, serta memiliki prevalensi kejadian menarik yang rendah sekaligus dinamis terhadap waktu (potensi *concept drift*). Dalam kondisi seperti ini, pendekatan *supervised learning* memerlukan investasi anotasi yang besar dan berisiko bias terhadap periode pelatihan tertentu, sedangkan *anomaly detection* memberi jalan tengah yang praktis yaitu model

menilai “keunikan” suatu peristiwa relatif terhadap dataset historis yang telah dibersihkan dan direkayasa fiturnya.

Dataset yang digunakan dalam tugas akhir ini berasal dari *log alert* SIEM dengan tulang punggung fitur yang relatif konsisten antar-hari dan antar-host: penanda waktu (tanggal, jam, *off-hours*), identitas *agent/host*, *decoder* dan *rule_id*, serta *rule_level* (keparahan). Setelah proses pembersihan, fitur-fitur tersebut direkayasa lebih lanjut menjadi vektor numerik yang menangkap dimensi temporal (misalnya *flag* akhir pekan atau jam di luar kantor), keparahan (standarisasi/ *z-score* terhadap baseline host), dan unsur *rarity/novelty* sederhana (misalnya kejarangan kombinasi *agent*×*rule*×*jam*). Ciri-ciri ini membawa beberapa konsekuensi metodologis.

Pertama, karena label “anomali” yang benar-benar terverifikasi biasanya sangat sedikit dan tidak merata, maka *ground truth* untuk pelatihan *supervised* sulit dibangun tanpa bias. Kedua, pola serangan atau mis-konfigurasi berpotensi berubah seiring waktu; karenanya model yang mengandalkan asumsi distribusi global yang kaku berisiko kehilangan sensitivitas. Ketiga, kebutuhan operasional SOC lebih menuntut *ranking* prioritas alert yang realistis untuk ditinjau setiap hari (misalnya *Top-K* atau *Top-p* persen), alih-alih keputusan biner pada seluruh dataset. Ketiga hal tersebut mendorong pemilihan pendekatan *anomaly detection* yang mampu memeringkat keanehan peristiwa berdasarkan jarak/kepadatan lokal atau kemudahan isolasi dalam ruang fitur.

Tujuan operasional tugas akhir ini adalah meningkatkan efektivitas *triage* analis dengan menyediakan daftar *Top-K* (atau *Top-p*) alert paling patut diperiksa. Oleh karena itu, metrik utama yang dipakai pada tahap evaluasi di Bab V bukanlah akurasi global, melainkan metrik yang langsung berkait dengan *review budget* analis, khususnya precision@K atau precision@p (proporsi temuan relevan di irisan yang memang ditinjau), lift@p (kenaikan efektivitas relatif terhadap *base rate/prevalence*), recall@p (cakupan pada *budget* yang sama), dan FPR@p (perkiraan *false positive* dalam irisan yang dinilai). Penekanan pada metrik-metrik ini secara implisit mengarahkan kita pada algoritma yang mampu menonjolkan

keanehan lokal (konteks *host/agent*/waktu) ketimbang semata mencari *outlier* global.

Tiga algoritma *unsupervised anomaly detection* dipertimbangkan karena bias induktifnya saling melengkapi terhadap sifat data yang telah dijelaskan.

1. k-Nearest Neighbor (k-NN) anomaly scoring

   Ketika beroperasi pada lingkungan lokal, k-NN unggul ketika sinyal *rarity* bersifat kontekstual (misalnya kombinasi *agent*×*rule*×*jam* yang jarang pada host tertentu). Dari perspektif *explainability*, kontribusi fitur terhadap jarak dapat diringkas kembali sebagai *reason codes* yang memadai di tingkat operasional (misalnya "skor tinggi karena *off-hours* dan *rule_level_z* di atas ambang pada host ini").

2. Isolation Forest (IF)

   IF cakap untuk mendeteksi *outlier* global dan relatif efisien pada dimensi sedang, namun dapat memerlukan penyesuaian *contamination* dan terkadang kurang sensitif terhadap anomali lokal yang berada dekat sebuah klaster minor tetapi relevan secara operasional.

3. Local Outlier Factor (LOF)

   LOF efektif menyorot anomali lokal, tetapi dapat menunjukkan variabilitas yang lebih besar pada korpus dengan heterogenitas kerapatan yang tinggi antar-host atau antar-waktu, sehingga pemilihan *k* dan kebijakan pemisahan konteks (*global* atau *per-host*) menjadi penting.

Berdasarkan tujuan operasional di atas, tugas akhir ini menetapkan empat kriteria pemilihan kandidat pada tahap uji awal (lihat Subbab IV.3.1) sebelum memusatkan *tuning* di Bab V.

1) Kinerja pada *budgeted triage*. Algoritma harus menunjukkan *precision@K/p* dan *lift@p* yang meyakinkan pada *budget* realistis tim analis keamanan, misalnya *Top-p* ≈ 1 persen atau *Top-K* yang setara secara operasional. Pemilihan metrik berbasis *ranking* ini didorong oleh

keterbatasan kapasitas manusia per hari, sehingga fokus evaluasi ditempatkan pada *head-of-list* yang benar-benar ditinjau. *precision@K/p* secara langsung mengukur proporsi temuan bernilai di dalam jatah tinjau, sedangkan *lift@p* menyatakan seberapa kali lebih efektif dibanding pemilihan acak pada *p* yang sama.

2) Stabilitas antar-hari. Hasil *ranking* tidak *noisy* secara berlebihan ketika data harian berubah, sehingga tim dapat memprediksi beban kerja dan konsisten dalam *triage*.
3) Keterjelasan (*explainability*) yang memadai. Setiap skor idealnya disertai petunjuk alasan yang dapat dipahami analis (*reason codes*), agar waktu investigasi dapat dipangkas dan adopsi operasional meningkat.
4) Efisiensi komputasi dan integrasi. Algoritma harus berjalan efisien pada *batch* harian atau *near real-time* dan mudah diintegrasikan dengan *pipeline* yang telah dibangun (penyimpanan artefak skala, indeks, serta skema fitur).

Justifikasi metrik *precision@K/p* dan *lift@p* pada konteks ini adalah sebagai berikut: selaras dengan *budgeted triage* karena kapasitas tinjau dibatasi pada K *alerts*/hari atau proporsi *Top-p*, sehingga metrik ini memetakan kinerja model langsung ke jatah kerja harian; tahan terhadap *class imbalance* pada data SIEM yang jarang sehingga metrik agregat seperti *accuracy* atau bahkan *AUC-ROC* kurang representatif, sementara metrik *ranking* di *head-of-list* lebih relevan dengan dampak operasional; minim ketergantungan *threshold* dan *calibration*, sebab banyak model khususnya *unsupervised* atau *one-class* menghasilkan skor yang tidak terkalibrasi dan evaluasi berbasis *ranking* tetap konsisten meski skala skor berubah; konsisten lintas volume harian karena *Top-p* proporsional terhadap jumlah *alert* sehingga memudahkan perbandingan hari ke hari dan membantu pengendalian *workload*, sementara *Top-K* tetap dipakai ketika kapasitas tim adalah jumlah tetap per hari; komunikatif bagi pemangku kepentingan karena *lift@p* mudah dijelaskan sebagai berapa kali lebih baik dari acak pada *p* tertentu sehingga berguna untuk *SLA* dan justifikasi prioritas; serta mendukung *human-in-the-loop* karena fokus pada

puncak *ranking* memudahkan penyisipan *reason codes* serta *active learning* dari umpan balik analis sehingga perbaikan model tepat di area berdampak.

Selaras dengan karakter data (sinyal temporal/keparahan/*rarity* yang kuat dan bersifat lokal), hipotesis Kerja tugas akhir ini adalah bahwa k-NN akan memberikan keseimbangan terbaik antara kinerja *budgeted triage*, stabilitas, dan *explainability*. Namun demikian, keputusan akhir tidak diambil di sini; ia akan ditopang oleh bukti empiris pada Subbab IV.3.1 dan Bab V yang menyajikan hasil *tuning* terstruktur.

IV.3 Implementasi

Langkah berikutnya adalah mewujudkannya menjadi artefak yang dapat dijalankan. Pembahasan dimulai dari implementasi algoritma pembelajaran mesin beserta pipa data dan fitur yang menopangnya, dilanjutkan dengan perwujudan antarmuka Gradio untuk demonstrasi secara visual, lalu diakhiri dengan simulasi API untuk memberikan gambaran kasar *output* hasil inferensi ke layanan eksternal. Urutan ini menjaga benang merah dari desain ke operasi: dari log mentah, menjadi skor anomali yang dapat ditindaklanjuti, hingga antarmuka dan integrasi yang siap dipakai di lingkungan SOC.

IV.3.1 Implementasi Algoritma

Pipeline memakai *hold-out* temporal agar menyerupai operasi SIEM harian. T1 menjadi korpus pelatihan dimana seluruh transformasi (normalisasi, pemetaan skema fitur, indeks/*rarity baseline*) di-*fit* hanya pada T1, lalu dibekukan dan diterapkan apa adanya ke T2 dan T3 untuk mencegah *temporal leakage*.

Validasi dan pemilihan konfigurasi dilakukan di T2 berlabel sintetis guna memilih algoritma/*hyperparameter* dan menetapkan p atau K operasional menggunakan metrik seperti *Precision@p, Recall@p,* dan *Lift*. T2 tidak berlabel dipakai sebagai *sanity-check* non-metrik: stabilitas tingkat seleksi harian, distribusi skor, dan indikasi drift tanpa penyesuaian ulang. Setelah konfigurasi dikunci, T3 menjadi uji akhir pada periode tak terlihat. Fokus pengujian adalah untuk mengukur indikator operasional (stabilitas seleksi, pergeseran distribusi skor, dan *hit-rate* analis).

Sumber data adalah ekspor *log* SIEM yang telah dibersihkan dan dikanonisasi agar kolom inti konsisten: *timestamp* (lokal), *agent/host, decoder, rule_id, rule_level*. Tipe data ditegakkan dan nilai kosong inti ditangani eksplisit. Transformasi deterministik membentuk *FeatureVector* numerik lintas-periode dari tiga pilar sinyal: (i) temporal (jam/*off-hours/weekend*, *bucket* waktu seperlunya), (ii) *severity* (*z-score rule_level* per host dengan *clipping*), dan (iii) *rarity/novelty* (kejarangan kombinasi *agent*×*rule*×*jam* via frekuensi/log1p atau *hashing* stabil). Daftar fitur aktif (urutan, dtype, clipping) disimpan sebagai artefak dan digunakan saat inferensi ketika skema diverifikasi dan kolom hilang diisi default yang terdefinisi.

Proporsi kecil (~1–3%) sintetis disebar per hari dan memodelkan pola operasional yang penting dan berdasarkan pola kerangka kerja MITRE ATT&CK: *off-hours* tak lazim, *rule/decoder* baru pada host terkait, serta deviasi *severity* tinggi. T2 sintetis tidak pernah dipakai melatih/menyetel scaler. Fungsinya adalah untuk kalibrasi area operasi dan menimbang *trade-off* hyperparameter, bukan pengganti *ground truth* penuh, dan selalu ditafsirkan bersama temuan pada T2 tanpa injeksi.

IV.3.2 Implementasi Antarmuka Sederhana

Antarmuka berbasis Gradio diposisikan semata sebagai alat visualisasi dan demonstrasi untuk mendukung penulisan tugas akhir. Perannya adalah menampilkan ringkasan hasil inferensi model secara lengkap dari data yang sudah direkayasa menuju penilaian anomali menggunakan model yang dipilih dalam satu tampilan yang mudah diikuti. Antarmuka ini membantu verifikasi dan komunikasi hasil selama proses penulisan, bukan ditujukan sebagai antarmuka produksi

Keluaran yang disajikan berfokus pada pemahaman analis: pratinjau dataset yang telah dibersihkan dan direkayasa fitur, ringkasan skor anomali berikut irisan prioritas (*top-p%*), serta visualisasi pendukung seperti histogram distribusi skor. Selain itu, tersedia lapisan *explainability* yang menyorot kontribusi fitur dominan per *alert* (misalnya pola *off-hours*, kebaruan perilaku, atau *severity* relatif *host*), lengkap dengan pratinjau visual untuk beberapa temuan teratas guna mempercepat triase. Pendekatan ini memastikan *pipeline* yang dikembangkan dapat dipahami,

diaudit, dan didemonstrasikan saat dibutuhkan, tanpa memaparkan detail implementasi antarmuka atau menggantikan rencana integrasi operasional di masa depan.

IV.3.3 Contoh Implementasi API

Dalam tugas akhir ini, layanan dirancang sebagai API *headless* untuk menjawab kebutuhan pelaporan harian sekaligus menyiapkan jalur integrasi masa depan. Tujuannya adalah memvalidasi bahwa pendekatan pembobotan dan pemeringkatan anomali berbasis *machine learning* layak dioperasionalkan. Agar kompatibel dengan berbagai skenario *enterprise*, antarmuka dan skema respons dipertahankan stabil sehingga hasil dapat (1) diberi umpan balik ke ekosistem Wazuh, (2) ditayangkan di *dashboard* operasional, atau (3) disalurkan ke layanan otomasi seperti n8n tanpa perubahan kontrak API.

Pada tahap saat ini, layanan masih bersifat simulasi. Alur di balik layar belum menjalankan pembersihan, rekayasa fitur, atau inferensi ulang. API membaca dataset yang telah dipersiapkan (*pre-scored*) di direktori data, menerapkan penyaringan waktu berdasarkan kolom timestamp bila tersedia, kemudian menyusun peringkat dengan mengurutkan *anomaly_score* menurun dan mengambil Top-K sesuai parameter seleksi, baik *fixed* (jumlah baris tertentu) maupun *percent* (persentase dari baris yang lolos filter). Meskipun logika hulu belum aktif, struktur respons sudah "*production-like*": memuat ringkasan jendela waktu, jumlah baris sebelum/sesudah *filter*, parameter seleksi, serta jejak artefak CSV untuk peninjauan dan audit. Ketika *pipeline* penuh nanti diaktifkan, kontrak permintaan dan format hasil tidak berubah. Hal ini memastikan transisi dari simulasi ke produksi berlangsung mulus dan aplikasi hilir tetap bekerja sebagaimana adanya. Contoh keluaran API dapat dilihat pada gambar IV.21.

```
{
  "request_id": "rpt_mock_20250824_053848Z",
  "window": {
    "from": null,
    "to": null,
    "timezone": "Asia/Jakarta",
    "input_rows": 26880,
    "filtered_rows_24h": 26880
  },
  "pipeline": {
    "cleaned_rows": 26880,
    "feature_engineered_rows": 26880,
    "model": { "name": null, "version": null }
  },
  "selection": { "mode": "fixed", "value": 10, "count": 10 },
  "artifact_csv": "artifacts/top10_T3_scored_mock.csv",
  "items": [
    {
      "event_id": "703267391",
      "timestamp": "2024-08-05T12:02:09",
      "agent": "linux-agent-02",
      "rule_id": "5712",
      "decoder": "audit",
      "rule_level": 12,
      "anomaly_score": 62.83491213577441
    },
    ....
  ]
}
```


Gambar IV.21 Contoh Keluaran API

BAB V

PENGUJIAN DAN EVALUASI

V.1 Metode Pengujian

Bagian ini merangkum kerangka uji agar hasil terukur, dapat direplikasi, dan relevan untuk operasi SOC. Subbagian V.1.1 menetapkan lingkungan uji meliputi spesifikasi perangkat keras, perangkat lunak, dan dependensi sebagai dasar konsistensi. Subbagian V.1.2 menguraikan skenario dan prosedur pengujian dengan skema *hold-out* temporal dan prinsip *no-peeking*, menilai *budgeted triage* Top-K atau Top-p menggunakan metrik seperti *precision@p/K, recall@p/K,* dan *lift.*

V.1.1 Konfigurasi Sistem

Subbagian ini mendokumentasikan lingkungan uji yang digunakan agar eksperimen dapat direplikasi dan hasilnya dapat dibandingkan lintas lingkungan.

1) Perangkat keras host eksperimen

Tabel V.1 merangkum spesifikasi mesin lokal yang digunakan untuk pembersihan data, rekayasa fitur, pelatihan model pembelajaran mesin, dan inferensi.

Tabel V.1 Spesifikasi Teknis Perangkat Keras Pengembangan

Komponen	**Spesifikasi**
Sistem operasi	Windows 11 Pro 64-bit
Prosesor	Intel® Core™ i5-12600K
Memori	32 GB DDR4
GPU	NVIDIA GeForce RTX 3070
Penyimpanan	1 TB NVMe (utama), 1 TB HDD (arsip/*by-product*)
Jaringan	Ethernet Cat6; Wi-Fi 5; Intel® Wi-Fi 6 AX201 (160 MHz)

2) Pustaka Pemrograman Yang Digunakan

Tabel V.2 mendokumentasikan seluruh pustaka yang digunakan selama implementasi beserta alasan penggunaannya dalam konteks tugas akhir.

Tabel V.2 Pustaka Eksternal Python (PyPI)

Pustaka	**Nama *import***	**Versi terbaru**	**Alasan penggunaan**
pandas	pandas	2.3.2	Inti *data wrangling*: baca/tulis CSV, *merge*, *groupby*, manipulasi *timestamp*, normalisasi skema kanonik, pembentukan *feature vector* untuk model.
NumPy	numpy	2.3.2	Operasi numerik tervektorisasi, tipe *array* efisien, utilitas acak untuk validasi sintetis T2.
Matplotlib	matplotlib	3.10.5	Visualisasi EDA dan pelaporan: histogram, *precision–recall* curve, *heatmap* jam×hari.
scikit-learn	sklearn	1.7.1	Algoritma dan API pemodelan: Isolation Forest, k-NN, LOF, *preprocessing*, dan metrik evaluasi.
joblib	joblib	1.5.1	*Serialization* dan *caching* model/array, paralelisasi ringan saat *feature scoring* dan inferensi.
Gradio	gradio	5.43.1	Antarmuka web untuk *pipeline upload CSV → clean → feature engineering → inferensi* beserta tampilan *explainability*.
FastAPI	fastapi	0.116.1	Membangun layanan API berbasis ASGI (pendefinisian rute, penanganan request/response).
Pydantic	pydantic	2.11.7	Validasi dan pemodelan data berbasis *type hints* agar payload terstruktur.
Uvicorn	uvicorn	0.35.0	Server ASGI untuk menjalankan aplikasi FastAPI.

Selain itu terdapat beberapa modul yang berasal dari Pustaka Standar Python (Versi Python yang digunakan adalah 3.13.5), disertakan pada tabel V.3 demi kelengkapan dan alasan kegunaannya di kode.

Tabel V.3 Pustaka Internal Python

Modul	**Alasan penggunaan**
argparse	Antarmuka baris perintah untuk argumen input, direktori keluaran, dan parameter evaluasi.
ast	*Parsing* literal atau ekspresi sederhana yang aman pada utilitas EDA.
collections	Struktur data efisien seperti Counter dan defaultdict untuk agregasi cepat.
dataclasses	Deklarasi *data container* sederhana, misalnya menyimpan opsi aplikasi.
datetime	Ekstraksi fitur temporal seperti jam lokal, *off-hours*, hari dalam pekan, serta *windowing* waktu.
glob	Pencarian berkas dengan pola *wildcard* saat menggabungkan banyak CSV.
hashlib	Pembuatan *hash* stabil untuk ID atau kunci *cache* artefak.
io	*Buffer* memori untuk berkas atau figur tanpa menulis sementara ke disk.
json	Baca tulis artefak konfigurasi dan hasil.
math	Fungsi matematis umum untuk perhitungan skor dan fitur.
os	Operasi sistem berkas, pembuatan direktori, dan penanganan path tingkat OS.
pathlib	Penanganan path berbasis objek yang lebih rapi daripada string mentah.
pickle	*Serialization* objek Python sederhana, pelengkap joblib.
random	*Sampling* deterministik atau acak untuk injeksi anomali sintetis.

Tabel V.3 lanjutan Pustaka Internal Python

Modul	**Alasan penggunaan**
Re	*Regular expression* untuk pembersihan kolom dan *pattern matching*.
sys	*Exit code*, akses argumen mentah, dan kendali aliran output.
typing	*Type hints* untuk keterbacaan dan dukungan tooling.
warnings	Menonaktifkan peringatan non-kritis saat pelatihan atau inferensi.
zipfile	Mengemas keluaran EDA dan figur ke arsip ZIP untuk dokumentasi.

V.1.2 Skenario Pengujian

Evaluasi diarahkan pada kebutuhan *budgeted triage*: model dinilai bukan pada seluruh korpus, melainkan pada irisan kecil yang memang dibaca analis setiap hari. Tugas akhir menggunakan dua cara pemotongan hasil pemeringkatan skor anomali: *Top-p* (persentase teratas) dan *Top-K* (sejumlah tetap). Seluruh metrik dihitung hanya pada irisan tersebut per hari. Seluruh proses mengikuti *hold-out temporal* dan prinsip *no-peeking*: artefak skala dan skema fitur di-*fit* pada T1 dan diaplikasikan apa adanya ke T2/T3.

Metrik utama adalah *precision@p/K*, yaitu proporsi temuan benar di irisan yang benar-benar dibaca analis. Metrik ini langsung memetakan nilai bersih yang diterima tim. *Recall@p/K* melengkapi pembacaan dengan menunjukkan seberapa banyak kejadian relevan yang terangkat pada *budget* yang sama. Untuk menormalkan variasi *base rate* harian, kami melaporkan *lift@p* (seberapa kali lebih baik daripada memilih acak). Untuk mengendalikan kebisingan, kami sertakan *FPR@p/K* sebagai indikasi seberapa banyak negatif yang ikut masuk irisan. Aspek stabilitas dibaca dari sebaran harian *precision/lift* agar beban kerja dan kualitas hasil tidak berfluktuasi tanpa alasan.

Pelaporan disajikan dari dua perspektif agar mudah dioperasionalkan: *Top-p* (khususnya *Top-1%* sebagai titik operasi utama) dan *Top-K* (misalnya K=25/50/100) agar hasil bisa langsung diterjemahkan ke kapasitas tim. Dengan

kerangka ini, metrik yang dilaporkan tetap singkat, bermakna, dan siap dipakai untuk pengambilan keputusan *triage*.

V.2 Hasil Evaluasi

Setelah protokol uji, skema *hold-out* temporal, dan metrik *budgeted triage* ditetapkan pada bagian sebelumnya, fokus kini beralih pada temuan untuk menjawab pertanyaan "bagaimana model menyeleksi irisan prioritas harian dan seberapa konsisten presisi, recall, serta lift lintas hari?" Pembacaan dimulai dengan ringkasan perbandingan performa beberapa model, penilaian kinerja inti dan pola *Top-K/Top-p*, lalu ditautkan ke interpretasi operasional yang menyoroti stabilitas, pergeseran distribusi skor, dan implikasinya bagi alur triase.

V.2.1 Evaluasi *Hyperparameter Tuning* dan Pemilihan Model

Bagian ini menampilkan ringkasan konfigurais terbaik masing-masing algoritma pada titik operasi yang telah ditetapkan (misal p=1%), lalu membacanya dari perspektif *budgeted triage*. Sumber data adalah ringkasan *best-of-each* yang didokumentasikan selama proses pelatihan.

Ringkasan *best-of-each* pada tabel V.4 secara konsisten menunjukkan k-NN sebagai pemenang operasional di p yang disepakati, dengan *precision@p* dan *lift@p* tertinggi. *Isolation Forest* cenderung menjadi pilihan kedua karena kuat pada *outlier* global namun kurang tajam untuk keanehan lokal yang dekat dengan klaster minor. LOF memberi hasil baik pada beberapa hari, tetapi varians antar-hari lebih besar pada korpus dengan heterogenitas *density* antargroup *host/decoder*. Implikasi praktisnya jelas: untuk *budgeted triage* yang menuntut presisi tinggi di *slice* kecil, k-NN mendominasi.

Tabel V.4 *Best-of-each* Algoritma pada p Operasi

Algoritma	**Konfigurasi**	***Precision@p***	***Recall@p***	***Lift@p***	***FPR@p***
k-NN	{'n_neighbors': 35}	0,6801	0,2340	23.34	0.0033
IF	{'n_estimators' : 600, 'max_samples': 0.5, 'max_features': 0.8, 'bootstrap': True}	0.4032	0.1388	13.84	0.0061
LOF	{'n_neighbors': 20}	0.3010	0.1036	10.33	0.0072

Algoritma k-Nearest Neighbors (k-NN) menunjukkan performa yang dominan pada metrik presisi maupun *lift*, serta relatif stabil antar-hari. Sementara itu, Isolation Forest terbukti efektif dalam mendeteksi *outlier* global, meskipun kurang unggul ketika dihadapkan pada anomali yang bersifat lokal. Berbeda dengan keduanya, Local Outlier Factor (LOF) menghasilkan performa yang lebih variatif dan cenderung sensitif terhadap heterogenitas *density* dalam data.

Untuk menambah klarifikasi terhadap dasar penilaian model, dikembangkan fitur *explainability* dengan menggunakan *reason codes* untuk menampilkan alasan di balik skor anomali pada beberapa peringkat teratas. Hal ini merupakan unsur yang sangat penting untuk adopsi operasional, karena analis membutuhkan konteks "mengapa ini naik ke atas". Tabel V.5 menampilkan contoh 5 anomali dengan skor tertinggi yang dilakukan pada T3.

Tabel V.5 Ringkasan 5 Anomali dengan Nilai Fitur Paling Tinggi

Urutan	**ID *Alert***	**Skor Anomali**	**Skor Tiga Fitur Teratas**
1	cQwFkJgB_cd9Tf92i-yN	54,1279	[{""feature"": ""rule_time_since_last_host"", ""contrib_scaled"": 914.8321660830443, ""abs_diff"": 3657.4990000000107, ""neighbor_median"": 125979.071}, {""feature"": ""weekend_x_rule_level_z"", ""contrib_scaled"": 16.472005407318715, ""abs_diff"": 16.472005407318715, ""neighbor_median"": 0.0}, {""feature"": ""offhours_x_rule_level_z"", ""contrib_scaled"": 16.472005407318715, ""abs_diff"": 16.472005407318715, ""neighbor_median"": 0.0}, …]
2	cwwFkJgB_cd9Tf92i-yN	53,2052	[{""feature"": ""weekend_x_rule_level_z"", ""contrib_scaled"": 16.472005407318715, ""abs_diff"": 16.472005407318715, ""neighbor_median"": 0.0}, {""feature"": ""offhours_x_rule_level_z"", ""contrib_scaled"": 11.828996058087785, ""abs_diff"": 11.828996058087785, ""neighbor_median"": 4.64300934923093}, {""feature"": ""rule_level_z_host"", ""contrib_scaled"": 7.834592299477884, ""abs_diff"": 11.828996058087785, ""neighbor_median"": 4.64300934923093},..]
3	cgwFkJgB_cd9Tf92i-yN	53,1947	[{""feature"": ""weekend_x_rule_level_z"", ""contrib_scaled"": 16.472005407318715, ""abs_diff"": 16.472005407318715, ""neighbor_median"": 0.0}, {""feature"": ""offhours_x_rule_level_z"", ""contrib_scaled"": 11.828996058087785, ""abs_diff"": 11.828996058087785, ""neighbor_median"": 4.64300934923093}, {""feature"": ""rule_level_z_host"", ""contrib_scaled"": 7.834592299477884, ""abs_diff"": 11.828996058087785, ""neighbor_median"": 4.64300934923093},..]

Tabel V.5 lanjutan 5 Anomali dengan Nilai Fitur Kontributor Paling Tinggi

Urutan	**ID *Alert***	**Skor Anomali**	**Skor Tiga Fitur Teratas**
4	dAwFkJgB_cd9Tf92i-yN	53,1772	[{""feature"": ""weekend_x_rule_level_z"", ""contrib_scaled"": 16.472005407318715, ""abs_diff"": 16.472005407318715, ""neighbor_median"": 0.0}, {""feature"": ""offhours_x_rule_level_z"", ""contrib_scaled"": 11.828996058087785, ""abs_diff"": 11.828996058087785, ""neighbor_median"": 4.64300934923093}, {""feature"": ""rule_level_z_host"", ""contrib_scaled"": 7.834592299477884, ""abs_diff"": 11.828996058087785, ""neighbor_median"": 4.64300934923093},..]
5	rwzcjZgB_cd9Tf92geSI	48,1241	[{""feature"": ""rule_time_since_last_host"", ""contrib_scaled"": 1068.7888944472263, ""abs_diff"": 4273.018000000011, ""neighbor_median"": 141540.931}, {""feature"": ""weekend_x_rule_level_z"", ""contrib_scaled"": 16.45132492344261, ""abs_diff"": 16.45132492344261, ""neighbor_median"": 0.0}, {""feature"": ""rule_level_z_host"", ""contrib_scaled"": 11.471220215455588, ""abs_diff"": 17.31972941580176, ""neighbor_median"": 0.8684044923591503}, ...]

Untuk memvisualisasikan kontribusi tiap fitur ke dalam nilai akhir anomaly, Gambar V.9 dan V.10 menampilkan *reason codes* sebagai dasar penilaian anomali tersebut untuk peringkat pertama, dan ketiga.

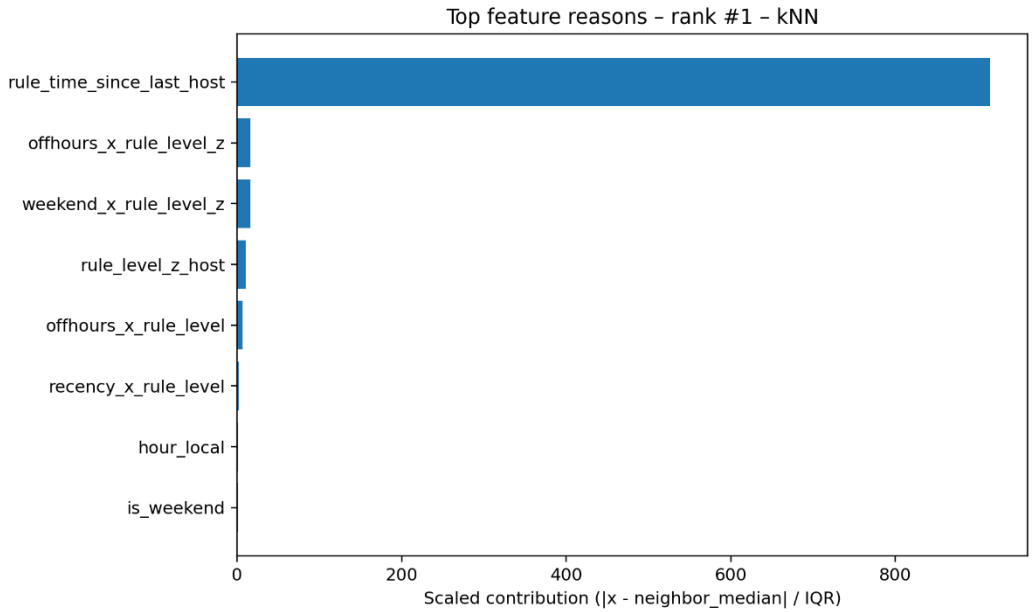

Gambar V.1 Visualisasi Penilaian Anomali Peringkat ke-1

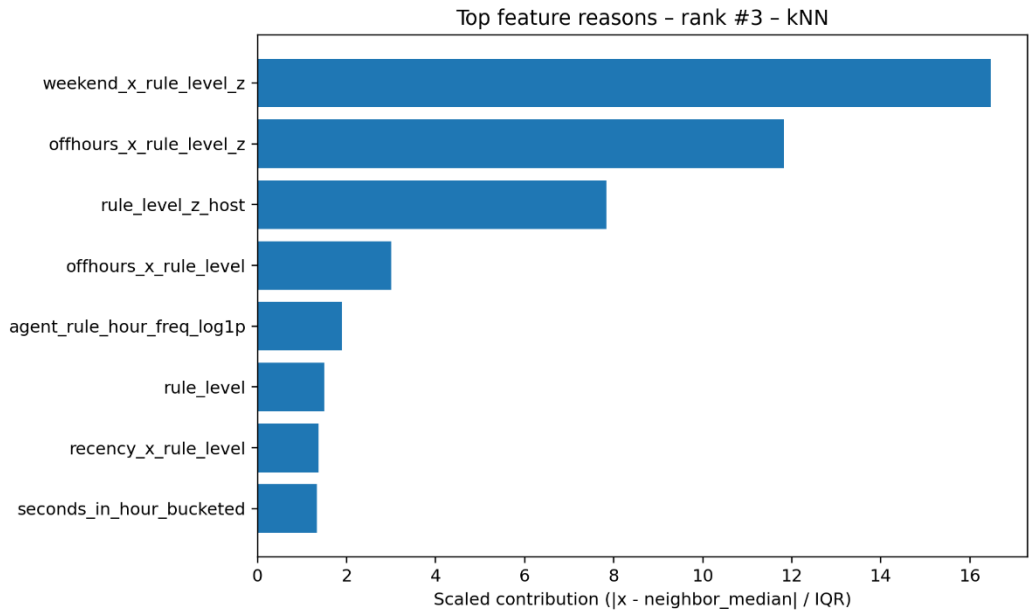

Gambar V.2 Visualisasi Penilaian Anomali Peringkat ke-3

Untuk menunjukkan kontras antara nilai anomali tertinggi dan paling rendah, Tabel V.6 menampilkan contoh 5 anomali dengan skor paling rendah yang dilakukan pada T3.

Tabel V.6 Ringkasan 5 Anomali dengan Nilai Fitur Paling Rendah

Urutan	**ID**	**Skor**	**Skor Tiga Fitur Teratas**
1	cAwihpgB_cd9Tf9228Na	0,4573	[{""feature"": ""agent_rule_hour_freq_log1p"", ""contrib_scaled"": 0.38237239528842365, ""abs_diff"": 0.5824050752264434, ""neighbor_median"": 8.155936337972394}, {""feature"": ""offhours_x_rule_level_z"", ""contrib_scaled"": 0.055679832391584694, ""abs_diff"": 0.055679832391584694, ""neighbor_median"": -0.6414374503895616}, {""feature"": ""rule_level_z_host"", ""contrib_scaled"": 0.03687792133408211, ""abs_diff"": 0.055679832391584694, ""neighbor_median"": -0.6414374503895616},.]
2	cQwihpgB_cd9Tf9228Na	0,4573	[{""feature"": ""agent_rule_hour_freq_log1p"", ""contrib_scaled"": 0.38237239528842365, ""abs_diff"": 0.5824050752264434, ""neighbor_median"": 8.155936337972394}, {""feature"": ""offhours_x_rule_level_z"", ""contrib_scaled"": 0.055679832391584694, ""abs_diff"": 0.055679832391584694, ""neighbor_median"": -0.6414374503895616}, {""feature"": ""rule_level_z_host"", ""contrib_scaled"": 0.03687792133408211, ""abs_diff"": 0.055679832391584694, ""neighbor_median"": -0.6414374503895616},.]
3	cgwihpgB_cd9Tf9228Na	0,4574	[{""feature"": ""agent_rule_hour_freq_log1p"", ""contrib_scaled"": 0.38237239528842365, ""abs_diff"": 0.5824050752264434, ""neighbor_median"": 8.155936337972394}, {""feature"": ""offhours_x_rule_level_z"", ""contrib_scaled"": 0.055679832391584694, ""abs_diff"": 0.055679832391584694, ""neighbor_median"": -0.6414374503895616}, {""feature"": ""rule_level_z_host"", ""contrib_scaled"": 0.03687792133408211, ""abs_diff"": 0.055679832391584694, ""neighbor_median"": -0.6414374503895616},.]

Tabel V.6 lanjutan Ringkasan 5 Anomali dengan Nilai Fitur Paling Rendah

Urutan	**ID**	**Skor**	**Skor Tiga Fitur Teratas**
4	kQzoh ZgB_cd 9Tf92_ cLz	0, 4609	[{""feature"": ""agent_rule_hour_freq_log1p"", ""contrib_scaled"": 0.38237239528842365, ""abs_diff"": 0.5824050752264434, ""neighbor_median"": 8.155936337972394}, {""feature"": ""offhours_x_rule_level_z"", ""contrib_scaled"": 0.055679832391584694, ""abs_diff"": 0.055679832391584694, ""neighbor_median"": -0.6414374503895616}, {""feature"": ""rule_level_z_host"", ""contrib_scaled"": 0.03687792133408211, ""abs_diff"": 0.055679832391584694, ""neighbor_median"": -0.6414374503895616},.]
5	kwzoh ZgB_cd 9Tf92_ cLz	0, 4610	[{""feature"": ""agent_rule_hour_freq_log1p"", ""contrib_scaled"": 0.38237239528842365, ""abs_diff"": 0.5824050752264434, ""neighbor_median"": 8.155936337972394}, {""feature"": ""offhours_x_rule_level_z"", ""contrib_scaled"": 0.055679832391584694, ""abs_diff"": 0.055679832391584694, ""neighbor_median"": -0.6414374503895616}, {""feature"": ""rule_level_z_host"", ""contrib_scaled"": 0.03687792133408211, ""abs_diff"": 0.055679832391584694, ""neighbor_median"": -0.6414374503895616}, {""feature"": ""rule_time_since_last_host_log1p"", ""contrib_scaled"": 0.0006224085356505143, ""abs_diff"": 0.0009985023295894999, ""neighbor_median"": 0.001998002662673}, ...]

Skor anomali yang dihasilkan oleh model tidak merepresentasikan skala absolut tertentu (misalnya 1–10 atau 1–100), melainkan merupakan nilai relatif terhadap distribusi perilaku normal yang dipelajari pada data latih. Dengan kata lain, skor ini tidak memiliki satuan baku, tetapi menunjukkan seberapa jauh sebuah peristiwa menyimpang dibandingkan mayoritas data historis. Oleh karena itu, interpretasi skor tidak dilakukan secara mandiri pada angka mentah, melainkan melalui posisi relatifnya dalam distribusi. Sebagai contoh, skor sebesar 54 hanya dapat dimaknai

sebagai “sangat tinggi” karena ia berada pada ekor distribusi skor di dataset uji, bukan karena angka 54 itu sendiri memiliki arti absolut.

Dalam praktik operasional, hal ini ditangani dengan pendekatan *ranking-based evaluation*, yakni memilih sejumlah kecil peristiwa dengan skor tertinggi (misalnya *Top-K* atau *Top-p%*). Pendekatan ini memastikan konsistensi lintas *dataset* dan periode waktu tanpa bergantung pada batasan angka tertentu. Dengan demikian, sistem tidak menjawab apakah sebuah skor “besar atau kecil” secara absolut, melainkan memastikan bahwa peristiwa dengan skor relatif paling ekstremlah yang diprioritaskan untuk ditinjau analis. Pendekatan ini diperkuat dengan mekanisme *explainability* berupa *reason codes* yang menampilkan fitur-fitur utama penyumbang skor, sehingga analis tidak hanya melihat peringkat anomali, tetapi juga memahami konteks mengapa peristiwa tersebut dipandang menyimpang

Reason codes semacam ini mempercepat *triage*, sebab analis tidak memulai dari nol: mereka langsung melihat tiga alasan teratas yang terukur di ruang fitur. Pada *defense*, bukti ini menegaskan bahwa model bukan “kotak hitam”, melainkan penambah daya fokus *attention* manusia.

Berdasarkan keseluruhan bukti, tuning *Top-p*, terjemahan *Top-K* operasional, pembanding IF/LOF, dan *reason codes*, tugas akhir ini menetapkan k-NN sebagai model prioritisasi alert untuk konteks data SIEM ini.

V.2.2 Evaluasi Desain Eksperimen dan Hasil Tuning k-NN (Top-p)

Evaluasi dilakukan pada set validasi T2 dengan *hold-out temporal*, sedangkan artefak *fit* (skema fitur, *scaler*, indeks/model) dibekukan dari T1 dan tidak pernah diadaptasi berdasarkan T2 untuk mencegah *temporal leakage*. Unit evaluasi adalah harian; skor anomali diurutkan menurun dan diambil irisan Top-p sebagai *budgeted triage* (mis. p=1%). Seluruh metrik dihitung pada irisan tersebut dan diringkas lintas hari. Secara operasional, p dipilih untuk merefleksikan kapasitas harian tim analis. Pada bagian ini, kami menilai perilaku k-NN di $p \in \{0{,}5\%, 1\%, 2\%, 3\%\}$ sebelum mematok titik operasi utama (1%). Tabel V.7 menyajikan kinerja k-NN di

p = 1% untuk berbagai nilai k. Angka-angka diekstraksi dari *log* pelatihan, dengan jumlah irisan harian selected = 372 (≈ 1% dari N harian di T2).

Tabel V.7 Hasil k-NN di p = 1% (Top-1% per hari)

k	**precision@1%**	**recall@1%**	**lift@1%**	**FPR@1%**
5	0,663978	0,228492	22,789634	0,003470
8	0,666667	0,229417	22,881899	0,003442
10	0,669355	0,230342	22,974165	0,003415
15	0,677419	0,233117	23,250962	0,003331
20	0,672043	0,231267	23,066431	0,003387
35	**0,680108**	**0,234043**	**23,343228**	**0,003304**
50	0,674731	0,232192	23,158697	0,003359
75	0,666667	0,229417	22,881899	0,003442
100	0,658602	0,226642	22,605102	0,003526

Berdasarkan data pada tabel V.7 terdapat puncak presisi pada k=35 dengan *precision@1%* = 0,6801 dan *lift@1%* = 23,34× terhadap *prevalence* harian. Artinya, dari 372 alert yang benar-benar dibaca per hari, sekitar 253 adalah temuan relevan (TP) dan 119 *false positive* (FP), sehingga rasio "bersih" (TP:FP) ≈ 2,13 : 1. Kedua, *FPR@1%* tetap rendah (≈ 0,33%) yang merupakan proporsi *non-anomali* yang masuk ke irisan di antara semua negatif, sehingga "kebisingan" yang lolos *filter* tetap terkendali. Ketiga, dibanding k kecil (5–10), k=35 memberi *trade-off* yang seimbang: presisi sedikit lebih tinggi tanpa pengorbanan besar pada *recall*. Terakhir, k yang terlalu besar (75–100) cenderung meratakan *locality* sehingga presisi menurun, selaras dengan ekspektasi teori k-NN (*over-smoothing*).

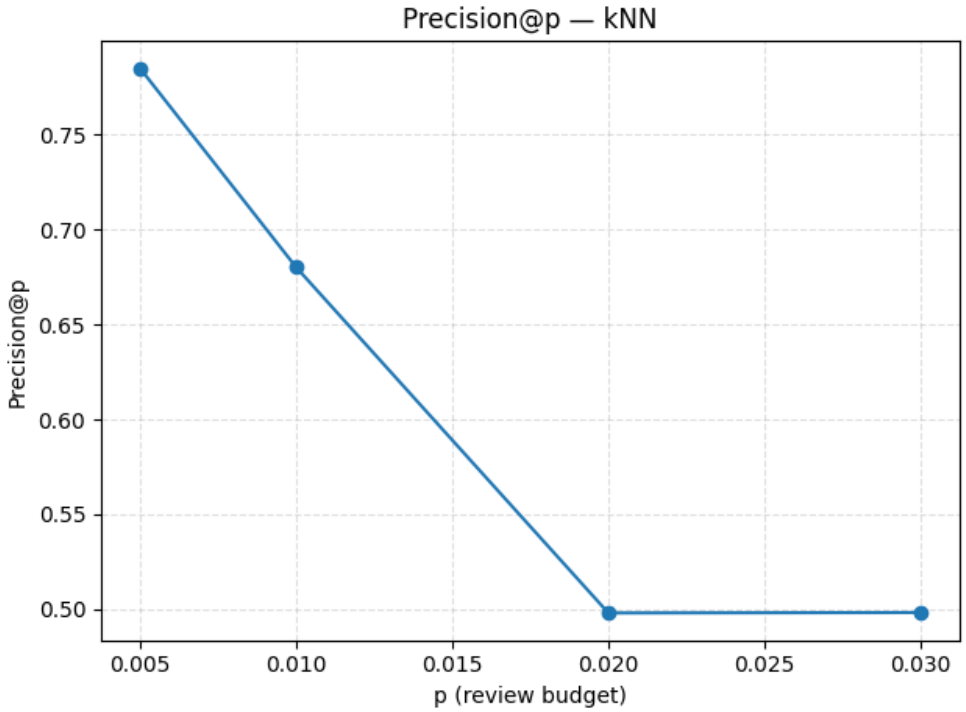

Gambar V.3 *Precision-vs-p* untuk k-NN

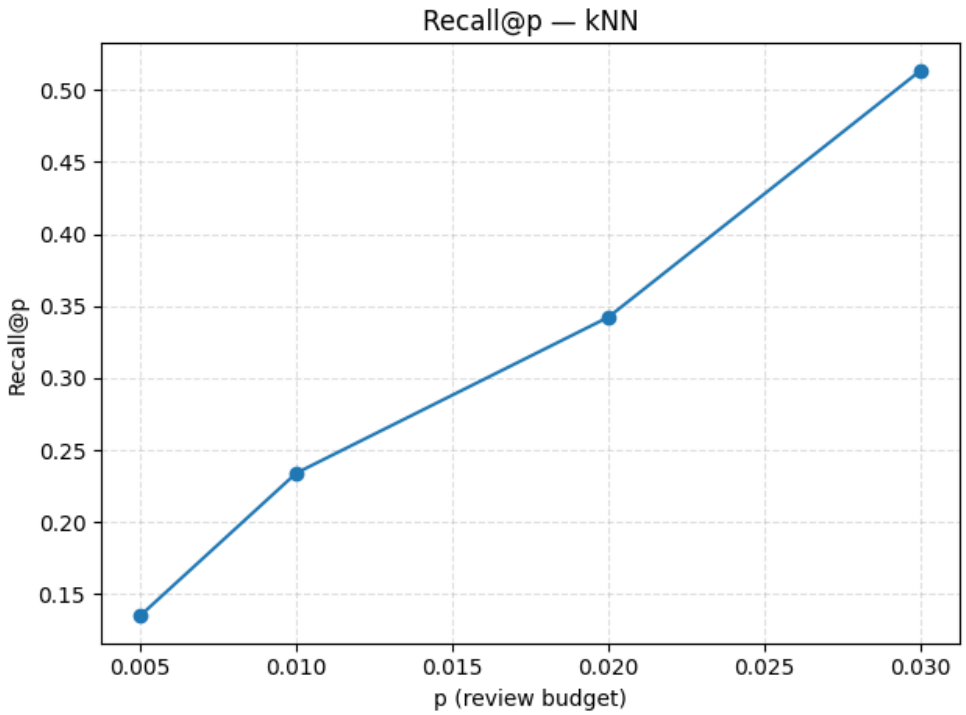

Gambar V.4 *Recall-vs-p* untuk k-NN

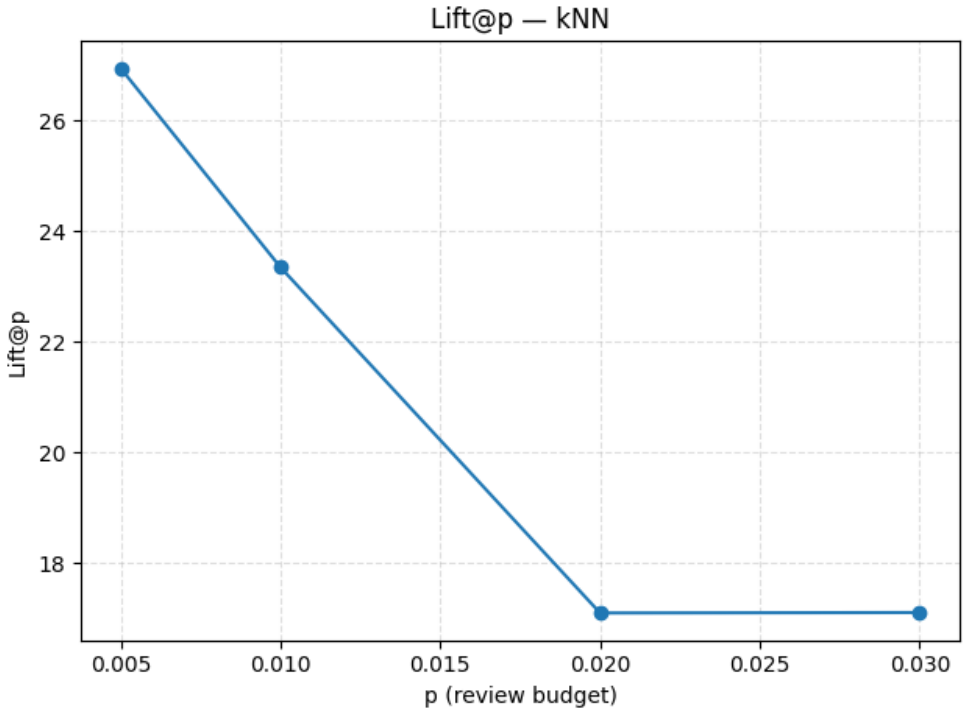

Gambar V.5 *Lift-vs-p* untuk k-NN

Gambar V.3 sampai V.5 memperlihatkan kurva tren terhadap p. Pada rentang p kecil (≤ 1%), kurva *precision* terhadap p menurun secara wajar karena irisan semakin lebar, sedangkan kurva *recall* terhadap p meningkat. Kurva *lift* terhadap p menurun karena pembilang (presisi) turun lebih cepat dibanding *base rate*. Namun, pada p = 1% nilainya masih di atas 23×, yang secara operasional berarti *return on attention* analis jauh lebih tinggi dibanding membaca acak. Untuk menunjukkan *robustness* pemilihan k lintas *budget*, Tabel V.8 merangkum konfigurasi per p.

Tabel V.8 *Best-of-k* per p

p	**k terbaik**	**precision@p**	**recall@p**	**lift@p**	**FPR@p**
0,5%	5	0,811828	0,139685	27,864249	0,000972
1%	**35**	**0,680108**	**0,234043**	**23,343228**	**0,003304**
2%	50	0,503365	0,345976	17,276912	0,010244
3%	35	0,498205	0,513414	17,099804	0,015518

Di p = 0,5%, presisi mencapai 0,812 (dengan k=5), cocok jika organisasi ingin irisan *sangat kecil* demi akurasi maksimum. Namun *recall* menjadi rendah (≈ 0,14). Di p = 1%, konfigurasi k = 35 unggul dan memberi keseimbangan yang baik untuk operasi harian: presisi tinggi (0,68), *lift* besar (23,34×), dan *recall* meningkat ke 0,234. Di p = 2–3%, *recall* bertambah pesat tetapi presisi/lift turun, selaras dengan prinsip *budgeted triage*. Dengan demikian, p = 1% merupakan titik operasi realistis yang memaksimalkan nilai (tinggi *lift*, presisi memadai) tanpa menjadikan beban kerja meledak.

Pemilihan p = 1% sebagai titik operasi utama didukung tiga alasan empiris:

1) Kinerja dan ROI atensi. Pada p = 1% dan konfigurasi model k = 35, precision@p = 0,6801 dan lift@p = 23,34×. Ini berarti 23 kali lebih baik dari pembacaan acak terhadap *base rate* hariannya. Sebagai konsekuensi, lebih dari dua-pertiga dari irisan bacaan harian benar-benar relevan bagi analis.

2) Keseimbangan cakupan. *Recall@1%* = 0,234 menunjukkan bagian bermakna dari temuan menarik tetap terangkat tanpa memperbesar irisan secara berlebihan. Dibanding p = 0,5%, peningkatan *recall* ini nyata dengan penurunan presisi yang terbatas.

3) Konsistensi operasional. *FPR@1%* ≈ 0,33% menunjukkan *noise* yang lolos ke irisan relatif rendah; di sisi lain, *selection-rate stability* sangat kecil (orde 1e-5), yang secara kualitatif menandakan stabilitas proses pemilihan irisan antar-hari.

Hasil ini membuktikan bahwa, pada kerangka *Top-p*, k-NN mencapai kinerja terbaik pada p = 1% dengan konfigurasi k = 35, memberikan *precision* ≈ 0,68, lift ≈ 23,34×, dan FPR rendah (≈0,33%). Temuan ini konsisten dengan hipotesis bahwa sinyal *rarity* dan temporal/keparahan bersifat lokal, sehingga pendekatan *local distance* seperti k-NN sangat efektif. Evaluasi berikutnya mengonversi titik operasi ini ke bahasa operasional *Top-K* (K=25/50/100), lalu menilai stabilitas praktisnya,

V.2.3 Evaluasi *Budgeted Triage* dengan K Tetap untuk Lingkungan Operasional

Pada praktik SOC, kapasitas telaah harian sering dinyatakan dalam jumlah tiket/alert yang realistis dibaca per analis per hari, bukan dalam persentase. Oleh karena itu, selain evaluasi *Top-p* (misalnya p=1%), tugas akhir ini juga menyajikan *budgeted triage* dalam K tetap (misalnya K=25, K=50, K=100 alert/hari). Pendekatan ini mempermudah *capacity planning*: pemangku kepentingan dapat langsung memproyeksikan berapa banyak *true positive* (TP) dan *false positive* (FP) yang masuk ke meja analis tiap hari untuk sebuah pilihan K tertentu, serta menimbang *trade-off* antara ketelitian dan cakupan.

Secara matematis, untuk hari ke-d dengan *alert* sebanyak N_d, evaluasi *Top-K* mengambil irisan berukuran K setelah mengurutkan skor anomali secara menurun. Seluruh metrik (precision, recall, *lift*, FPR) dihitung pada irisan ini dan diringkas lintas hari uji. Dengan demikian, *Top-K* setara dengan *Top-p* harian dengan $p_d=K/N_d$ yang adaptif terhadap variasi volume harian; hal ini dijelaskan eksplisit pada narasi berikut. Tabel V.9 merangkum metrik inti pada masing-masing K pada model yang terpilih.

Tabel V.9 Ringkasan Kinerja k-NN pada K tetap

K	Precision	Recall	Lift	FPR	TP	FP	FN	TN
25	0,84	0,0194	28,83	0,0001	21	4	1060	36018
50	0,84	0,0388	28,83	0,0002	42	8	1039	36014
100	0,64	0,0592	21,97	0,0009	64	36	1017	35986

Secara umum, *precision* menurun perlahan ketika K bertambah (karena irisan menjadi lebih lebar), sementara *recall* meningkat (cakupan makin luas). *Lift* menunjukkan perilaku serupa dengan *precision* (karena penomoran terhadap *prevalence*), sedangkan FPR cenderung meningkat seiring membesarnya irisan adalah sebuah konsekuensi yang dapat diterima apabila K yang dipilih sesuai kapasitas tim. Pada K yang lebih kecil (misalnya 25), rasio TP:FP biasanya paling

menguntungkan; pada K menengah (50), *trade-off* presisi vs cakupan sering kali paling seimbang; dan pada K besar (100), tim memperoleh lebih banyak temuan (recall naik) dengan harga peningkatan *noise* yang terkendali.

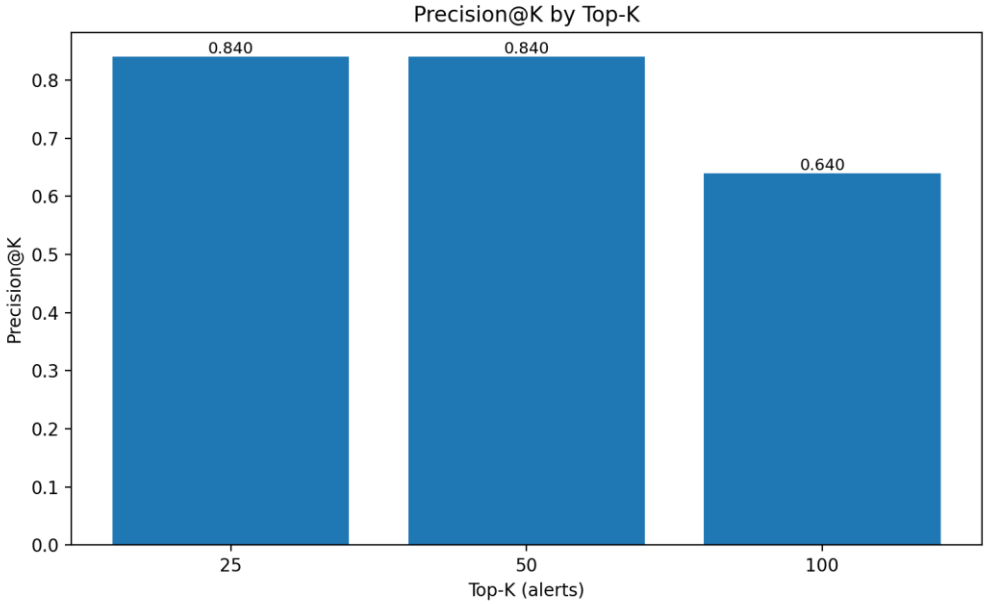

Gambar V.6 Grafik *Precision* pada K tetap (*Precision@K*)

Gambar V.6 menunjukkan penurunan *precision* yang tidak drastis dari K=25 ke K=100, menandakan bahwa ranking k-NN tetap tajam meskipun irisan diperlebar. Secara operasional, hal ini mengindikasikan bahwa tim dapat menaikkan kuota bacaan tanpa kehilangan terlalu banyak kualitas hasil.

Pada Gambar V.7, dapat dilihat bahwa *Recall* meningkat konsisten seiring bertambahnya K. Kenaikan ini penting untuk mencegah *missed opportunity* pada hari dengan volume kejadian menarik yang lebih tinggi. Pilihan K=50 sering menjadi titik tengah yang memberikan peningkatan *recall* signifikan dari K=25, dengan penurunan *precision* yang masih terkendali.

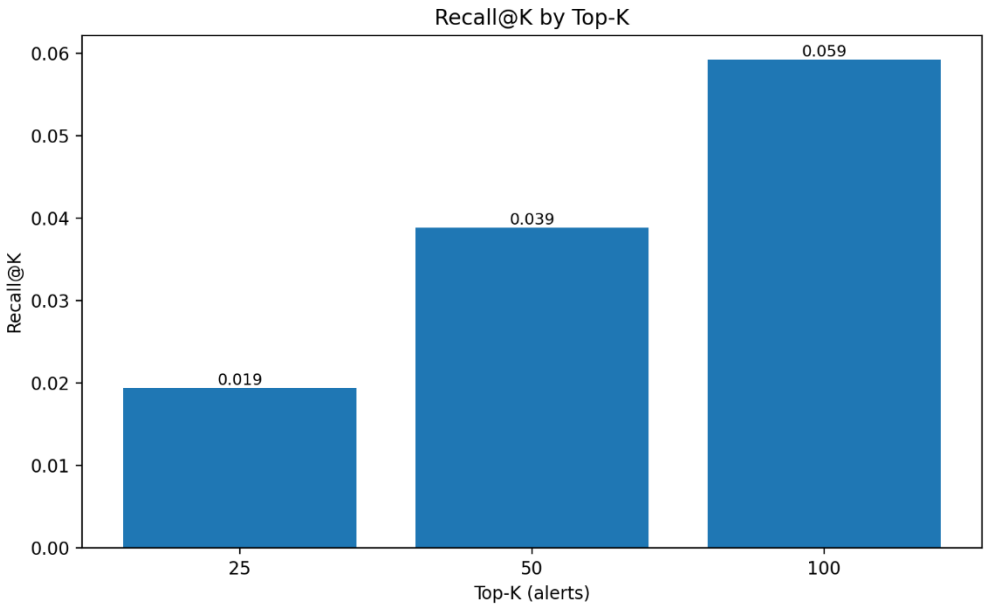

Gambar V.7 Grafik Perbandingan *Recall* pada K tetap (*Recall@K*)

Pada Gambar V.8 meskipun *lift* menurun saat K bertambah, karena *precision* di pembilang melemah relatif terhadap *prevalence*, pada K yang realistis (25–50) nilainya tetap jauh di atas 1, menandakan efisiensi prioritisasi yang berlipat dibanding pembacaan acak.

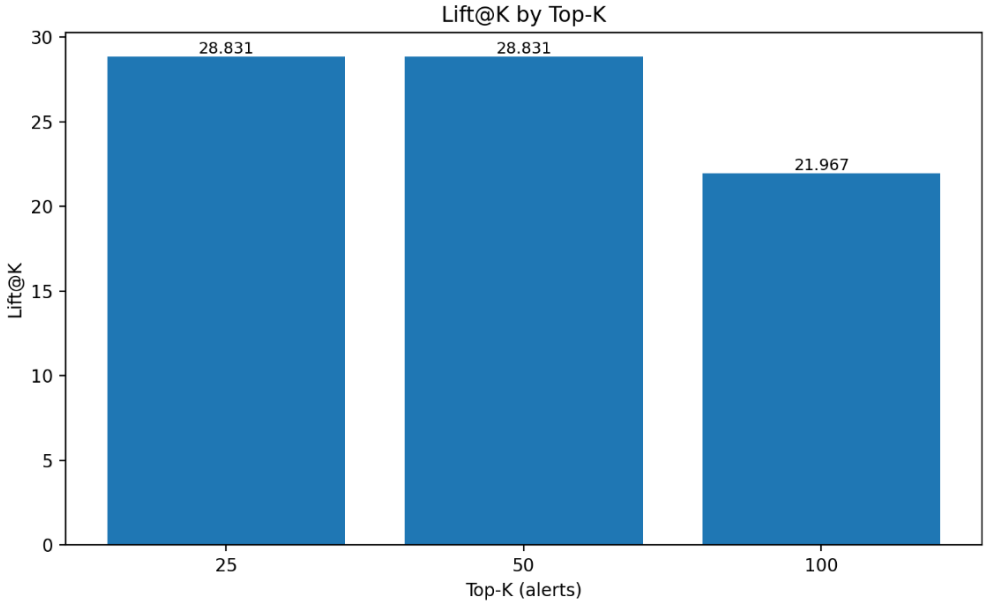

Gambar V.8 Grafik Perbandingan *Lift* pada K tetap (*Lift@K*)

Peningkatan FPR seiring peningkatan K sebagaimana digambarkan pada gambar V.9 adalah hal yang wajar dikarenakan irisan lebih lebar membawa lebih banyak negatif yang terangkat (*false positive*). Namun pada rentang K yang realistis, FPR tetap rendah, sehingga *noise* tambahan masih dapat ditoleransi oleh prosedur *triage*.

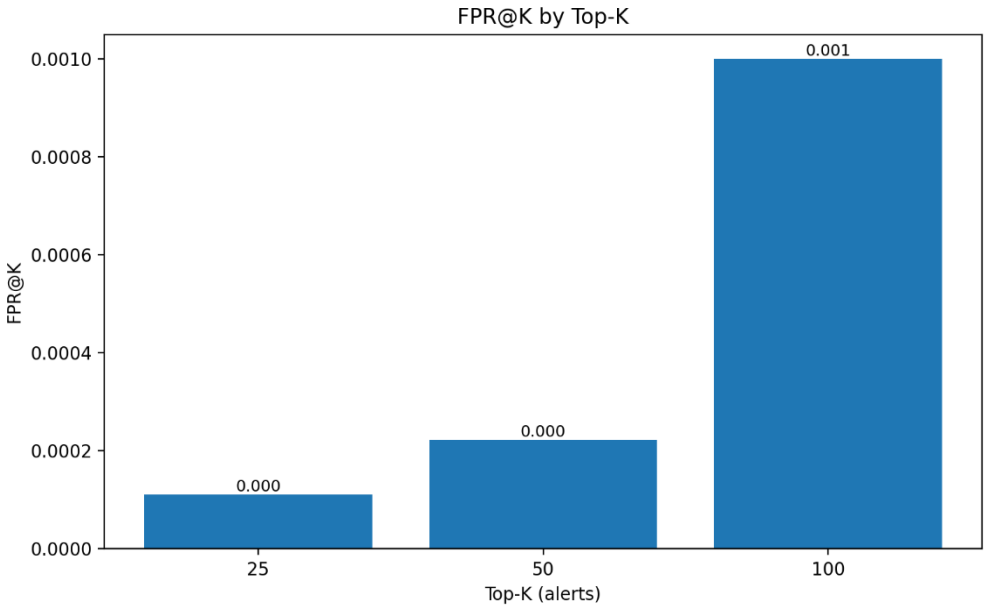

Gambar V.9 Grafik Perbandingan *FPR* pada K tetap (*FPR@K*)

Gambar V.10 sangat berguna untuk pihak manajemen SOC untuk melihat berapa TP dan FP yang dihasilkan per hari pada tiap K. Grafik ini menghubungkan metrik statistik ke beban kerja riil. Misalnya, jika K=50 menghasilkan TP sebesar X dan FP sekitar Y, maka kepala tim dapat mengalokasikan jumlah analis untuk menyelesaikan tiket sejumlah TP+FP dalam satu *shift* sehingga hasil dari pengembangan model ini lebih bersifat *actionable*.

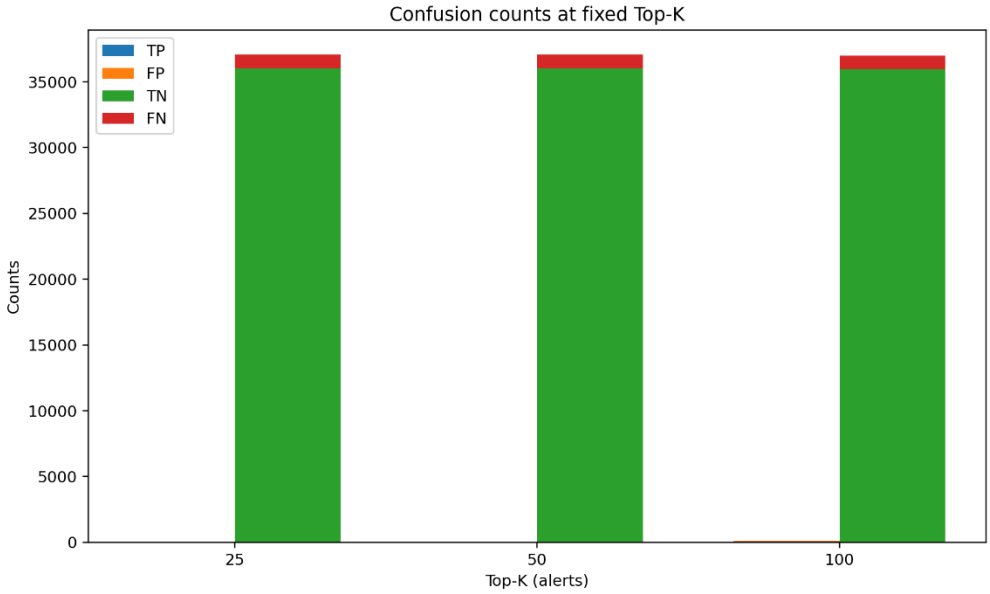

Gambar V.10 Grafik Perbandingan *Confusion* pada K tetap

Pada skenario *Top-K*, jumlah yang diangkat selalu sama (K tetap), tetapi proporsi akan berfluktuasi mengikuti volume harian. Oleh karena itu, indikator stabilitas yang relevan adalah stabilitas kualitas (*precision/lift/FPR*) bukan sekadar stabilitas *selection rate*. Perilaku *precision/lift* antar-hari cenderung rapat (IQR kecil), menandakan ranking k-NN stabil untuk variasi yang terjadi di T2.

Evaluasi ini mendaratkan performa k-NN ke dalam bahasa operasional: pada K kecil (25) presisi paling tinggi dan *noise* paling rendah; pada K menengah (50) *trade-off* presisi terhadap cakupan biasanya paling efisien; pada K besar (100) *recall* meningkat tajam sementara *noise* bertambah namun masih terkendali. Stabilitas *precision/lift* antar-hari yang rapat menunjukkan bahwa *ranking* k-NN dapat diandalkan untuk variasi volume harian. Kombinasi metrik dan grafik yang dihasilkan dapat dijadikan sebagai alat komunikasi yang kuat untuk pimpinan SOC dalam menentukan K operasional yang sesuai kapasitas tim.

V.3 Diskusi

Diskusi ini memaparkan keterjalinan logis antara perumusan masalah, tujuan, rancangan solusi, pemilihan serta rekayasa fitur, implementasi, dan evaluasi, untuk menilai sejauh mana artefak yang dibangun menjawab persoalan utama: mereduksi *alert fatigue* dan meningkatkan efektivitas triase pada lingkungan SIEM berbasis Wazuh. Sejak awal, tugas akhir ini menempatkan deteksi anomali sebagai persoalan pemeringkatan (*ranking*) dengan sasaran praktis pada irisan Top-K/Top-p yang sepadan dengan kapasitas atensi harian analis. Hipotesis kerja yang menyertainya adalah bahwa pemeringkatan berbasis sinyal yang memiliki cakupan tinggi pada data Wazuh dan disertai penjelasan ringkas (*reason codes*) akan mendorong adopsi operasional yang lebih cepat dan akuntabel.

Rancangan solusi dicapai melalui pendekatan yang berangkat dari realitas data. Karakter data yang *alert-centric* mendorong pemilihan "tulang punggung" fitur dengan ketersediaan merata dan biaya komputasi rendah, yakni sinyal temporal (jam lokal, hari, *off-hours*), identitas agen/host, serta metadata aturan (rule/decoder/level). Fitur jaringan, geolokasi, maupun taksonomi serangan yang tidak konsisten hadirnya tidak dijadikan penopang utama; keputusan ini bersifat pragmatis untuk memastikan model dapat berjalan konsisten dari hari ke hari. Di atas fondasi tersebut, rekayasa fitur berfokus pada normalisasi keparahan relatif per host (misalnya *z-score*), ukuran kelangkaan/kebaruan kombinasi *agent*×*rule/decoder*×*waktu*, serta interaksi sederhana (misalnya *off-hours* × *severity*) guna menangkap intuisi operasional yang lazim dipakai analis.

Agar mutu inferensi terjaga, prosedur pembersihan dan kanonisasi skema diterapkan secara deterministik: penyetaraan tipe dan zona waktu, deduplikasi, serta normalisasi nilai *placeholder* sebagai *missing*. Pendekatan ini diperlukan untuk menghindari bias karena "isi semu" dan untuk memastikan bahwa cakupan kolom kunci tercatat akurat sebelum transformasi fitur dilakukan. Seluruh transformer fitur di-*fit* pada periode pelatihan dan "dibekukan" (*frozen*) untuk mencegah *leakage* dan menjaga reprodusibilitas saat inferensi prospektif.

Desain evaluasi meniru kondisi operasional melalui pemisahan temporal pelatihan–validasi–uji prospektif. Periode validasi dilengkapi injeksi kejadian sintetis yang terkurasi (misalnya lonjakan *severity* pada jam tidak lazim, atau kemunculan kombinasi *decoder* yang langka) untuk menyediakan *ground truth* terkontrol tanpa mengandalkan pelabelan manual yang mahal. Dengan demikian, penilaian kinerja bertumpu pada metrik berbasis pemeringkatan yang relevan untuk skenario *budgeted triage*.

Perbandingan kandidat pendekatan menunjukkan perbedaan bias induktif yang bermakna. Metode bertetangga (misalnya k-NN untuk *anomaly scoring*) cenderung unggul pada kejanggalan yang bersifat lokal-kontekstual seperti pola yang normal bagi host tertentu bisa menjadi tidak lazim bagi host lain pada jam berbeda. Pendekatan *global outlier* (misalnya *Isolation Forest*) lebih sensitif pada penyimpangan ekstrem lintas korpus tetapi kurang tajam untuk nuansa *per-host* yang dibutuhkan pada irisan *Top-p* kecil. Secara empiris, pemeringkatan berbasis tetangga secara konsisten menaikkan kepadatan kejadian relevan pada bagian atas daftar dengan *false positive* yang terkendali dan stabil antar-hari, selaras dengan hipotesis awal mengenai keunggulan sensitivitas lokal untuk kebutuhan triase harian.

Secara kuantitatif, evaluasi harian pada set validasi dengan irisan operasional Top-p menunjukkan bahwa pada p = 1% konfigurasi k-NN terbaik (k = 35) mencapai *precision@1%* = 0,6801, *recall@1%* = 0,2340, *lift@1%* = 23,34× terhadap *base rate* harian, dan *FPR@1%* = 0,003304. Ini berpadanan dengan 253 *true positive* dan 119 *false positive* dari 372 *alerts* yang ditelaah per hari (rasio TP:FP ≈ 2,13:1), sekaligus menegaskan "*return on attention*" analis yang tinggi pada irisan kecil tersebut. Pada p yang lebih kecil (0,5%), presisi meningkat hingga 0,812 (k = 5) namun dengan *recall* ≈ 0,14; sementara memperlebar irisan ke p = 2–3% menaikkan *recall* (≈ 0,346 hingga ≈ 0,513) dengan *trade-off* penurunan presisi/*lift* yang konsisten dengan prinsip *budgeted triage*. Oleh karena itu, p = 1% dipilih sebagai titik operasi yang seimbang (presisi tinggi, lift > 23×, *noise* rendah), dengan stabilitas pemilihan irisan antar-hari yang baik.

Lapisan *explainability* dirancang bersamaan dengan mekanisme pemeringkatan. Setiap kejadian berperingkat atas disertai *reason codes* yang merangkum fitur kontributor utama, nilai pembanding terhadap "tetangga normal", serta indikator konteks (misalnya terjadi pada *off-hours* untuk host tertentu). Penjelasan yang ringkas dan terstruktur ini mempercepat proses *handoff* dari deteksi menuju investigasi, sekaligus memperkuat akuntabilitas keputusan triase karena alasan di balik skor dapat ditelusuri kembali.

Implementasi diarahkan untuk siap dioperasionalkan. Transformasi fitur yang deterministik dan dibekukan memungkinkan inferensi harian yang ringan. Layanan *headless* disiapkan dengan kontrak keluaran yang stabil (mengembalikan *Top-K/Top-p* berikut ringkasan penjelasan) sehingga dapat diintegrasikan dengan dasbor pemantauan atau *workflow* otomasi tanpa mengubah kebiasaan kerja analis. Pada tahap demonstrasi, alur layanan dapat dijalankan dalam bentuk *mock* yang membaca keluaran tersiapkan; langkah ini menjaga fokus evaluasi ilmiah sambil menyediakan jalur migrasi yang mulus ke pipeline penuh.

Batasan tugas akhir diakui secara eksplisit. Pertama, sinyal jaringan/geolokasi/taksonomi serangan yang belum konsisten ketersediaannya membatasi perannya dalam "tulang punggung" fitur, meskipun berpotensi memperkaya model setelah dilakukan pembersihan lebih lanjut. Kedua, *ground truth* pada fase validasi bersumber dari injeksi sintetis terkurasi; meskipun realistis, validitas eksternal tetap perlu dilengkapi melalui pelabelan insiden nyata. Ketiga, heterogenitas lingkungan (jumlah agen, perubahan beban kerja) berpotensi menimbulkan *covariate shift*; pengendalian versi data, *seed*, dan dokumentasi prosedur digunakan untuk memperkuat reproduksibilitas. Keempat, penyambungan pembersihan–rekayasa fitur–inferensi ujung-ke-ujung adalah langkah lanjutan yang telah dipetakan pada rencana penerapan.

Jika ditautkan kembali pada pertanyaan dan hipotesis awal, benang merahnya konsisten. Pemodelan sebagai *ranking* terbukti selaras dengan kebutuhan operasional SOC untuk memusatkan atensi pada irisan kecil yang bernilai tinggi. Rangkaian fitur ber-*coverage* tinggi mampu menonjolkan perilaku "tidak seperti

biasanya" pada skala harian. Metode bertetangga menunjukkan kinerja yang meyakinkan pada *budgeted triage* seraya menyediakan penjelasan yang dapat diaudit. Implementasi layanan yang *deployment-friendly* memperlihatkan kesiapan integrasi tanpa mengorbankan ketelitian evaluatif.

Dengan demikian, kontribusi praktis tugas akhir ini terletak pada tiga hal kunci: formulasi deteksi sebagai pemeringkatan yang relevan dengan kapasitas triase, rancangan fitur yang tahan terhadap kelangkaan atribut dan tetap informatif, serta pendekatan model yang sensitif terhadap konteks lokal dan dapat dijelaskan. Arah pengembangan selanjutnya mencakup serialisasi penuh transformer fitur, pengayaan sinyal jaringan/geo/taksonomi pasca-pembersihan, pengurangan ketergantungan pada injeksi sintetis melalui korpus *label* insiden nyata, serta aktivasi *pipeline* inferensi harian ujung-ke-ujung. Keseluruhan hasil menunjukkan bahwa artefak yang dibangun berada pada jalur yang tepat untuk mengatasi *alert fatigue* dan memperkuat kualitas triase pada operasi keamanan harian.

BAB VI

KESIMPULAN DAN SARAN

VI.1 Kesimpulan

Penelitian ini menyajikan artefak deteksi anomali berbasis *machine learning* yang berorientasi operasional untuk mereduksi *alert fatigue* dan meningkatkan efektivitas triase pada lingkungan SIEM Wazuh. Pendekatan yang digunakan menempatkan deteksi sebagai persoalan pemeringkatan (*ranking*) berlapis penjelasan (*explainability*), dengan rancangan data, fitur, evaluasi, dan implementasi yang konsisten satu sama lain.

1. Deteksi dimodelkan sebagai pemeringkatan Top-K/Top-p dengan *reason codes* untuk memastikan fokus atensi analis sekaligus akuntabilitas keputusan.
2. Dibangun *feature spine* ber-coverage tinggi: ritme temporal (jam, hari, *off-hours*), identitas agen/*rule/decoder*/level, normalisasi keparahan relatif per host, ukuran *rarity/novelty*, serta interaksi sederhana; seluruh transformer deterministik dan dibekukan pasca-pelatihan.
3. Skema dinormalisasi, duplikasi dihapus, dan *placeholder* diperlakukan sebagai *missing* untuk mencegah bias serta menjaga konsistensi kolom kunci sebelum inferensi.
4. Pemisahan temporal latih–validasi (dengan injeksi sintetis terkurasi)–uji prospektif meniru kondisi operasional dan menghindari *temporal leakage*; kinerja dinilai lewat *precision@p, recall@p, average precision,* dan *lift@p*.
5. Pendekatan bertetangga (k-NN untuk *anomaly scoring*) paling konsisten pada *budgeted triage* kecil (≈1%): kepadatan *true positive* tinggi, *false positive* terkendali, dan stabilitas antar-hari memadai; *reason codes* mempercepat *handoff* investigasi.

6. Transformasi fitur yang ringan dan layanan *headless* dengan kontrak keluaran stabil (*Top-K/Top-p* + alasan ringkas) menunjukkan kesiapan integrasi ke dasbor/orkestrasi; *mock* menjaga antarmuka tetap konstan menuju pipeline penuh.
7. Permasalahan yang dirumuskan terjawab: pemeringkatan efektif memusatkan atensi pada irisan bernilai tinggi; *feature spine* tahan kelangkaan atribut namun tetap informatif; model sensitif konteks lokal dan dapat dijelaskan. Batasan meliputi ketidakmerataan sinyal jaringan/geo/taksonomi, *ground truth* validasi yang masih sintetis, serta penyambungan E2E yang menjadi pekerjaan lanjutan.

Secara keseluruhan, artefak yang dihasilkan terbukti relevan dan layak dioperasionalkan untuk memperkuat triase harian pada SOC.

VI.2 Saran

Penelitian ini membuka ruang pengembangan lebih lanjut agar kontribusi ilmiah dan nilai praktis sistem semakin kuat. Rekomendasi berikut merangkum perluasan dari butir-butir yang telah dirumuskan, diperkaya dengan arah pengembangan selanjutnya.

1. Normalisasi MITRE ATT&CK (taktik/teknik), tingkatkan kualitas geolokasi, pastikan kolom kunci tersedia di pipeline, seragamkan skema antar-agen, dan bersihkan nilai *placeholder*.
2. Kaitkan ke triase autentikasi, pemantauan web/aplikasi, dan validasi perubahan konfigurasi; tetapkan kebijakan pascadeteksi (rute eskalasi, koroborasi artefak, *feedback* analis) untuk penyetelan ambang dan *active learning*.
3. Integrasikan dengan ekosistem Wazuh/dasbor untuk tren harian, distribusi jam/hari, peringkat anomali, *explainability* per kejadian, dan kesehatan data (cakupan kolom, latensi); hubungkan notifikasi, audit keputusan, dan dokumentasi insiden.

4. Bangun korpus label insiden nyata untuk mengurangi ketergantungan sintetis; lakukan validasi periodik, pemantauan *drift*, dan *recalibration* ambang; uji IF, LOF, One-Class SVM, HBOS, COPOD/ECOD pada subset fitur dan metrik identik (AP, *Precision@k, Recall@1%,* FPR), sambil mencatat latensi dan biaya komputasi.
5. Latih model menggunakan data sintetis sepenuhnya, bukan hanya untuk injeksi anomali, yang dibangun tanpa rujukan apa pun terhadap data maupun karakteristik *Wazuh logs* asli (skema kolom, distribusi, korelasi, atau *template* pola), guna menghilangkan potensi *dataset bias*. Sintesis dilakukan melalui *programmatic simulation* dan *grammar of events* berbasis pengetahuan domain umum serta taksonomi terbuka alih-alih statistik dataset asli; evaluasi memakai *scenario-based testing*, *red teaming*, dan *invariance checks*, dengan *seed* dan konfigurasi generator yang terdokumentasi agar replikasi dan auditabilitas terjaga.

Rekomendasi di atas bertujuan memastikan artefak tidak hanya unggul di metrik, tetapi juga siap diadopsi secara berkelanjutan dalam praktik SOC, skalabel, dan mudah diaudit.

DAFTAR PUSTAKA

Alatawi, Eman, dan Umar Albalawi. 2025. "Harnessing AI for Cyber Defense: Honeypot-Driven Intrusion Detection Systems." *Symmetry* 17 (5): 628. https://doi.org/10.3390/sym17050628.

Al-Dahasi, Ezaz, dan Fakhri Alam Khan. 2024. "Automating Security Incident Response in SCADA Systems through SIEM-ML Integration." Dalam *ICAC 2024 - 29th International Conference on Automation and Computing*. Institute of Electrical and Electronics Engineers Inc. https://doi.org/10.1109/ICAC61394.2024.10718780.

Aminanto, Muhamad Erza, Lei Zhu, Tao Ban, Ryoichi Isawa, Takeshi Takahashi, dan Daisuke Inoue. 2019. "Automated Threat-Alert Screening for Battling Alert Fatigue with Temporal Isolation Forest." Dalam *2019 17th International Conference on Privacy, Security and Trust (PST)*, 1–3. https://doi.org/10.1109/PST47121.2019.8949029.

Ban, Tao, Takeshi Takahashi, Samuel Ndichu, dan Daisuke Inoue. 2023. "Breaking Alert Fatigue: AI-Assisted SIEM Framework for Effective Incident Response." *Applied Sciences (Switzerland)* 13 (11). https://doi.org/10.3390/app13116610.

Bulgakova, Elena V., Pavel A. Vasilevskiy, Daniil S. Doynikov, dan Alexander N. Kubankov. 2025. "Analysis of Explainable Artificial Intelligence Methods in Security Information and Event Management Systems." Dalam *2025 Systems of Signals Generating and Processing in the Field of on Board Communications, SOSG 2025 - Conference Proceedings*. Institute of Electrical and Electronics Engineers Inc. https://doi.org/10.1109/IEEECONF64229.2025.10948089.

Clickhouse. 2025. *Clickhouse Documentation*. Clickhouse. Diakses 5 Mei 2025. https://clickhouse.com/docs.

Coralogix. 2024. "What Is SIEM, How It Works, and Essential SIEM Tools to Consider." Coralogix. Diakses 3 Mei 2025. https://coralogix.com/guides/siem/.

Cynet. 2024. “What Is a SOC? 10 Core Functions and 6 Key Challenges.” Cynet. 20 November 2024. Diakses 2 Mei 2025. https://www.cynet.com/incident-response/what-is-a-soc-10-core-functions-and-6-key-challenges/.

Goldstein, Markus, Matthias Reif, Andrew Hutchison, dan Stefan Asanger. 2013. “Enhancing Security Event Management Systems with Unsupervised Anomaly Detection.” https://www.researchgate.net/publication/235744906.

Gsami, Rezos, dan Thiagoalz. t.t. “Brute Force Attack.” OWASP. Diakses 1 Mei 2025. https://owasp.org/www-community/attacks/Brute_force_attack.

IBM. t.t. “What is OLAP (online analytical processing)?” IBM. Diakses 1 Mei 2025. https://www.ibm.com/think/topics/olap.

ISO/IEC 27001. 2022. *Information security, cybersecurity and privacy protection-Information security management systems-Requirements*. ISO

Jangampeta, Shivadutt. 2022. “AI AND MACHINE LEARNING IN SIEM: ENHANCING THREAT DETECTION AND RESPONSE WITH PREDICTIVE ANALYTICS.” *International Journal of Artificial Intelligence & Machine Learning (IJAIML)*. Vol. 1.

Kidd, Chrissy. 2025. “SIEM: Security Information & Event Management Explained.” Splunk. 3 Januari 2025. https://www.splunk.com/en_us/blog/learn/siem-security-information-event-management.html.

Langlois, Philippe, Alex Pinto, David Hylender, dan Suzanne Widup. 2023. *DBIR 2023 Data Breach Investigations Report*. Verizon

Manning, Christopher, Prabhakar Raghavan, dan Hinrich Schütze. 2009. *An Introduction to Information Retrieval*. Cambridge University Press.

MITRE Corporation. 2025. “MITRE ATT&CK Framework.” MITRE. Diakses 20 Agustus 2025 https://attack.mitre.org/.

Miranda, Paola. 2024. “What is a Security Operations Center (SOC) ?” Crowdstrike. 24 Mei 2024. https://www.crowdstrike.com/en-us/cybersecurity-101/next-gen-siem/security-operations-center-soc/.

Mohanan, Remya. 2022. “What Is Security Information and Event Management (SIEM)? Definition, Architecture, Operational Process, and Best Practices.” Spiceworks. 24 Februari 2022. https://www.spiceworks.com/it-security/vulnerability-management/articles/what-is-siem/.

Mohri, M, A Rostamizadeh, dan A Talwalkar. 2012. *Foundations of Machine Learning*. Adaptive Computation and Machine Learning series. MIT Press.

Muhammad, Adabi Raihan, Parman Sukarno, dan Aulia Arif Wardana. 2022. “Integrated Security Information and Event Management (SIEM) with Intrusion Detection System (IDS) for Live Analysis based on Machine Learning.” Dalam *Procedia Computer Science*, 217:1406–15. Elsevier B.V. https://doi.org/10.1016/j.procs.2022.12.339.

Nichols, Mike, dan Mike Paquette. 2024. “Tracing history: The generative AI revolution in SIEM.” Elastic. 9 April 2024. https://www.elastic.co/blog/generative-ai-revolution-in-siem.

NIST. 2020. *Security and Privacy Controls for Information Systems and Organizations*. Gaithersburg, MD: NIST. https://doi.org/10.6028/NIST.SP.800-53r5.

Ranjan, RIshu. t.t. “Password Spraying Attack.” OWASP. Diakses 1 Mei 2025. https://owasp.org/www-community/attacks/Password_Spraying_Attack.

Russell, S, dan P Norvig. 2021. *Artificial Intelligence: A Modern Approach, Global Edition*. Pearson Education.

Sørbø S, Ruocco M. 2024. “Navigating the metric maze: a taxonomy of evaluation metrics for anomaly detection in time series.” *Data Mining and Knowledge Discovery* 38 (3):1027-1068. https://doi.org/10.1007/s10618-023-00988-8

Tendikov, Noyan, Leila Rzayeva, Bilal Saoud, Ibraheem Shayea, Marwan Hadri Azmi, Ali Myrzatay, dan Mohammad Alnakhli. 2024. “Security Information Event

Management data acquisition and analysis methods with machine learning principles." *Results in Engineering* 22 (Juni). https://doi.org/10.1016/j.rineng.2024.102254.

Wazuh. 2025. *Wazuh Documentation*. Wazuh. Diakses 1 Mei 2025. https://documentation.wazuh.com/current/index.html.

Whitman, M E, dan H J Mattord. 2021. *Principles of Information Security*. Cengage Learning.

LAMPIRAN A

HASIL *BEST-OF-EACH* ALGORITMA PADA METRIK P

A.1 Tabel Metrik Terbaik Pada Algoritma *k-Nearest Neighbor* (Parameter: **{"n_neighbors": 35})**

p	Selected	TP	FP	FN	TN	Precision@p	Recall@p	Lift@p	Prevalence	FPR@p	Primary Precision
0.005	186	146	40	935	35982	0.7849	0.1351	26.9416	0.0291	0.0011	0.6801
0.01	372	253	119	828	35903	0.6801	0.234	23.3432	0.0291	0.0033	0.6801
0.02	743	370	373	711	35649	0.498	0.3423	17.0921	0.0291	0.0104	0.6801
0.03	1114	555	559	526	35463	0.4982	0.5134	17.0998	0.0291	0.0155	0.6801

A.2 Tabel Metrik Terbaik Pada Algoritma *Isolation Forest* (Parameter: {"n_estimators": 600, "max_samples": 0.5, "max_features": 0.8, "bootstrap": true})

p	Selected	TP	FP	FN	TN	Precision@p	Recall@p	Lift@p	Prevalence	FPR@p	Primary Precision
0.005	186	66	120	1015	35902	0.3548	0.0611	12.1791	0.0291	0.0033	0.4032
0.01	372	150	222	931	35800	0.4032	0.1388	13.8399	0.0291	0.0062	0.4032
0.02	743	224	519	857	35503	0.3015	0.2072	10.3477	0.0291	0.0144	0.4032
0.03	1114	285	829	796	35193	0.2558	0.2636	8.781	0.0291	0.023	0.4032

A.3 Tabel Metrik Terbaik Pada Algoritma *Local Outlier Factor*

p	Selected	TP	FP	FN	TN	Precision@p	Recall@p	Lift@p	Prevalence	FPR@p	Primary Precision
0.005	186	28	158	1053	35864	0.1505	0.0259	5.1669	0.0291	0.0044	0.3011
0.01	372	112	260	969	35762	0.3011	0.1036	10.3338	0.0291	0.0072	0.3011
0.02	743	119	624	962	35398	0.1602	0.1101	5.4972	0.0291	0.0173	0.3011
0.03	1114	130	984	951	35038	0.1167	0.1203	4.0054	0.0291	0.0273	0.3011

LAMPIRAN B

TANGKAPAN LAYAR ANTARMUKA GRADIO

B.1 *Screenshot* Tampilan UI Gradio untuk Demo Inferensi

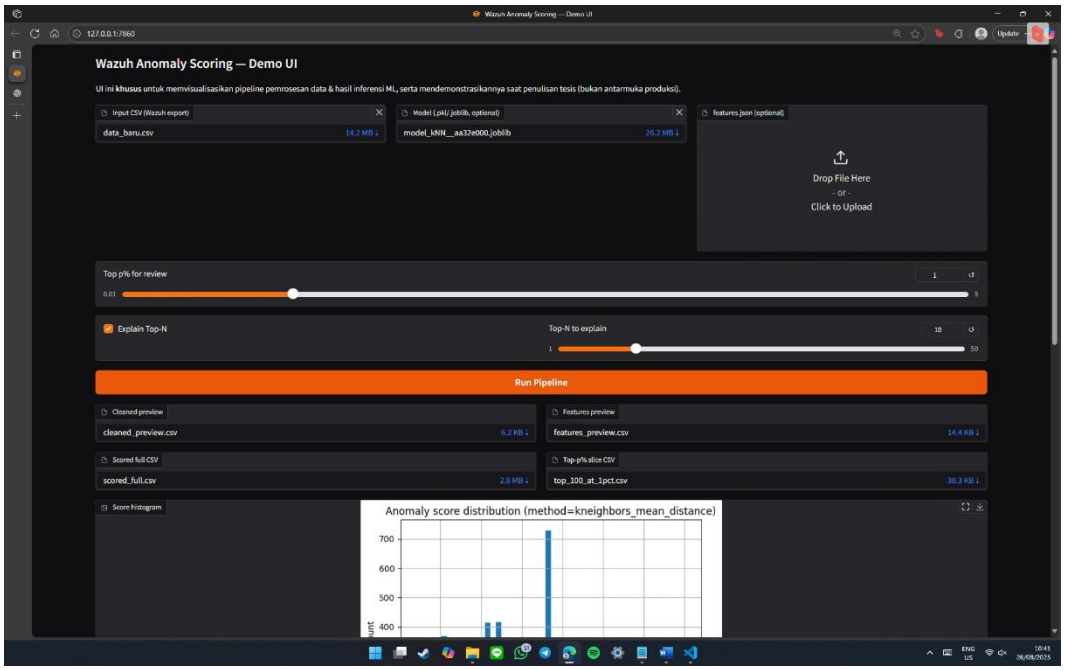

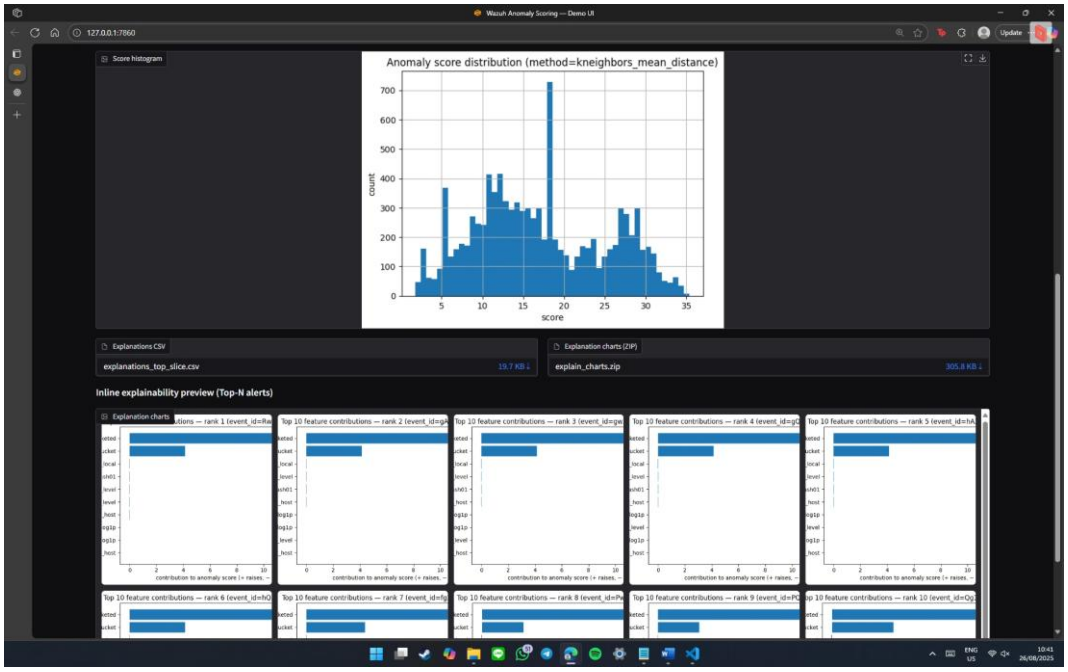

LAMPIRAN C

SOURCE CODE IMPLEMENTASI

C.1 Tautan Github

https://github.com/SirRay03/Wazuh-Anomaly-Triage-ML